



AN IMAGE IS WORTH 16X16 WORDS: TRANSFORMERS FOR IMAGE RECOGNITION AT SCALE

■ 생성일	@2025년 9월 24일 오후 10:17
■ 태그	In progress

- 1) 어떤 문제를 해결하려 했는가? (Abstract)
- 2) 연구 동기와 문제점 (Introduction)
- 3) 관련 연구 동향 (Related Works)
- 4) 연구 접근법과 모델 구조 (Method)
- 5) 무엇을 발견했고 한계는? (Discussion)
- 6) 결론 및 주요 요약 (Conclusion)

1) 어떤 문제를 해결하려 했는가? (Abstract)

- CNN에 의존하지 않고도, 이미지를 패치 토큰의 시퀀스로 보고 표준 Transformer 인 코더만으로 이미지 분류가 잘 되는지 규명
- 충분한 대규모 데이터로 사전학습(pre-train) 후 다양한 중/소규모 벤치마크로 전이하면 SOTA CNN과 비슷하거나 더 좋은 성능을 적은 연산량으로 달성한다는 것을 보임

2) 연구 동기와 문제점 (Introduction)

- NLP에서는 대용량 코퍼스에서 사전학습 → 다운스트림 미세조정이 표준이며, 트랜스포머는 효율·스케일러빌리티 덕에 초대형 모델까지 확장되어 성능이 계속 향상됨
- CV에서는 여전히 CNN이 주류이고, Self-Attention을 도입하더라도 특수한 어텐션 패턴 탓에 대규모로 잘 스케일되지 않았음

- 저자들은 최소한의 변경으로 표준 Transformer를 이미지에 직접 적용: 이미지를 패치로 나눠 패치 임베딩 시퀀스를 입력으로 사용하고 감독학습으로 학습

중간 규모 데이터(예: ImageNet)만으로는 ResNet 대비 소폭 열세이나, 대규모 데이터 (14M-300M) 로 사전학습하면 귀납 편향의 부족을 데이터로 극복하며 다양한 벤치마크에서 SOTA를 달성함

3) 관련 연구 동향 (Related Works)

- 픽셀 단위로 직접 Self-Attention을 쓰면 $O(P^2)$ 비용이라 현실적 이미지 크기에 비효율적
- 그래서 국소 어텐션, 스파스/블록/축(axial) 어텐션 등 다양한 근사법이 등장했으나 하드웨어 친화적 구현이 복잡함
- 비슷한 아이디어로 2x2 패치를 토큰화해 전역 어텐션을 쓴 모델(Cordonnier 등)도 있으나, 저자들은 더 큰 패치/중간 해상도까지 다루며 대규모 사전학습이 순수 트랜스포머를 경쟁력 있게 만든다는 점을 입증
- CNN+어텐션 하이브리드, DETR, iGPT 등 다양한 변형이 제안되었으나 순수 트랜스포머의 단순성·스케일 이점을 본 논문이 보여줌

4) 연구 접근법과 모델 구조 (Method)

<토큰화 & 입력 구성>

- 이미지를 PxP패치로 나눈 뒤, 각 패치를 선형 투영해서 패치 임베딩을 얻고, [CLS] 토큰과 학습 가능한 1D 위치 임베딩을 더해 Transformer 인코더에 입력
- 1D 위치 임베딩이면 충분하고 2D-aware 변형은 큰 이득이 없었음
- 핵심 수식(식 1-4):

$$z_0 = [x_{\text{class}}; x_1^p E; \dots; x_N^p E] + E_{\text{pos}},$$

$$z'_\ell = \text{MSA}(\text{LN}(z_{\ell-1})) + z_{\ell-1},$$

$$z_\ell = \text{MLP}(\text{LN}(z'_\ell)) + z'_\ell,$$

$$y = \text{LN}(z_L^0)$$

<블록 구성>

- 인코더는 MSA ↔ MLP를 교차하게 쌓고, Pre-LN + 잔차 구조, MLP는 GELU

- 귀납 편향은 CNN보다 훨씬 적다: ViT는 전역 어텐션이 기본이며 2D 구조 가정이 거의 없음(패치화, 고해상도 미세조정시 pos. interp 정도만 사용)

- **하이브리드 변형 & 고해상도 미세조정**

- ResNet 특징맵을 입력 시퀀스로 바꾸는 Hybrid ViT도 제시
- 미세조정 시 입력 해상도를 올리고, 사전학습된 위치 임베딩을 2D 보간하여 길어진 시퀀스에 맞춤

- **MSA 기본식**

- qkv 투영 → 점곱 어텐션 → 다중 헤드 결합:

$$[q, k, v] = zU_{qkv}, A = \text{softmax}(qk^\top / \sqrt{D_h}), SA(z) = Av,$$

$$MSA(z) = [SA_1(z); \dots; SA_k(z)]U_{msa}$$

실험 구성과 결과 (Experiments)

- 모델·데이터·학습
 - 모델 스케일: Base/Large/Huge(12/24/32층, 86M/307M/632M 파라미터)
패치 크기가 작을수록 시퀀스 길이가 $1/P^2$ 에 비례해 늘어 연산 증가
 - 옵티마이저/정규화: 사전학습은 Adam, 배치 4096, weight decay 0.1, LR warmup/decay, ImageNet 미세조정은 SGD(m=0.9)
- 주요 결과
 - **성능-연산량 트레이드오프**: ViT는 ResNet 대비 동일 성능에 2-4x 적은 사전학습 연산이 필요하다. 소규모 예산에선 하이브리드가 근소 우위이나 규모가 커지면 차이 해소. 확장할수록 성능이 계속 오름(미포화)
 - **속도/메모리**: TPU에서 실행 시 ViT는 비슷한 크기의 ResNet과 유사 속도, 더 큰 배치를 엮을 만큼 메모리 효율적
 - **전이 학습**: ImageNet-21k 또는 JFT-300M 사전학습 후 ImageNet/CIFAR/VTAB 등에서 SOTA에 근접·상회, 예: ImageNet 88.55% 등
 - **표현 분석**:
 - 첫 층 필터는 패치 내 저차 구조의 기저 함수처럼 보임

- 위치 임베딩은 2D 구조(행/열·거리)를 학습해 나타냄
- Attention distance(수용영역 유사)는 깊이와 함께 증가, 하위층 일부 헤드는 전역을, 일부는 국소를 본다

5) 무엇을 발견했고 한계는? (Discussion)

- 발견
 - 큰 데이터로의 사전 학습이 CNN의 귀납 편향(평행이동 불변·국소성 등) 부족을 상쇄함
 - ViT는 전역·국소 주의의 병용을 층/헤드별로 자연스럽게 학습하며, 깊어질수록 전역 통합이 증가
 - 위치 인코딩 방식의 차이는 성능 차이가 매우 작음(무/1D/2D/상대)
- 한계
 - **자가 지도**만으로는 아직 감독 사전 학습에 성능 격차가 남아있음
 - 본 논문은 주로 분류에 초점—검출/분할 등 다른 과업으로의 일반화와 더 큰 스케일링은 과제로 남음

6) 결론 및 주요 요약 (Conclusion)

- 이미지를 패치 시퀀스로 보고 표준 Transformer만으로 처리하는 단순·스케일 친화적 접근이, 대규모 사전학습과 결합될 때 강력함
- 다양한 분류 벤치마크에서 SOTA 수준이며 학습 연산량도 절감된다

1. **순수 트랜스포머**: CNN 구성요소/특수 어텐션 패턴 없이 표준 인코더만 사용(패치화 + 1D pos)
2. **스케일 우선 전략**: 귀납편향 대신 대규모 감독 사전 학습으로 일반화 확보
3. **연산 효율**: 동일 전이 성능에 2-4× 적은 사전 학습 연산