

BART

■ 상위 작업	📖 세션 논문 리뷰
■ 진행 상태	완료
■ 첨부 파일	BART.pdf

[0. Abstract](#)

[1. Introduction](#)

[2. Related Work](#)

[3. Method \(제안 방법론\)](#)

[3.1. Model Architecture](#)

[3.2. Pre-training BART](#)

[3.3 Fine-tuning BART](#)

[4. Experiments \(실험 및 결과\)](#)

[4.1. Comparing Pre-training Objectives](#)

[4.2 Tasks](#)

[4.3 Results](#)

[4.4. Large-scale Pre-training Experiment](#)

[4.5. Tasks](#)

[4.6. Qualitative Analysis](#)

[5. Conclusion](#)

0. Abstract

어떤 문제를 해결하려 했는가?



- 기존의 사전학습 모델들은 이해나 생성 등 특정 태스크에만 강점을 보여 범용성이 부족했다.
- **BART**는 Denoising Autoencoder 기반의 Seq2Seq 모델로,
 1. 텍스트에 임의의 노이즈를 주고,
 2. 원본 텍스트를 복원하도록 학습한다.
- 이 과정은 Transformer 기반 신경기계번역 아키텍처를 사용하며, **BERT(양방향 인코더)**와 **GPT(좌→우 디코더)**의 특성을 모두 결합한 형태로 볼 수 있다.

- 본 논문에서는 문장 순서를 무작위로 섞거나 특정 구간을 하나의 마스크 토큰으로 대체하는 방식의 노이즈를 활용했다. 특히 Fine-tuning 시 텍스트 생성에서 뛰어난 성능을 보였으며, 텍스트 이해 태스크에서도 준수한 성능을 보였다.
- 발표 당시 BART는 RoBERTa와 유사한 학습 환경에서 대화, 질의응답, 요약 태스크에서 새로운 state-of-the-art를 기록했다.

1. Introduction


연구 동기와 문제점은 무엇인가?

- Self-supervised Learning은 NLP에서 성공적이었다. 대표적으로 단어를 마스킹해 맞추는 방식인 denoising autoencoder이다.
- 하지만 최근 연구는 마스크된 토큰의 분포를 개선하는 방향으로 진행되었고 이 방법들은 특정 태스크에만 집중되는 한계가 있다.
- 본문에서는 매우 광범위한 end task에 적용 가능한 범용모델인 BART를 제안한다.
- BART는 denoising autoencoder로 sequence-to-sequence 모델로 만들어져 다양한 태스크에 적용 가능하다.
- BART는 사전학습 시
 1. 텍스트에 임의의 noise로 손상을 주고
 2. seq2seq 모델을 학습해 원래 텍스트 데이터로 재구성하는 과정을 거친다.



BERT: Random token들이 masks로 대체되고, 문서는 Bidirectionally하게 인코딩된다. 누락된 token들은 독립적으로 예측되므로 **BERT는 generation에 쉽게 사용될 수 없다.**

GPT: Token들이 auto-regressively하게 예측되므로 GPT는 generation에 사용될 수 있다. 그러나 단어들은 왼쪽 context만 의존할 수 있으므로 **bidirectional interactions**를 학습할 수 없다.



BART : Encoder에 대한 입력은 decoder 출력과 aligned 될 필요가 없으므로 임의의 noise transformations를 허용한다. 손상된 문서(왼쪽)는 bidirectional model로 인코딩된 다음 원본 문서(오른쪽)의 likelihood가 autoregressive decoder로 계산된다. Fine-tuning을 위해 손상되지 않은 문서가 encoder와 decoder 모두에 입력되고 decoder의 final hidden state에서 representations를 사용한다.

- BART의 장점은 noising flexibility인데, 문장 섞기, 구간 in-filling 등 다양한 손상 방식이 적용 가능하다.
- 문장 이해(GLUE, SQuAD)에서는 RoBERTa 수준, 문장 생성(QA/요약/대화)에서는 SOTA를 달성했다.
- 추가적으로 기계번역에 맞는 새로운 fine-tuning 구조를 제안하여 1.1BLEU 증가를 보였고, ablation 분석을 통해서 모든 태스크에서 일관된 강력함을 입증했다.

2. Related Work

| 관련 연구 동향은 어떠한가?

- **GPT (Radford et al., 2018)**

좌→우(Leftward) 문맥만 학습하는 언어모델이라 생성은 가능하지만, 미래 문맥을 활용하지 못해 한계가 있다.

- **ELMo (Peters et al., 2018)**

좌→우, 우→좌 LM을 각각 학습해 연결했지만, 두 방향의 상호작용을 학습하지 못했다.

- **BERT (Devlin et al., 2019)**

Masked LM으로 양방향 문맥을 학습할 수 있게 했지만, 예측이 독립적으로 이루어져 생성 태스크에는 약하다. 이후 RoBERTa(더 긴 학습), SpanBERT(스팬 마스킹), ALBERT(파라미터 공유) 등 다양한 변형이 제안되었다.

- **UniLM (Dong et al., 2019)**

마스킹 패턴을 다양하게 적용해 생성과 이해 모두 가능하게 했다. 그러나 예측이 조건부 독립적이라 BART처럼 Autoregressive 특성을 갖지 않는다.

- **MASS (Song et al., 2019)**

입력의 연속된 스펠을 마스킹하고 그 구간을 복원하는 Seq2Seq 모델. BART와 유사하지만, 인코더·디코더에 분리된 입력을 넣기 때문에 분류 태스크에는 덜 효과적이다.

- **XLNet (Yang et al., 2019)**

BERT를 확장해 토큰 순서를 섞어 학습함으로써 양방향 정보를 얻고, Autoregressive 성질도 유지한다.

3. Method (제안 방법론)

| 연구 접근법과 모델 구조는 어떻게 되는가?

Main Idea

1. corrupting text with an arbitrary noising function (document corruption)
2. learning a model to reconstruct the original text (denoising)

3.1. Model Architecture

Sequence-to-Sequence transformer model

ReLU activation function 대신 GeLUs 사용

base model : 6 layers (인코더 디코더 각각)

large model : 12 layers (인코더 디코더 각각) → BERT와 유사

차이점

1. decoder의 각 layer에서는 encoder의 마지막 hidden layer와 cross-attention 수행
2. BERT에서 사용한 additional feed-forward network 사용 X

3.2. Pre-training BART

- BART는 원문 텍스트를 **document corruption(변환)**으로 일부러 손상시킨 뒤, 손상된 문장을 입력으로 넣어 원래 문장을 복원하도록 학습한다.
- 복원 결과와 원문 차이는 cross-entropy 기반 reconstruction loss로 계산해 최적화한다.
- 이때 **변환**에 사용하는 기법은 다음과 같다.




Figure 2: Transformations for noising the input that we experiment with. These transformations can be composed.

3.2.1. Token Masking

- 임의 토큰을 [MASK] token으로 바꾸는 방식이다. (BERT 방식)
- BERT의 Masking을 따르기 때문에 input sequence는 유지해야 한다.
- [MASK] token이 무엇인지 예측해야 한다.

3.2.2. Token Deletion

- input에서 임의 token을 삭제하는 방식이다.
- 삭제된 token에 대해 위치 추론이 필요하다.

3.2.3. Text Infilling

- Poisson dist. ($\lambda=3$)에서 text span length를 뽑아 하나의 [MASK] token으로 대체한다.
- Span length가 0인 경우 해당 위치에 [MASK] token을 추가한다.
- [MASK]로 대체된 token을 몇 개의 token이 존재할지 예측해야 한다.

3.2.4. Sentence Permutation

- 문서를 문장 단위로 나누고 문장 순서를 랜덤으로 섞어 입력하는 방식이다.


3.2.5. Document Rotation

- 하나의 token을 uniformly하게 뽑은 후, 그 토큰을 시작점으로 회전한다.
- 모델이 문서의 start point를 찾도록 학습시킨다.

3.3 Fine-tuning BART

- BART는 pre-trained 모델로, 다양한 downstream 태스크에 다양하게 fine-tuning 하여 적용될 수 있다.

3.3.1. Sequence Classification Tasks



BART를 classification 문제에 사용하기 위해 동일한 입력이 encoder와 decoder에 입력되고, final output에서 얻은 representation이 사용됩니다.

- 같은 입력값이 인코더와 디코더에 입력된다.
- 마지막 디코더 토큰의 hidden state는 새로운 multi classifier에 입력된다.
- 이때 BERT는 `[CLS] ... tokens ... [SEP]` 토큰 구조에서 [CLS]의 hidden state를 representation으로 활용한다.
- BART에서는 End 토큰을 사용하여 `<s> ... tokens ... </s>` 구조에서 </s>의 hidden state를 representation로 활용한다.

3.3.2. Token Classification Task

- SQuAD와 같은 Token Classification에서 완전한 문서를 인코더와 디코더에 입력한다.
- 마지막 디코더의 hidden state를 각 단어의 representation으로 사용한다
- 이 representation은 토큰 분류에 사용된다.


3.3.3. Sequence Generation Tasks

- BART는 자기회귀(autoressive decoder)를 가지고 있어 abstractive question answering, summarization와 같은 sequence generation 태스크에

사용될 수 있다.

- BART는 자기회귀(autoregressive decoder)를 가지고 있어 abstractive question answering, summarization와 같은 sequence generation 태스크에 사용될 수 있다.
- 두 태스크 모두 입력 정보를 활용해 재구성하는 과정을 거치며, BART의 denoising pre-training 목표와 연결된다.
- 인코더는 입력을 받고, 디코더는 이를 자기회귀적으로 생성한다.

3.3.4. Machine Translation



- BART를 기계번역 디코더로 활용해 성능을 개선하였다.
- 기존 연구는 사전학습된 인코더 활용의 이점을 보였지만, 디코더 쪽 이점은 제한적이었다.
- 본 연구에서는 전체 BART(encoder+decoder)를 사전학습된 디코더로 사용하고, 인코더는 새로 초기화하여 외국어를 BART가 복원 가능한 영어 표현으로 학습시켰다.
- 학습은 두 단계로 진행되는데
 - 1단계에서는 parameter 대부분을 freeze하고, source encoder, positional embedding, self-attention input projection matrix만 업데이트한다.
 - 2단계에서는 모든 model parameter를 적은 iteration 동안 학습한다. 두 단계 모두 cross-entropy loss를 역전파하여 최적화한다.

4. Experiments (실험 및 결과)

| 실험 구성과 결과는?

4.1. Comparing Pre-training Objectives

- BART는 이전 연구보다 사전학습 과정에서 더 넓은 범위의 noising 구조를 사용할 수 있었다. base-size model을 사용해 여러 태스크에 대해서 비교했다.
→ 6개의 encoder, 6개의 decoder, hidden size 768
- 다양한 pre-training objectives를 공정하게 비교하기 위해, 동일한 크기의 모델을 Books+Wikipedia corpus에서 1M steps 동안 다시 학습시켰다. 각 objective에 대해서는 learning rate와 layer normalization을 약간 조정했으며, 결과는 동일한 데이터에서 1M steps 동안 학습된 BERT의 published numbers와 비교하였다.
- 비교에 사용한 모델은 다음과 같다.

Language Model

GPT처럼 left-to-right 단어를 예측하는 모델

Permuted Language Model

XLNet 기반 모델, 순서를 무작위로 섞은 후 원래의 단어를 예측

Masked Language Model

BERT와 동일한 방식, 단어를 MASK로 가리고, 가려진 단어가 무엇인지 양방향 문맥을 활용하여 예측

Multitask Masked Language Model

Masked Language Model을 추가적인 self-attention mask를 통해 훈련

Masked Seq-to-Seq

문장의 일부 구간을 통째로 가린 뒤 Incoder - Decoder모델로 가려진 부분을 예측

4.2 Tasks

- a. **SQuAD** : extractive question answering
- b. **MNLI** : bitext classification
- c. **ELI5** : long-form abstractive question answering
- d. **XSum** : news summarization
- e. **ConvAI2** : dialogue response generation task

f. **CNN/DM** : news summarization

4.3 Results

Model	SQuAD 1.1 F1	MNLI Acc	ELI5 PPL	XSum PPL	ConvAI2 PPL	CNN/DM PPL
BERT Base (Devlin et al., 2019)	88.5	84.3	-	-	-	-
Masked Language Model	90.0	83.5	24.77	7.87	12.59	7.06
Masked Seq2seq	87.0	82.1	23.40	6.80	11.43	6.19
Language Model	76.7	80.1	21.40	7.00	11.51	6.56
Permuted Language Model	89.1	83.7	24.03	7.69	12.23	6.96
Multitask Masked Language Model	89.2	82.4	23.73	7.50	12.39	6.74
BART Base						
w/ Token Masking	90.4	84.1	25.05	7.08	11.73	6.10
w/ Token Deletion	90.4	84.1	24.61	6.90	11.46	5.87
w/ Text Infilling	90.8	84.0	24.26	6.61	11.05	5.83
w/ Document Rotation	77.2	75.3	53.69	17.14	19.87	10.59
w/ Sentence Shuffling	85.4	81.5	41.87	10.93	16.67	7.89
w/ Text Infilling + Sentence Shuffling	90.8	83.8	24.17	6.62	11.12	5.41

- 사전학습 방법의 성능이 태스크에 따라 크게 다르다. 예를 들어 simple language 모델이 ELI5에서 가장 좋은 성능을 보이지만 SQuAD에서 가장 나쁜 성능을 보입니다.
- Token masking은 중요하다.
- rotating document나 permuting sentences는 상대적으로 성능이 떨어졌다.
- left-to-right 사전학습은 생성에 성능 향상을 이끌었다.
- SQuAD에서는 양방향 인코더가 중요하다.
- Permuted Language Model은 XLNet보다 낮은 성능을 보여줬는데 이는 relative-position embedding이나 segment level recurrence와 같은 다른 구조적 개선을 포함하지 않아 나타난 것으로 사전학습 objective만이 중요한 것은 아님을 보여준다
- ELI5 데이터셋은 outlier로 Pure language model일 때 좋은 성능을 보인다.
- **text-infilling**을 사용한 **BART**가 ELI5를 제외하고 가장 좋은 성능을 보여줘 가장 일관되게 높은 성능을 가진다.

4.4. Large-scale Pre-training Experiment

- 최근 연구에 따르면 사전학습은 large batch size와 대규모 코퍼스를 사용할 때 하위 태스크 성능이 크게 향상된다. 이에 BART를 RoBERTa와 동일한 스케일로 학습하여 실제 활용성을 검증했다.

- 인코더와 디코더 각각 12레이어, hidden size 1024의 Large 모델을 160GB 텍스트로 50만 스텝 학습했으며, text infilling과 sentence permutation을 조합한 objective를 사용했다. 또한 마지막 10% 단계에서는 dropout을 제거해 모델이 데이터에 더 잘 적합하도록 했다.

4.5. Tasks

4.5.1. Discriminative Tasks

	SQuAD 1.1 EM/F1	SQuAD 2.0 EM/F1	MNLI m/mm	SST Acc	QQP Acc	QNLI Acc	STS-B Acc	RTE Acc	MRPC Acc	CoLA Mcc
BERT	84.1/90.9	79.0/81.8	86.6/-	93.2	91.3	92.3	90.0	70.4	88.0	60.6
UniLM	-/-	80.5/83.4	87.0/85.9	94.5	-	92.7	-	70.9	-	61.1
XLNet	89.0/94.5	86.1/88.8	89.8/-	95.6	91.8	93.9	91.8	83.8	89.2	63.6
RoBERTa	88.9/ 94.6	86.5/89.4	90.2/90.2	96.4	92.2	94.7	92.4	86.6	90.9	68.0
BART	88.8/ 94.6	86.1/89.2	89.9/90.1	96.6	92.5	94.9	91.2	87.0	90.4	62.8

- SQuAD와 GLUE 태스크에서의 Large model 결과
 - BART는 RoBERTa와 XLNet과 비슷한 성능을 보였다.
→ BART의 uni-directional decoder가 discriminative task의 성능을 낮추지 않았다.

4.5.2. Generation Tasks

- Summarization

	CNN/DailyMail			XSum		
	R1	R2	RL	R1	R2	RL
Lead-3	40.42	17.62	36.67	16.30	1.60	11.95
PTGEN (See et al., 2017)	36.44	15.66	33.42	29.70	9.21	23.24
PTGEN+COV (See et al., 2017)	39.53	17.28	36.38	28.10	8.02	21.72
UniLM	43.33	20.21	40.51	-	-	-
BERTSUMABS (Liu & Lapata, 2019)	41.72	19.39	38.76	38.76	16.33	31.15
BERTSUMEXTABS (Liu & Lapata, 2019)	42.13	19.60	39.18	38.81	16.50	31.27
BART	44.16	21.28	40.90	45.14	22.27	37.25

- CNN/DailyMail 데이터셋은 추출요약에서 좋은 성능을 보였고 XSum 데이터셋은 생성 요약에 높은 성능을 보였다.

- BART가 SOTA를 달성했다.

- Dialogue

	ConvAI2	
	Valid F1	Valid PPL
Seq2Seq + Attention	16.02	35.07
Best System	19.09	17.51
BART	20.72	11.85

- BART가 두 성능평가에서 이전 모델을 능가했다.

- Abstractive QA

	ELI5		
	R1	R2	RL
Best Extractive	23.5	3.1	17.5
Language Model	27.8	4.7	23.1
Seq2Seq	28.3	5.1	22.8
Seq2Seq Multitask	28.9	5.4	23.1
BART	30.6	6.2	24.3

- 이전 연구보다 1.2 ROUGE-L 향상을 보였다. (SOTA)
→ 하지만 질문에 대한 답이 여전히 약하게 명시되어 있어 연구가 필요하다.

- Translation

	RO-EN
Baseline	36.80
Fixed BART	36.29
Tuned BART	37.96

- Back-translation data를 사용하였고, 6-layer Transformer source encoder를 사용하여 Romanian을 BART가 처리 가능한 형태로 변환했다.
- Baseline Transformer model 대비 성능이 향상했다. 다만 Back-translation data 없이는 overfitting 발생 가능성이 있다.

4.6. Qualitative Analysis

Source Document (abbreviated)	BART Summary
The researchers examined three types of coral in reefs off the coast of Fiji ... The researchers found when fish were plentiful, they would eat algae and seaweed off the corals, which appeared to leave them more resistant to the bacterium <i>Vibrio coralliilyticus</i> , a bacterium associated with bleaching. The researchers suggested the algae, like warming temperatures, might render the corals' chemical defenses less effective, and the fish were protecting the coral by removing the algae.	Fisheries off the coast of Fiji are protecting coral reefs from the effects of global warming, according to a study in the journal Science.
Sacoolas, who has immunity as a diplomat's wife, was involved in a traffic collision ... Prime Minister Johnson was questioned about the case while speaking to the press at a hospital in Watford. He said, "I hope that Anne Sacoolas will come back ... if we can't resolve it then of course I will be raising it myself personally with the White House."	Boris Johnson has said he will raise the issue of US diplomat Anne Sacoolas' diplomatic immunity with the White House.
According to Syrian state media, government forces began deploying into previously SDF controlled territory yesterday. ... On October 6, US President Donald Trump and Turkish President Recep Tayyip Erdoan spoke on the phone. Then both nations issued statements speaking of an imminent incursion into northeast Syria On Wednesday, Turkey began a military offensive with airstrikes followed by a ground invasion.	Syrian government forces have entered territory held by the US-backed Syrian Democratic Forces (SDF) in response to Turkey's incursion into the region.

- BART는 요약에서 이전 SOTA 대비 6점 향상이라는 큰 개선을 보였다. 연구진은 WikiNews 기사로 정성 평가를 진행했으며, 첫 문장을 삭제해 요약을 더 어렵게 만들었다.
- 결과 요약은 유창하고 문법적으로 적절했으며, 문구 복제는 거의 없고 사실적 정확성과 추론 능력을 보였다. 이는 BART의 사전학습이 자연어 이해와 생성 능력을 잘 결합했음을 보여준다.
- 다만 첫 번째 예시에서 물고기가 지구 온난화로부터 암초를 보호한다는 추론은 성공적이지만, 해당 연구가 Science에 발표되었다는 주장은 원문에서 근거를 찾을 수 없었다.
→ *Hallucination* 리스크 존재

5. Conclusion

| 결론 및 주요 요약은?

- BART는 기존 MLM보다 더 다양한 noise를 적용하는 denoising 방식을 통해 학습된다.
- 이 모델은 입력 시퀀스를 받아 출력 시퀀스를 생성하는 Encoder-Decoder 구조의 sequence-to-sequence 모델이다.
- 따라서 언어 이해(예: 분류)뿐만 아니라 요약, 번역, 질문응답 같은 언어 생성 태스크에도 모두 강력한 성능을 보이는 범용 seq2seq 모델로 활용될 수 있다.
- 다만, hallucination 문제를 해결하기 위해서는 더 다양한 corruption 기법과 task에 특화된 사전학습이 필요하다.