

BASE_2주차_이론

1. LSTM 기반 Seq2Seq 모델에서 디코딩 할 때 사용하는 Beam Search 동작 방식에 대해서 설명

디코더가 문장을 만들 때 매 토큰마다 확률이 가장 높은 단어를 하나만 고르면 오류가 연쇄적으로 커진다. Beam Search는 이를 막기 위해 “확률이 높은 경로 k개”를 동시에 유지한다. 시작 기호 후에 상위 k개의 단어를 뽑고, 다음 스텝마다 각 경로를 다시 확장해 전체 후보 중 점수 상위 k개만 남긴다. 종료 토큰이 나오면 그 경로는 완성으로 저장하고, 모든 경로가 끝나거나 최대 길이에 도달하면 중단한다. 마지막에 점수가 가장 높은 완성 문장을 결과로 선택한다. 이렇게 하면 계산량은 적당히 억제하면서도 한 가지 경로만 따를 때보다 훨씬 자연스러운 번역/요약을 얻을 수 있다.

2. Seq2Seq (LSTM) 기본형이 가진 문제와 Attention이 해결한 방법

Seq2Seq (LSTM) 기본형이 가진 문제

1. 정보 압축 문제

- 인코더는 긴 문장을 다 읽은 뒤 벡터 하나만 디코더에 줌.
- 그래서 벡터 하나에 모든 내용을 옥여넣으면 → 긴 문장의 앞부분 정보가 잘 날아감.

2. 어디를 봐야 할지 모름

- 디코더는 “지금 번역할 단어가 입력 문장의 어느 위치랑 관련 있는지” 알 길이 X.
- 그래서 단어 순서가 많이 바뀌는 번역에서 실수가 잦음.

Attention이 해결한 방법

핵심 아이디어	한 줄 설명
필요할 때만 꺼내 보기	디코더가 매 순간 인코더의 모든 단어 벡터를 훑어보고, 필요한 부분에 가중치를 줌
정보 손실 ↓	고정 벡터 1개 대신 가변 컨텍스트 사용 → 긴 문장도 앞·뒤 내용을 다 참고할 수 있음

핵심 아이디어	한 줄 설명
정렬(Alignment) 제공	가중치를 보면 “지금 생성 중인 단어가 입력 문장의 어디를 보고 있는지”가 드러나 번역 품질이 상승함

<비유>

- 기존 모델: 책 내용을 전부 외운 친구가 요약 한 장을 들려주고 떠나는 상황.
- Attention 모델: 줄곧 옆에 앉아 있다가, 필요할 때 책 페이지를 바로 보여주는 친구.

결과적으로, Attention을 단 Seq2Seq는 긴 문장 번역이나 요약에서 오류가 크게 줄고 점수가 훨씬 높아짐.