

# 5주차-Attention

- before transformer
  - RNN
    - 시퀀스 데이터 처리
    - 한계: 장기 의존성, 기울기 소실 등
  - LSTM
    - forget, input, output 게이트 활용
    - 장기 의존성 문제 개선!
    - but 구조 복잡, 느림
  - GRU
    - reset, update 게이트 활용
    - LSTM보다 단순, 연산량 감소
  - Seq2Seq
    - encoder-decoder 구조, RNN 기반 구현
    - with attention
      - 디코더는 인코더의 모든 output을 참고
      - attention? → 연관 있는 부분에 집중
        - dot-product attention
          - attention score 구하기
          - softmax로 attention 분포 구하기
          - 가중치x은닉 상태 → attention value 구하기
          - concatenate

---

## transformer

- positional encoding

- 토큰의 위치 고려. 순서 정보 포함!
  - !! self attention
    - 자기 자신에게 attention 적용
  - scaled dot product
    - 행렬 연산
    - 루트 d\_k로 안정성 향상
  - !! multi-head attention
    - attention을 병렬적으로 나눠서 진행(각 head에 대해)
    - → 다양한 task 수행 가능
  - !! masked multi-head attention
    - 미래 정보를 mask한 후 softmax→0이 되도록(고려X)
  - feed forward networks
    - 벡터 크기 보존
- 

- transformer
  - 양방향 구조
  - 단방향 구조
- transformer 사용 모델
  - GPT: 문장 수준 이해는 잘 못했음
    - decoder만을 사용
    - label이 없어도 학습하기 위해
      - unsupervised pre-training
        - 장기적인 학습 ok
      - supervised fine-tuning
  - BERT

- transformer의 인코더만을 사용
  - unsupervised pre-training
    - 랜덤하게 마스킹→파인튜닝과 차이 생김
    - n%만 마스킹하는 식으로~
  - supervised fine-tuning: end-to-end
    - 지피티와 다르게 structure 차이X
- GPT+BERT → BART: input에 노이즈(텍스트에 마스킹) 추가하고 그걸 변형. 다양하게 학습
  - BART와 기존 transformer 차이점
    - 인코더 학습 시 텍스트에 마스킹하는 것 외에도 다양하게 노이즈 줌
    - ex. 아예 토큰 삭제 / 문장 내 단어 섞기 / 문서 회전(순서는 안섞고 단어만 앞에 배치) / 텍스트 채우기(뭉음으로 마스킹함) etc...
    - BART는 인코더의 마지막 레이어(좋은 벡터 생성), 디코더의 각 계층에서만 attention 수행