

BASE_9주차_BART&TCN

1. BART 개요

- **정의:** Denoising Autoencoder 기반의 Seq2Seq 모델.
 - **핵심 아이디어:** 입력을 손상(Corruption)시키고 원래 문장을 복원하도록 학습.
 - **특징:** BERT(이해) + GPT(생성)의 장점을 모두 결합.
-

2. 아키텍처

- **구조:** Transformer 기반 Encoder-Decoder.
 - **차이점:**
 1. Encoder-Decoder 사이에 **Cross Attention** 존재.
 2. Word prediction 직전 추가 Feed-forward layer 없음.
 - **모델 크기:** Base (6/6), Large (12/12).
-

3. Pre-training 목표

- 다양한 Noise 방식으로 입력 손상 후 복원:
 - **Token Masking**
 - **Token Deletion**
 - **Text Infilling** (가변 길이 마스킹)
 - **Sentence Shuffling**
 - **Document Rotation**
 - **장점:** 문맥 구조, 위치, 유연한 생성 능력 모두 학습.
-

4. Fine-tuning 방식

- **Sequence Classification:** 문장 단위 분류 (BERT의 [CLS]와 유사).

- **Token Classification:** 토큰 단위 역할 분류 (예: QA span).
 - **Sequence Generation:** 요약·생성 (Decoder가 단어 단위로 출력).
 - **Machine Translation:** Pre-trained Decoder 재활용, 새로운 Encoder 학습.
-

5. Benchmark & 실험 결과

- **Benchmark:** SQuAD, MNLI, ELI5, XSum, ConvAI2, CNN/DM.
 - **결과:**
 - Token Masking, Text Infilling이 효과적.
 - Generation Task(XSum, CNN/DM)에서 기존 모델 대비 큰 폭 성능 향상.
 - Translation Task에서 Tuned BART가 최고 성능.
 - **일관성:** 다양한 Task에서 BART가 가장 안정적이고 강력한 성능을 보임.
-

6. 한계와 분석

- **강점:** Abstractive Task(요약·생성)에 특히 강함.
 - **한계:** Hallucination(사실과 다른 정보 생성) 위험 존재.
 - **필요한 점:** 더 다양한 corruption 방식과 Task 맞춤형 사전학습 필요.
-

7. 결론

- **BART = 범용 Seq2Seq 모델:** 언어 이해(분류) + 생성(요약, 번역, QA) 모두 잘 수행.
 - **혁신 포인트:**
 - Denoising autoencoder
 - 다양한 pretraining objective
 - Encoder-Decoder 결합 구조
 - **미래 방향:** Hallucination 억제 + Task-specific 사전학습.
-
-

1. TCN 개요

- **정의:** Dilated causal convolution 기반의 시퀀스 모델.
 - **핵심 아이디어:** CNN 구조로도 장기 의존성을 안정적으로 학습 가능.
 - **특징:** 단순 구조 + 병렬 연산 가능 + 긴 기억 유지.
-

2. 아키텍처

- **구조:** 1D Convolution 기반 네트워크.
 - **핵심 구성:**
 - *Causal Convolution*: 미래 정보 누출 방지.
 - *Exponential Dilation*: 지수적으로 receptive field 확장.
 - *Residual Connection*: 깊은 네트워크 안정적 학습.
 - **장점:** 순차적 계산이 필요 없어 **RNN 대비 병렬화 가능**.
-

3. 학습 셋업

- **비교 대상:** TCN vs LSTM, GRU, RNN.
 - **조건:** 파라미터 수 유사하게 맞춤 → 공정 비교.
 - **최적화:** Adam (lr=0.002), gradient clipping, dropout.
 - **공정성 확보:** gating, skip-connection 등 추가 트릭 사용 안 함.
-

4. Synthetic Task 결과

- **Adding Problem:** TCN $\approx$ 0 손실, GRU 준수, LSTM/RNN 실패.
- **Sequential & Permuted MNIST:**
 - TCN 정확도 97~99% (SOTA 수준).
 - LSTM/GRU 85~96%, RNN 25%.
- **Copy Memory:**

- TCN → T=1000에서도 정확 복사.
- LSTM/GRU → 대부분 "0"만 출력.

결론: TCN은 장기 기억 안정적 유지 + 빠른 수렴.

5. Real-world Task 결과

- **Music Modeling:** JSB, Nottingham → TCN이 낮은 loss.
- **Language Modeling:**
 - Word-level PTB: 예외적으로 LSTM이 더 낮은 perplexity.
 - 대규모 데이터(WikiText-103, LAMBADA): TCN이 훨씬 우위.
 - Char-level PTB, text8: TCN이 낮은 BPC 기록.

결론: 실제 데이터셋에서도 대부분 TCN이 RNN보다 우수.

6. 한계와 분석

- **강점:** 단순 구조, 안정성, 장기 의존성 처리.
 - **한계:** LSTM 대비 최적화 연구 부족 → 일부 작은 데이터셋에서 약세.
 - **필요한 점:** 더 다양한 최적화 연구 및 Task-specific 튜닝.
-

7. 결론

- **TCN = 단순·강력한 시퀀스 모델**
 - 장점: 긴 의존성 학습, 빠른 수렴, 병렬 처리.
 - 한계: LSTM 대비 community 최적화 부족.
- **혁신 포인트:**
 - Dilated causal convolution
 - Residual connection
 - 병렬 학습 가능 구조
- **미래 방향:** 최적화 기법 발전 시, RNN 대체할 수 있는 새로운 표준 가능.