

BASE_학기 1주차_GPT-1

모델 등장 전

Word2Vec

- 대규모 어휘와 데이터가 필요한 과제에서 더 효율적인 분산 표현을 위해 등장
- 기존 NNLM의 비싼 은닉층 연산을 단순화
- 벡터 연산으로 단어 간 관계를 설명

Seq2Seq + Attention

- Word2Vec은 단어 표현까지만 제공 → Seq2Seq 등장
- Seq2Seq: Encoder RNN이 입력 문장을 읽어 고정 벡터로 요약, Decoder RNN이 해당 벡터를 토대로 번역 생성
- 기존 RNN 기반 번역은 긴 문장에서 정보 손실 심각 → Attention 등장
- Attention: 디코더가 단어를 생성할 때 입력 문장의 모든 단어를 다시 보고 가중치를 줌

Transformer

- Self-Attention : 각 단어가 문장 내 모든 단어와 직접 관계를 맺음
- Multi-Head Attention : 서로 다른 의미적 관계를 병렬로 학습
- Encoder-Decoder 구조
- Positional Encoding : 순서 정보가 사라지지 않도록 위치 인코딩 추가

ELMo

- 대규모 텍스트로 사전학습된 양방향 LSTM 언어모델(BiLM) 사용

핵심 아이디어와 모델

Generative


- 언어모델 objective를 통해 auto-regressive하게 다음 단어를 반복적으로 분류하여 시퀀스를 생성하므로, 현대적 의미에서 생성형 모델로 분류

Pre-trained

- 준지도학습 (semi-supervised learning)
- 지식 전이(transfer)
- Task-agnostic 모델

Transformer

- **Decoder only**
- **Framework**
 - Unsupervised pre-training
 - 컨텍스트 벡터: 청크를 임베딩 + 위치 인코딩한 입력 벡터
 - hidden state 구성
 - Masked Multi-Head Attention: 하나의 attention을 여러 개의 head로 분할
- **Attention**
- **Add+Norm , FFN**
- **supervised fine-tuning: 미세 조정 단계에서 추가된 파라미터 : 구분자 임베딩**



Experiment, 한계

Natural Language Inference

- 한 쌍의 문장에 대해 '함의, 모순, 중립' 중 하나의 관계를 판단하는 task
- 사용한 모든 dataset에서 SOTA

Question answering & commonsense reasoning

- RACE dataset, Story Cloze Test를 사용
- 모델이 긴 맥락을 잘 다룬다는 걸 알 수 있었음

Semantic similarity

- 두 문장이 의미적으로 동일한지 예측하는 task
- 세 데이터셋 중 두 개에서 SOTA.

Classification

- CoLA (문장이 문법적으로 맞는지) & SST-2 (이진분류) dataset
- GLUE 벤치마크 사용. CoLA, GLUE는 SOTA, SST-2도 좋은 성능을 보임.

후속 연구

GPT-2

- 파라미터나 구조 변경 없이도 zero-shot 환경에서 language model이 잘 수행할 수 있다는 걸 보여줌

GPT-3

- in-context learning 성능의 발전