

BART

배경지식 (BERT)

항목	GPT	BERT
아키텍처	Decoder-only Transformer (causal self-attention)	Encoder-only Transformer (bidirectional self-attention)
방향성	단방향(좌→우)	양방향(좌↔우 동시)
사전학습 목표	Autoregressive LM : 다음 토큰 예측 $P(w_t w_{<t})P(w_t w_{<t})$	MLM + NSP : 가린 토큰 복원 + 문장 연결성 판단
LM 형태	생성형 LM	이해형 LM(마스크 복원)
입력 포맷(대표)	프롬프트(문맥) → 이어서 생성	[CLS] 문장(들) [SEP]
출력 형태	새 토큰 생성 (길이 가변)	입력 길이와 동일한 hidden states ; 마스크 위치만 예측
주요 강점	자유 텍스트 생성 , 대화, 창작, 생성형 QA	문맥 이해 , 분류, NLI, NER, 추출형 QA
QA 방식	생성형(답을 문장으로 생성)	추출형(컨텍스트 span 시작/끝 위치 분류)
파인튜닝 방식	지시학습/대화튜닝(SFT), RLHF, 어댑터/LoRA 등	태스크 헤드 추가(분류/토큰분류/span-head), 미세조정
마스킹/노이즈	없음(자기회귀 마스크만)	15% 토큰 선택 → 80% [MASK], 10% 랜덤치환, 10% 원형 유지
장기 문맥	스케일업으로 강함(긴 컨텍스트 창)	문맥 이해 강함이나 생성은 불가(기본 구조상)
계산 복잡도	$O(n^2)$ attention, 생성은 토큰별 순차 추론	$O(n^2)$ attention, 전 토큰 병렬 인코딩
전이(Transfer)	범용 생성 태스크로 광범위 전이	이해 중심 다운스트림에 강한 전이
대표 태스크	요약/번역(생성형), 스토리·코드 생성, 에이전트	분류, NLI, NER, 문장 유사도, SQuAD(추출형)
장점 요약	생성 최강, 프롬프트 유연성, 범용성	이해 최강, 적은 파라미터로도 높은 정확도
한계 요약	비용 큼, 해석성/사실성 이슈	생성 불가(기본형), NSP 효용 논쟁

• Shallow vs Deep

구분	Shallow Bidirectional	Deep Bidirectional
구조	L2R, R2L 두 개 모델 학습 후 출력만 합침	한 모델 안에서 self-attention으로 앞뒤 문맥 동시 학습
상호작용 시점	출력 단계에서만 결합	**각 층(hidden state)**에서 양방향 통합
대표 예시	BiRNN, BiLSTM, ELMo(부분적)	BERT, RoBERTa
장점	구현 단순, 직관적	문맥 이해 훨씬 강력, 표현력↑
단점	앞뒤 정보가 깊게 섞이지 않음	연산량↑, 사전학습 필요량 큼

• Feature-based vs End-to-End Fine-tuning

구분	Feature-based (ELMo, Word2Vec, GloVe 등)	End-to-End Fine-tuning (BERT 이후)
사전학습 모델 활용 방식	임베딩/feature extractor 출력만 사용	사전학습된 모델 전체를 포함해 학습
전이 방법	사전학습 모델은 freeze (고정), downstream 모델만 새로 학습	사전학습 모델 + 새로 붙인 task head를 동시에 업데이트
추가 구성	기존 단어 임베딩(Word2Vec/GloVe) + 사전학습 contextual feature (ELMo) → downstream 모델(LSTM, CRF 등)	BERT 본체 위에 작은 classifier head(Linear/Softmax/CRF 등)만 추가
Task Head 역할	downstream task 전용 모델 자체가 head 역할 (예: BiLSTM+CRF)	BERT 위에 단순한 Linear/Softmax head 추가
학습 안정성	상대적으로 안정적 (사전학습 모델 파라미터는 고정)	대규모 파라미터 업데이트 필요 → 더 불안정, 하지만 성능 높음
파라미터 업데이트	오직 downstream 모델 파라미터만 학습	BERT의 encoder 전체 + task head 모두 학습
필요 데이터량	비교적 많은 라벨 데이터 필요 (feature만 사용하므로)	적은 라벨 데이터로도 높은 성능 (사전학습 모델이 강력한 표현 제공)
대표 예시	Word2Vec, GloVe, ELMo	BERT, RoBERTa, GPT 파인튜닝
핵심 개념 요약	"사전학습 피처를 가져다 쓴다"	"사전학습 모델 전체를 태스크에 맞게 미세조정한다"

BERT의 의의

BERT의 혁신은 **Transformer의 self-attention**을 채택하면서 가능해졌다. BERT는 self-attention을 통해 각 층에서 앞뒤 문맥을 동시에 깊게 반영하는 **deep bidirectional** 표현을 만들어낼 수 있었고, 이런 안정적인 구조 덕분에 사전학습된 모델 전체를 태스크에

맞게 **end-to-end fine-tuning**으로 조정할 수 있었다. 이는 feature-based 접근에서 벗어나 다양한 다운스트림 작업에 강력한 전이를 가능케 했다.

즉, **BERT**와 **GPT** 둘 다 **transformer**를 아키텍처에 추가하여 이전보다 동적인 구조를 구현하였고 이는 **사전학습-미세조정** 구조에 혁신을 가져왔다.

GPT는 생성을 목표로 하였기에 **LM**을 사전학습 목표로 설정하여 **Decoder-only** 구조를 채택했고,

BERT는 문맥 이해를 목표로 하였기에 **MLM, NSP**를 사전학습 목표로 설정하여 **Encoder-only** 구조를 채택했다는 차이점이 있을 뿐 **두 모델이 가지는 의미는 transformer의 채택에 있다.**

BART

Denoising Autoencoder (DAE)

- **아이디어:** 데이터를 일부러 손상시키고, 다시 원래 상태로 복원하도록 학습
- **구조:**
 - **Encoder:** 손상된 입력을 압축된 표현으로 변환
 - **Decoder:** 그 표현을 바탕으로 원래 입력을 복원
- **노이즈 예시:**
 - 이미지 → 일부 픽셀 지우기, 잡음 추가
 - 텍스트 → 단어 마스킹, 삭제, 순서 섞기
- **효과:**
 - 단순 복사 방지
 - 데이터의 본질적인 패턴(의미) 학습
 - 노이즈 제거, 더 일반적인 특징 추출
- **비고:**
 - 여기서 쓰인 DAE는 투영/복원 개념의 AE나 확률분포를 학습하는 VAE와는 개념이 사뭇 다름

Pre-Training

- **Token Masking:** 토큰 → [MASK] → 원래 단어 복원
- **Token Deletion:** 토큰 삭제 → 삭제된 단어 복원
- **Sentence Permutation:** 문장 순서 섞기 → 원래 순서 복원
- **Document Rotation:** 문서 임의 지점 회전 → 올바른 시작점 복원
- **Text Infilling:** 연속 토큰 마스킹 → 가변 길이 구간 복원

-
- **입력:** 손상된 문장
 - **출력:** 원래 문장
 - **구조:** Transformer Encoder-Decoder
 - **학습 방식:** Denoising Autoencoder
 - **목적:** 자기지도 표현 학습 → downstream task 전이

Fine-Tuning

Task	입력/출력	Decoder 입력	Head / Output 방식
Sequence Classification	문장 → 라벨	Encoder와 동일 문장을 target처럼 넣음 (대표 벡터 뽑기)	마지막 hidden state → Classifier head
Token Classification	문장(+질문) → 토큰 별 라벨	없음 (Encoder 출력만 사용)	각 토큰 hidden state → Classifier head
Sequence Generation	문서 → 요약/번역된 문장	<s> + target 시퀀스 (teacher forcing)	Decoder autoregressive 생성
Machine Translation	외국어 문장 → 번역된 문장	<s> + target 시퀀스	Decoder autoregressive 생성

BART의 의의

BART의 핵심은 **Denoising Autoencoder(DAE)** 개념을 Transformer 기반 **Encoder-Decoder** 구조에 접목했다는 데 있다.

BERT가 **MLM**으로 문맥 이해를, GPT가 **LM**으로 생성을 사전학습했다면, BART는 다양한 방식으로 입력을 손상시킨 뒤 원래 문장을 복원하는 **복원 학습(denoising)**을 사전학습 목표로 삼았다.

이로써 BART는 **양방향 인코더(BERT의 강점)**와 **자기회귀 디코더(GPT의 강점)**를 결합하여, 분류·QA 같은 **이해 태스크**와 요약·번역 같은 **생성 태스크** 모두에 효과적으로 적용될 수 있는 범용성을 갖추게 되었다.

즉, **BART의 의의**는 DAE 기반 사전학습을 통해 Transformer seq2seq 구조를 범용 사전 학습 모델로 끌어올렸다는 데 있다.