



Attention + Transformer

주차 5주차

Transformer 이전

1) RNN

- **Hidden State 구조**
 - 이전 타임스텝의 정보를 현재 타임스텝으로 전달
- **장기 의존성 문제**
 - 모델이 멀리 있는 단어 간의 관계를 학습하지 못하는 상황

2) LSTM

- **Cell State 추가**
 - 중요한 정보는 '직접' 경로를 통해 손실 없이 유지됨
- **Forget, Input, Output Gates**
 - Forget : 과거의 정보를 버릴지 유지할지 결정하는 게이트
 - Input : 새로운 정보 추가 여부를 결정하는 게이트
 - Output : 다음 Hidden State를 생성하는 게이트

3) GRU

- **Cell State 삭제**
 - Cell State 대신 Hidden State 하나만 사용
- **Reset, Update Gates**
 - Reset : 과거 정보를 삭제할지 결정

4) Seq2Seq

- **Encoder-Decoder**
 - Encoder : 입력 시퀀스를 압축된 벡터로 변환
 - Decoder : 이 벡터를 기반으로 출력 시퀀스를 생성
- **Context Vector**

- Update : LSTM의 Forget Gate + Input Gate 역할, 과거 정보를 얼마나 유지할지 결정

- Encoder에서 압축된 벡터
- 하나의 Context Vector에 소스 문장의 정보를 압축

Attention

해당 시점에서 예측해야 할 단어와 연관이 있는 입력 단어 부분을 좀 더 집중(attention)해서 보는 것

Attention Value

- Query에 대해 모든 Key 값을 한 번씩 살펴본 뒤, 가중치를 부여

Dot-Product Attention

1. Attention Score 구하기
2. softmax 함수를 통해 Attention 분포 구하기
3. 각 인코더의 어텐션 가중치와 은닉 상태를 가중합하여 Attention Value 구하기
4. Attention Value와 디코더의 t 시점의 은닉 상태 연결하기
5. 출력층 연산의 입력이 되는 S_t 를 계산

Transformer

Input into encoder

- 각 입력 시퀀스를 학습에 사용되는 벡터로 임베딩하는 embedding layer 구축
- 임베딩 행렬 W에서 look-up을 수행하여 해당하는 벡터를 반환
→ 순서 정보가 포함 되지 않음

Encoder

Positional Encoding

- 각 토큰의 위치에 고유한 값을 부여
- 토큰 간의 거리에 대한 정보를 일정하게 반영
- 입력 길이가 매우 길어져도 충분히 반영할 수 있는 일반화 능력

Self Attention

- Attention과 동일한 원리이나, 자기 자신에게 Attention을 적용하는 것
- Self-Attention은 문장 스스로 attention을 적용했기 때문에 Query, Key, Value의 기원은 같음

Scaled Dot-Product Attention

- 각 차원에 대한 영향력이 과도하게 커지는 것을 방지하고 학습의 안전성을 향상

Multi-Head Attention

- 각 head들에 대해서 self-attention 연산 → 각 head의 output vector는 concatenate 하게 됨
- 이후, weighted vector를 곱해주어 입력 sequence의 vector와 동일한 크기의 vector를 결과로 출력

Decoder

Masked Multi-Head Attention

- Transformer는 문장 전체를 한 번에 입력 받는 방식이기 때문에 미래의 정보를 확인 가능
- 문장을 출력하는 디코더에서는 이러한 문제가 발생해서는 안됨
- 따라서 미래 정보에 해당하는 attention score를 $-\infty$ 로 치환한 후 softmax를 취했을 때 값이 0이 되게 하여 미래 정보를 고려하지 않게 함

Position-wise Feed-Forward Networks

- ReLU 활성화 함수와 두 번의 선형 변환을 적용하는 레이어

Residual Connection

- Multi-head Attention의 입력과 출력을 더함
- 그래디언트 소실 문제를 완화하고 학습을 용이하게 함

Layer Normalization

- Residual Connection을 수행한 결과를 정규화해줌
- 시퀀스의 길이가 일정하지 않을 때는 Batch Normalization을 할 수 없어 Layer Normalization을 적용해야 함

GPT

- Decoder only
- 다음 단어 예측
- 입력 문장을 순서대로 읽으면서 미래 단어는 보지 못하도록 Masked Multi-Head Attention 적용

BERT

- Encoder only
- MLM: 일부 단어를 [MASK]로 가리고 양방향 문맥을 활용해 예측
- NSP: 두 문장이 이어지는 문장인지 분류
- 양방향으로 문맥을 동시에 고려 → 문장의 의미 파악에 매우 강력

BART

- GPT + BERT
- Encoder는 BERT처럼 양방향 문맥 이해
- Decoder는 GPT처럼 autoregressive 생성

- 입력 문장을 의도적으로 망가뜨린 뒤(토큰 삭제, 마스킹, 순서 섞기 등), 원래 문장을 복원하는 방식으로 학습