

1. 서론: NLP 패러다임의 전환과 GPT의 등장

최근 몇 년간 딥러닝 기술은 언어 모델링 분야에서 큰 성공을 거둬. GPT 시리즈는 하나의 모델이 다양한 언어 작업을 수행하는 새로운 패러다임을 제시하며 이 분야의 중요한 전환점을 만들어 냄. 본 보고서는 GPT-1부터 GPT-3까지의 주요 논문을 분석하며, 언어 모델의 발전 과정과 각 모델이 기여한 핵심적인 혁신을 정리함.

2. GPT 시리즈의 핵심 기여와 발전 과정

GPT 모델의 발전은 Pre-training과 Scaling이라는 두 가지 핵심 전략을 중심으로 진행됨.

2.1. GPT-1: Pre-training & Fine-tuning

GPT-1은 **Improving Language Understanding by Generative Pre-training** 논문을 통해 언어 모델의 새로운 학습 패러다임을 구축했음.

- **핵심 아이디어:** 대규모 비지도 데이터로 언어 모델을 미리 학습시킨 후, 특정 작업에 맞춰 지도 학습을 통해 모델을 Fine-tuning하는 2단계 학습 방식을 제시함.
- **모델 구조:** 문장의 다음 단어를 예측하는 데 특화된 **Transformer decoder**를 사용했음. 이 구조는 이후 모든 GPT 모델의 근간이 됨.
- **의의:** 이 방법은 각 작업마다 모델을 처음부터 설계하고 학습해야 했던 기존의 한계를 극복하며, 여러 NLP 벤치마크에서 뛰어난 성능을 입증했음.

2.2. GPT-2: Zero-shot learning

GPT-2는 **Language Models are Unsupervised Multitask Learners** 논문에서 GPT-1의 학습 전략을 확장하여 모델 규모와 데이터의 양을 극적으로 늘렸음.

- **핵심 아이디어:** 모델의 크기와 데이터의 양을 충분히 늘리면, 모델이 특정 작업에 대한 지도 데이터 없이도 다양한 작업을 수행할 수 있는 능력, 즉 **Zero-shot 학습** 능력이 발현된다는 것을 발견했음.
- **Emergent Property:** GPT-2의 이러한 제로샷 능력은 모델 규모의 확장으로 인해 나타난 예상치 못한 새로운 능력, 즉 Emergent Property로 간주될 수 있음.
- **의의:** 이 논문은 언어 모델이 단순히 언어의 패턴을 학습하는 것을 넘어, 여러 작업을 수행하는 '**학습하는 방법**' 자체를 습득한다는 것을 시사하며, 언어 모델의 잠재력을 재정의했음.

2.3. GPT-3: Parameter scaling & Few-shot learning

GPT-3는 **Language Models are Few-Shot Learners** 논문을 통해 GPT-2의 스케일링 가설을 극한까지 밀어붙였음.

- **핵심 아이디어:** 1,750억 개에 달하는 방대한 파라미터를 가진 GPT-3는 몇 가지 예시만으로도 새로운 작업을 학습하는 **Few-shot 학습** 능력을 보여주었음.
- **In-context learning:** 미세 조정 없이, 프롬프트에 제공된 소수의 예시를 보고 모델이 가중치를

변경하지 않은 채로 작업을 수행함.

- **의의:** 퓨샷 학습은 기존의 미세 조정 방식에 필적하거나 때로는 능가하는 성능을 보이며, 대규모 언어 모델이 새로운 작업을 배우는 가장 효율적인 방법으로 자리매김했음.

3. 결론

GPT 시리즈는

대규모 사전 학습과 스케일링을 통해 언어 모델의 성능이 선형적으로 개선되는 것을 넘어, **제로샷, 퓨샷**과 같은 새로운 능력이 발현된다는 것을 증명함. GPT의 이러한 발전은 언어 모델이 단순한 텍스트 생성기를 넘어, 마치 인간처럼 다양한 맥락을 이해하고 적응하는 범용적인 AI로 나아갈 수 있다는 가능성을 보여줌.

GPT 시리즈가 제시한 새로운 패러다임은 이후 BERT, T5, LLaMA, Claude와 같은 수많은 LLM의 개발에 영향을 주었으며, 앞으로도 인공지능 연구의 중요한 이정표가 될 것임.

Question list

- Q. GPT는 Transformer의 decoder 부분만 이어 붙여 Autoregressive 하게 학습
-> good at generating, but understaidng은 incoder에서 학습할텐데?
-> 그럼 encoder도 이어 붙이면 성능이 더 좋아지는 것 아닌가?
- A. Encoder만 사용하는 모델 -> BERT
encoder-decoder 전부 사용하는 모델 -> BART
BART는 다음주 주제니까 미리 공부해서 다시 또 질문하겠습니다~!
- Q. GPT-1 논문에서 zero-shot learning 언급을 시작으로,
GPT-2에서는 Emergent property처럼 zero-shot을 강조하고 BERT까지 언급.
-> zero-shot learning 가능성을 입증했다며, NLU 마저 SOTA라 말했는데,
-> 정말 BERT보다 NLU task를 잘하는가?
- A. GPT-2 논문은 zero-shot 능력의 가능성을 입증하며 NLU에서 SOTA를 달성했다고 주장했지만,
이는 특정 벤치마크에 한정된 결과였으며, fine-tunning 된 BERT 모델의 NLU 성능을 전반적으로 뛰어넘지는 못했음.
- Q. GPT-3에서 prompt로 few-shot learning을 하는데,
-> 이것이 진정한 의미의 '학습'이라고 할 수 있는지,
-> 아니면 단순히 사전 학습된 지식 중 가장 적절한 패턴을 '인식',
-> 즉 'few-shot 추론'하는 것이 아닌지?
- A. Prompt의 task 성격을 zero/one/few-shot으로 파악하는 방식.
prompt를 이해해서 task를 추론한다고 이해했음.