

0. 서론

2019년 페이스북 AI에서 발표한 BART 논문을 분석함. BART는 denoising autoencoder의 개념을 기반으로, 임의로 손상된 텍스트를 원본 텍스트로 복원하도록 훈련하는 새로운 사전 학습 모델임. 이 모델은 양방향 인코더와 단방향 디코더를 결합한 seq2seq 아키텍처를 사용함. 덕분에 **BERT**처럼 문맥을 깊이 이해하는 능력과 **GPT**처럼 자연스러운 텍스트를 생성하는 능력을 동시에 갖추게 되었음.

1. 기존 모델들의 한계

기존의 사전 학습 모델들은 특정 작업에 특화되어 있어서, 넓은 범위에서 유연하게 사용하기 어려운 한계가 있었음.

- **BERT의 한계:** BERT는 마스크 언어 모델(MLM)을 통해 문장 양쪽의 문맥을 깊이 이해하는 데는 탁월했지만, 입력과 전혀 다른 새로운 문장을 생성하는 데는 취약했음.
- **GPT의 한계:** GPT는 자기회귀 디코더를 사용해 텍스트 생성 능력은 뛰어났지만, 이전 단어들만 보고 다음 단어를 예측하는 단방향 방식으로 학습했기에, 문장 전체의 양방향 문맥을 이해해야 하는 문제에는 어려움이 있었음.

BART는 이러한 문제점들을 해결하기 위해 인코더-디코더 구조를 채택한 것임.

2. 핵심 방법론: 텍스트 손상과 복원

BART의 가장 큰 특징은 원본 텍스트에 다양한 형태의 '노이즈(noise)'를 추가하여 손상된 문서를 만들고, 이를 원래의 문서로 복원하도록 학습하는 것임. 이는 단순히 빈칸을 채우는 것을 넘어, 모델에게 훨씬 더 복잡하고 광범위한 언어 능력을 요구함. 논문에서 실험한 훈련 방법론들은 다음과 같음.

- **토큰 마스킹 (Token Masking):** BERT와 유사하게, 문장 내 임의의 토큰을 [MASK]로 대체함.
- **토큰 삭제 (Token Deletion):** 임의의 토큰을 아예 삭제하여 모델이 어떤 위치의 단어가 사라졌는지 스스로 파악하도록 함.
- **텍스트 채우기 (Text Infilling):** 연속된 텍스트 스패(span)를 하나의 [MASK] 토큰으로 대체함. 이 덕분에 모델은 누락된 토큰의 개수까지 예측하는 능력을 기르게 됨.
- **문장 순서 섞기 (Sentence Permutation):** 마침표를 기준으로 문장을 나눈 뒤 순서를 무작위로 섞음.
- **문서 회전 (Document Rotation):** 문서 내의 임의 토큰을 선택해 그 토큰이 문서의 시작점이 되도록 순서를 바꿈.

BART는 이 방법론들을 단독으로 사용하거나 조합하여 실험했는데, 특히 **텍스트 채우기**와 **문장 순서 섞기** 조합이 가장 뛰어난 성능을 보였음.

3. 모델 아키텍처 및 파인튜닝

BART는 기본적으로 **표준 트랜스포머 아키텍처**를 사용하며, GPT와 같이 활성화 함수로 GeLU를 사용함. 모델은 기본(Base)과 대규모(Large) 두 가지가 있는데, 각각 인코더와 디코더에 6개, 12개 레이어를 적용함.

BERT의 [CLS] 토큰처럼 BART는 디코더의 마지막 토큰 표현을 활용해 Sequence Classification와 같은 하위 작업을 수행할 수 있음. 또한, **Sequence Generation** 작업에서는 인코더에 입력 문서를 넣고, 디코더가 이를 바탕으로 새로운 텍스트를 생성하게 됨.

4. 실험 결과 및 결론

BART는 다양한 자연어 이해 및 생성 작업에서 뛰어난 성능을 입증했음.

- **자연어 이해(NLU)**: SQuAD와 GLUE 벤치마크에서 **RoBERTa**와 동등한 수준의 성능을 달성하여, 디코더가 문맥 이해 능력을 저해하지 않음을 보여주었음.
- **자연어 생성(NLG)**: summarization과 같은 생성 작업에서 기존 모델들을 압도적으로 능가하며 **SOTA**를 기록했음.

결론적으로, BART는 **BERT의 양방향 문맥 이해 능력**과 **GPT의 자기회귀 생성 능력**을 하나의 seq2seq 프레임워크에 성공적으로 융합한 모델임. 유연한 노이즈 함수를 사용해 다양한 형태의 데이터 손상을 처리하도록 학습함으로써, 기존 모델들의 한계를 극복하고 다양한 NLP 작업에 적용 가능한 범용성을 확보함.

Question list

- Q. Text Infilling(텍스트 채우기) 할 때, 스패의 길이가 Poission dist($\lambda=3$)을 따르게 하는데 왜 하필 $\lambda=3$ 이고, 왜 Poission인가?
- A. 주로 2~4, 가끔 0이나 높은 숫자로 마스킹 된다.
이는 real world스러운 마스킹이라 합당한 분포 선정.
- Q. Text infilling과 sentence permutation을 조합한게 왜 가장 성능이 좋은가?
- A. 부분적인 학습과 전역적인 학습으로 서로 상호보완 할 수 있는 조합.
- Q. BART도 GPT-2,-3처럼 대규모데이터, 대규모 파라미터로 늘리면 성능이 더 좋아지는 것 아니냐
왜 GPT처럼 추후 발전이 되질 않았나
+ 이게 19년도 논문인데 이제는 컴퓨팅 리소스 문제가 없을 것
기술적으로 가능한데 왜 하지 않는가?
- A. GPT는 브랜드화되었지만, BART는 그러지 못했음
+ GPT를 이길 수 없음

0. 서론

TCN은 기존에 RNN이 지배하던 시퀀스 모델링 분야에 새로운 관점을 제시하며, 단순한 Convolutional 기반 아키텍처가 RNN보다 뛰어난 성능을 보일 수 있음을 증명함. 이 모델은 RNN의 단점인 순차적 처리와 불안정한 학습 문제를 해결하며, 다양한 시퀀스 작업에 대한 효율적인 대안을 제시했음.

1. 기존 모델들의 한계

논문이 발표될 당시, 딥러닝 분야에서는 시퀀스 모델링을 RNN과 동일시하는 경향이 강했음. RNN 계열 모델인 LSTM과 GRU는 긴 시퀀스 의존성 학습 능력을 이론적으로 가지고 있었지만, 실제로는 여러 한계에 부딪혔음.

- RNN의 한계:

- **순차적 처리**: RNN은 이전 시점의 출력이 있어야 다음 시점의 계산이 가능하므로, 병렬 처리가 어려워 긴 시퀀스를 처리하는 데 많은 시간이 소요됨.
- **불안정한 학습**: 역전파 과정에서 gradient vanishing 또는 exploding 문제가 발생하기 쉬워, 학습이 불안정해지고 이를 해결하기 위해 복잡한 구조(LSTM, GRU 등)가 필요했음.
- **제한된 기억력**: 이론적으로는 무한한 과거를 기억할 수 있지만, 실제로는 긴 시퀀스에서 먼 과거의 정보를 유지하는 데 어려움을 겪음.

TCN은 이러한 문제점들을 해결하기 위해 병렬 처리가 가능한 합성곱 아키텍처를 채택하고, 긴 시퀀스 의존성을 효과적으로 학습할 수 있는 새로운 구조를 제안함.

2. 핵심 방법론

팽창형 인과적 합성곱 및 잔차 연결 TCN의 가장 큰 특징은 시퀀스 데이터 처리에 적합하도록 설계된 두 가지 핵심 원리임.

- **인과적 합성곱 (Causal Convolutions)**: TCN은 미래의 정보가 현재의 예측에 영향을 미치지 않도록, 오직 과거의 입력값만 사용해 계산함. 이는 일반적인 합성곱과 달리 시퀀스의 시간적 순서를 보장하는 구조임.
- **팽창형 합성곱 (Dilated Convolutions)**: 필터 탭 사이에 고정된 dilation을 두어 계산함으로써, 네트워크의 깊이를 크게 늘리지 않고도 기하급수적으로 넓은 receptive field를 확보함. 논문에서는 팽창 계수를 네트워크 깊이에 따라 지수적으로 증가시켜 먼 과거의 정보를 효과적으로 학습함.

TCN은 이 두 가지 원리를 적용한 1D FCN으로 구성되며, 매우 깊은 네트워크의 학습을 안정화하기 위해 Residual Connections을 추가함. 이는 여러 변환을 거친 출력에 입력값을 직접 더해주는 방식으로, 그래디언트 소실 문제를 완화하고 성능을 향상시킴.

3. 모델 아키텍처 및 특징

TCN은 여러 개의 residual block으로 구성된 아키텍처를 사용하며, 각 블록은 팽창형 인과적 합성곱 층을 포함함. TCN은 RNN과 유사하게 입력 시퀀스에 대해 동일한 길이의 출력 시퀀스를 생성하며, 1D 합

성곱 커널을 슬라이딩하여 임의 길이의 입력도 처리할 수 있음.

TCN의 주요 장점들은 다음과 같음.

- **병렬 처리:** RNN과 달리 모든 컨볼루션 연산을 병렬로 수행할 수 있어, 학습 및 추론 속도가 매우 빠름.
- **안정적인 그래디언트:** 역전파 경로가 시퀀스의 시간적 방향과 다르기 때문에, RNN의 고질적인 문제인 그래디언트 소실/폭발 문제를 회피함.
- **유연한 수용 영역:** 필터 크기, 팽창 계수, 레이어 깊이를 조절하여 모델의 기억 크기를 유연하게 제어할 수 있음.

4. 실험 결과 및 결론

논문은 다양한 시퀀스 벤치마크 작업(Adding problem, MNIST, 음악 모델링, 언어 모델링 등)에서 TCN과 LSTM, GRU의 성능을 비교함.

- **종합 성능:** TCN은 모든 벤치마크에서 LSTM이나 GRU와 같은 정형화된 RNN 모델보다 우수한 성능을 보였음.
- **기억 능력:** 장기 기억을 테스트하는 'Copy memory' 문제에서 TCN은 시퀀스 길이에 관계없이 100%의 정확도를 유지했지만, RNN 모델들은 시퀀스 길이가 길어질수록 성능이 급격히 저하되어 랜덤 추측과 비슷한 수준이 되었음.
- **대규모 데이터셋:** Wikitext-103과 같은 대규모 언어 모델링 데이터셋에서도 하이퍼파라미터 튜닝 없이 LSTM보다 낮은 perplexity(낮을수록 좋음)를 달성함.

결론적으로, TCN은 RNN의 이론적인 장점인 무한 기억이 실제로는 제한적이라는 것을 보여주며, 간단하고 명확한 합성곱 기반 아키텍처가 시퀀스 모델링에서 강력한 대안이 될 수 있음을 증명함. 논문은 시퀀스 모델링의 '자연스러운 시작점'으로 TCN을 고려해야 한다고 제안함.

Question list

- Q. 왜 GPT처럼 추후 발전이 되질 않았나 (BART와 동일질문)
- A. GPT는 브랜드화되었지만, TCN은 그러지 못했음
- + GPT를 이길 수 없음
- (BART와 동일)