

1. 서론: 객체 감지 패러다임의 전환과 YOLO의 등장

YOLO(You Only Look Once)는 객체 감지를 위한 새로운 접근법을 제시한 모델이었음. 기존의 객체 감지 방식은 분류기(classifier)를 재활용하여 감지 작업을 수행하는 복잡한 파이프라인을 가졌음. 반면, YOLO는 객체 감지 문제를 경계 상자(bounding boxes)와 관련된 클래스 확률을 예측하는 회귀(regression) 문제로 재구성하며, 이 모든 과정을 하나의 신경망으로 통합하여 혁신을 가져왔음.

2. YOLOv1의 핵심 기여와 특징

YOLOv1은 "You Only Look Once: Unified, Real-Time Object Detection" 논문을 통해 객체 감지를 회귀 문제로 정의하는 새로운 패러다임을 구축했음.

- 핵심 아이디어: YOLO는 이미지를 단 한 번만 보고, 경계 상자의 좌표와 해당 클래스의 확률을 하나의 신경망으로 직접 예측함. 이 단일 네트워크는 이미지 전체 픽셀을 기반으로 모든 경계 상자를 동시에 예측했음.
- 모델 구조: YOLO는 입력 이미지를 $S \times S$ 크기의 격자(grid)로 나눴음. 만약 객체의 중심이 특정 그리드 셀에 속하면, 그 셀이 해당 객체를 감지하는 역할을 맡았음. 각 그리드 셀은

B 개의 경계 상자과 그에 대한 신뢰도(confidence) 점수를 예측했음. 이 신뢰도 점수는 상자에 객체가 포함되어 있는지에 대한 모델의 확신도를 나타냈음. 또한, 각 그리드 셀은 객체가 존재한다는 조건 하에 각 클래스에 대한 조건부 클래스 확률; $P(\text{Class} | \text{Object})$ 을 예측했음. 경계 상자의 좌표는 그리드 셀을 기준으로 하며, 너비와 높이는 전체 이미지를 기준으로 예측됐음. 최종 예측은 $S \times S \times (B \times 5 + C)$ 텐서로 인코딩됐음. 예를 들어, PASCAL VOC 데이터셋의 경우 $S=7$, $B=2$, $C=20$ 을 사용하여 $7 \times 7 \times 30$ 텐서를 예측했음.

- 의의: 이 통합된 구조는 매우 빨라서, 기본 YOLO 모델은 초당 45 프레임을 처리하며, Fast YOLO는 초당 155 프레임을 처리했음. 이는 YOLO가 실시간 객체 감지 분야의 선두 주자임을 보여줌. 또한, YOLO는 이미지 전체를 보기 때문에 맥락적 정보를 암묵적으로 인코딩하여 배경을 객체로 잘못 예측하는 오류가 적었음. 이 모델은 DPM과 R-CNN을 포함한 다른 감지 방법보다 미술 작품과 같은 새로운 도메인으로 일반화하는 데 더 뛰어난 성능을 보였음.

3. 결론

YOLOv1은 단일 신경망을 사용해 객체 감지를 실시간으로 수행하는 혁신적인 접근법을 제시했음. YOLO는 기존의 분류기 기반 접근 방식과 달리, 탐지 성능에 직접적으로 관련된 손실 함수로 학습되며 전체 모델이 함께 훈련됨. YOLOv1은 객체 감지 기술을 실제 응용 분야에 적용 가능한 수준으로 끌어올리며, 이후 수많은 객체 감지 모델의 개발에 영향을 주었음.

Question list

- Q. You Only Look Once, classification+localization을 더해 단 한 번의 네트워크 통과만으로
-> object detection 작업이 완료된다는 이상적인 end-to-end 모델인데
-> NMS라는 후처리 과정이 필수적으로 필요한 점에서
-> Only Look Once는 아니지않나 생각함 (모순, v10에서야 고쳐진다고 함)
-> 그런 점에서 발제자분은 어떻게 생각하시는지?
- A. 학습과정에서는 look once 학습을 하고 inference때 NMS 하는 것임
training model로써는 YOLO 뜻이 옳다고 생각.
- Q. YOLOv1에서는 box regression을 도입하면서 기존 detection 모델에서 쓰이는
anchor box를 뺐는데 v2에서 다시 anchor box를 도입하여 정확도를 얻고 속도를
잃었다고 한다 (trade-off issue)
-> 이러한 기술적 타협이 YOLO의 가장 큰 강점인 실시간 처리 부분에서 손해본 게 아닌지?
- A. 그럼에도 빠르기에 큰 문제 없고,
v1은 regression에 의의, v2는 현실적 성능 upgrade에 의의.

1. 서론: 이미지 인식 패러다임의 전환과 ViT의 등장

ViT(Vision Transformer)는 자연어 처리(NLP)에서 혁신을 가져온 Transformer 아키텍처를 이미지 인식에 직접 적용한 모델이었음. 기존의 이미지 인식 분야는 픽셀의 지역적 특징을 추출하는 데 특화된 CNN이 지배적인 모델이었음. 하지만 ViT는 이러한 CNN에 대한 의존성을 없애고, 이미지를 언어의 '단어'처럼 취급하여 하나의 신경망으로 통합 처리하는 새로운 접근법을 제시했음.

2. ViT의 핵심 기여와 특징

ViT는 이미지를 patch들의 시퀀스로 변환하고, 표준 트랜스포머 인코더를 적용하여 이미지 인식 문제를 해결하는 새로운 패러다임을 구축했음.

- 핵심 아이디어: 이미지를 여러 개의 작은 패치로 나눈 후, 이 패치들을 언어 모델의 token처럼 다뤘음. 트랜스포머는 이 패치들의 시퀀스를 입력으로 받아, Self-Attention 메커니즘을 통해 모든 패치 간의 관계를 파악하고 최종적으로 이미지를 분류했음.
- 모델 구조: ViT는 입력 이미지를 고정된 크기의 패치($P \times P$)로 나누고, 이 패치들을 1차원 벡터로 펼쳤음.
 - 선형 임베딩: 각 패치 벡터는 학습 가능한 선형 투영(linear projection)을 통해 트랜스포머가 처리할 수 있는 차원(D)의 벡터(패치 임베딩)로 변환됐음.
 - 위치 임베딩: 패치의 위치 정보를 유지하기 위해, 각 패치 임베딩에 학습 가능한 1-D position embedding이 더해졌음. 이 임베딩은 모델이 데이터로부터 패치 간의 공간적 관계를 스스로 학습하도록 도왔음.
 - 분류 토큰: NLP의 BERT 모델처럼, 이미지 전체를 대표하는 특별한 학습 가능한 [class] 토큰이 패치 임베딩 시퀀스 맨 앞에 추가됐음. 이 토큰의 최종 출력값을 MLP Head에 입력하여 분류를 수행했음.
 - 트랜스포머 인코더: 이러한 준비 과정을 거친 벡터 시퀀스는 여러 층의 멀티 헤드 셀프 어텐션과 MLP 블록으로 구성된 표준 트랜스포머 인코더에 입력됐음.
- 의의: ViT는 대규모 데이터셋(ImageNet-21k, JFT-300M)으로 사전 학습했을 때, 기존의 최신 CNN 모델(ResNet 등)과 동등하거나 더 뛰어난 성능을 보였음. 특히, 훈련에 필요한 컴퓨팅 자원이 훨씬 적었다는 장점도 있었음. 또한, ViT는 CNN의 지역성(locality) 같은 유도 편향이 적기 때문에, 대규모 데이터로 학습 시 성능이 포화되지 않고 지속적으로 향상되는 경향을 보였음.

3. 결론

ViT는 이미지 인식에 트랜스포머를 직접 적용하여 새로운 패러다임을 제시한 선구적인 논문이었음. CNN에 대한 의존성을 깨고, "대규모 데이터 학습이 유도 편향을 압도한다(large scale training trumps inductive bias)"는 핵심 주장을 성공적으로 증명했음. ViT의 성공은 이미지 인식 분야에 새로운 방향을 제시하며, 이후 수많은 비전 트랜스포머 모델의 연구와 개발에 지대한 영향을 주었음.

Question list

- Q. 논문에서 Self-Supervised Learning으로, masked patch prediction을 적용했다고 나와있다.
-> data augmentation 기법 중 cutout이나 erasing 처럼 마스킹하는 증강이 있는데,
-> 증강과 SSL 방법론으로 무슨 차이가 있는지?
- A. Augmentation은 sample 수를 늘려 일반화 시키는 목적,
masked patch prediction은 학습에서 가중치를 조정하기 위해 적용.