

Sam + Gan 리뷰



논문 읽는 방법

1. 해당 연구는 어떤 문제를 해결하기 위함인가
2. 기존 연구들은 어떤 한계점이 있는가?
3. 그걸 이 논문이 어떻게 해결하려 하는가?
4. 어떤 방법론을 제시하는가
5. 해당 방법론이 기존과 다른점, 올바르게 검증되었는가
6. 결론

SAM

Abstract

- Segmentation 분야에서 zero-shot, few-shot 일반화가 가능한 foundation model의 부재
 - 웹 규모로 학습할 수 있는 대규모 mask data 부족
 - 다양한 prompt(point, box, mask, text)에 real-time으로 응답하는 유연한 segmentation model 필요
- Segment Anything 프로젝트 제안
 - promptable segmentation task 정의
 - Segment Anything Model(SAM) 아키텍처
 - 1.1B masks, 11M images의 SA-1B dataset 구축
- zero-shot transfer로 다수 downstream tasks에서 기존 fully-supervised 성능에 필적 또는 상회하는 결과

해당 연구는 어떤 문제를 해결하기 위함인가

- 새로운 domain과 task에서 추가 학습 없이도 동작하는 범용 segmentation 능력 확보가 어려움

- 대규모/다양한 pixel-level annotation이 부족하여 scale 이득을 누리기 어려움
- interactive segmentation은 입력이 많고 ambiguity handling이 취약하며 real-time 사용에 제약이 있음

기존 연구들은 어떤 한계점이 있는가?

- semantic, instance, panoptic 등 task별로 별도 학습이 필요
- prompt 유형을 폭넓게 다루지 못하고 real-time 성능이 부족
- 모호한 지시 한 개에 대해 일관된 multi-hypothesis 제공이 어려움
- 대규모 일반화에 필요한 web-scale mask dataset 부재

그걸 이 논문이 어떻게 해결하려 하는가?

- segmentation을 promptable task로 재정의하여 임의의 prompt에 즉시 valid mask 반환
- image embedding을 재사용하고 prompt 경로를 경량화하여 browser-level real-time 응답 구현
- model-in-the-loop data engine으로 대규모 mask를 점진 확장해 SA-1B 구축
- ambiguity-aware 설계로 한 prompt에 multiple candidate masks와 predicted IoU 제공

어떤 방법론을 제시하는가

- 모델 구성
 - image encoder
 - ViT 기반(MAE pretraining)
 - prompt encoder
 - point/box/mask/text 임베딩
 - mask decoder
 - Transformer decoder 변형 + dynamic mask head로 예측
- 학습 절차
 - prompt sequence 기반 interactive 시나리오 시뮬레이션
 - focal loss + dice loss 결합

- multi-mask 예측 후 min-loss 선택과 predicted IoU 학습
- 데이터 엔진
 - Assisted-manual 단계에서 도구 보조 라벨링으로 효율 향상
 - Semi-automatic 단계에서 detector 기반 auto masks를 주식과 혼합
 - Fully automatic 단계에서 grid point prompts와 stability-NMS로 대량 자동 생성

해당 방법론이 기존과 다른점, 올바르게 검증되었는가

- 단일 모델이 prompt만 달리해 다양한 segmentation tasks를 zero-shot으로 수행하는 task generalization 달성
- image embedding 1회 계산 후 prompt 처리만으로 real-time interactive 사용 가능
- ambiguity-aware multi-mask와 predicted IoU로 usability·reliability 향상
- 전례 없는 SA-1B 규모로 novel distributions에 대한 generalization 대폭 개선
- 23개 segmentation datasets와 여러 downstream tasks에서 zero-shot으로 강력한 정량적/정성적 성능 확인
- annotation efficiency 개선과 다양한 인구집단에 대한 성능 균형 등 Responsible AI 관점 점검

결론

- promptable segmentation task, SAM·SA-1B를 통해 segmentation용 foundation model의 실현 가능성과 실용성을 입증
- 공개 자원을 통해 다양한 응용에서 zero-shot transfer가 가능하며 segmentation 연구의 scale-up을 촉진
- small/transparent objects와 boundary precision, text prompt 고도화 등은 향후 과제로 남음

GAN

Abstract

- generative model estimation을 adversarial process로 수행하는 새로운 framework 제안
 - generator G는 data distribution을 학습
 - discriminator D는 sample이 data인지 G인지 판별하도록 학습
 - 학습은 G가 D를 속이도록 하고 전체는 minimax two-player game으로 정식화됨
- G와 D를 multilayer perceptron으로 두면 전체 시스템을 backpropagation만으로 end-to-end 학습 가능
 - training이나 sampling에서 Markov chains나 unrolled approximate inference가 불필요
- MNIST, TFD, CIFAR-10에서 정성·정량 평가로 framework의 잠재력 시연

해당 연구는 어떤 문제를 해결하기 위함인가

- deep generative model 학습에서 maximum likelihood 계열이 요구하는 비가법적 확률 연산과 MCMC 등으로 인한 학습 난이도와 효율성 저하를 해소하고자 함
- piecewise linear units를 활용한 효율적 학습을 generative setting에서도 가능하게 할 방법이 필요

기존 연구들은 어떤 한계점이 있는가

- RBM, DBM 등 undirected 모델은 partition function과 gradient가 비가역적이어서 MCMC에 의존하며 mixing 문제가 큼
 - DBN 같은 hybrid 모델은 directed/undirected의 어려움을 모두 가짐
- score matching, NCE 등은 정규화 상수까지 포함한 density 형태가 필요하거나 고정 noise 분포로 인해 학습이 둔화됨
- GSN 등 Markov chain 기반 방법은 sampling/학습 모두에 chain이 필요
 - feedback loop로 piecewise linear units 활용이 제약

그걸 이 논문이 어떻게 해결하려 하는가

- generator와 discriminator를 경쟁시키는 adversarial nets를 제안
 - likelihood 계산이나 MCMC 없이 gradient 기반으로 학습
 - D는 data vs model을 판별
 - G는 D의 오분류 확률을 최대화하도록 학습

- 분포를 간접적으로 맞춤
- 이 minimax 기준이 비모수 한계에서 p_g 가 p_{data} 에 수렴하도록 이론적으로 보임

어떤 방법론을 제시하는가

- 모델 구성
 - prior p_z 에서 z 를 샘플링하고 G 로 data space로 사상하는 generator
 - D 는 x 가 data일 확률을 산출하는 discriminator
- 학습 목적 함수
 - 초기 학습 안정화를 위해 G 의 대체 목적 $\log D(G(z))$ 를 사용하는 non-saturating trick 제안
- 학습 절차
 - discriminator를 k step 업데이트하고 generator를 1 step 업데이트하는 alternating SGD 알고리즘 제시
- 이론 결과
 - 최적 D 는 $D^*(x) = p_{data}(x) / (p_{data}(x) + p_g(x))$
 - global optimum은 $p_g = p_{data}$
 - 이때 $D(x) = 1/2$, 목적값은 $-\log 4$
 - 이상적인 조건에서 alternating 업데이트가 $p_g \rightarrow p_{data}$ 로 수렴함을 제시

해당 방법론이 기존과 다른점, 올바르게 검증되었는가

- likelihood 계산이나 MCMC 없이 backprop만으로 학습/샘플링이 가능해 계산적으로 간결
- generator가 data 예시를 직접 복사하기보다 discriminator를 통한 gradient로만 업데이트
 - 날카로운 분포까지 표현 가능
- MNIST/TFD 등에서 Parzen window 기반 log-likelihood가 기존 방법과 경쟁적 수준
- CIFAR-10 등에서 실제 샘플을 시각화하여 chain mixing 없이 생성 가능함을 보임

결론

- adversarial modeling framework가 deep generative modeling의 유효한 대안임을 보였고, 다양한 확장이 가능함
 - conditional GAN, learned inference network, semi-supervised learning, 효율 개선 등 후속 연구 방향 제안