

1. 서론: 세그멘테이션 패러다임의 전환과 SAM의 등장

기존의 이미지 segmentation 연구는 특정 데이터셋과 과제에 맞춰진 모델을 훈련하는 방식이 일반적이었음. 하지만 이런 방식은 새로운 데이터 분포나 과제를 만났을 때 일반화 성능이 떨어진다는 한계가 있었음. Meta AI의 Segment Anything Model (SAM)은 이를 극복하기 위해 **foundation model** 개념을 세그멘테이션에 도입했음. SAM은 promptable segmentation을 통해, 한 번 학습된 모델이 다양한 다운스트림 분할 과제에 제로샷으로 적용될 수 있도록 설계됐음. 또한, 이를 위해 1.1B 마스크, 11M 이미지 규모의 초대형 데이터셋 SA-1B를 구축했음.

2. YOLOv1의 핵심 기여와 특징

- 핵심 아이디어
 - NLP에서의 프롬프트 개념을 이미지 세그멘테이션으로 확장했음.
 - 사용자가 점, 박스, 마스크, 텍스트 등의 프롬프트를 입력하면, 모델이 해당 영역에 대한 분할 마스크를 출력하는 구조를 제안했음.
 - 프롬프트가 모호할 경우(예: 셔츠 위의 점 → '셔츠' 또는 '사람'), 여러 개의 합리적인 마스크를 동시에 예측할 수 있도록 했음
- 모델 구조
 - 이미지 인코더: MAE로 사전학습된 ViT를 활용해 이미지 임베딩을 생성했음.
 - 프롬프트 인코더: 점·박스·텍스트 등 다양한 형태의 프롬프트를 임베딩으로 변환했음. 텍스트의 경우 CLIP 인코더를 사용했음.
 - 마스크 디코더: 이미지 임베딩과 프롬프트 임베딩을 결합해 마스크를 빠르게 예측하는 경량 디코더를 사용했음.
 - 이 구조는 한 장의 이미지 임베딩을 미리 계산해두면, 다양한 프롬프트를 빠르게 처리할 수 있었음(브라우저 환경에서 약 50ms).
- 데이터 엔진과 SA-1B
 - 세그멘테이션 데이터가 부족하다는 한계를 극복하기 위해 모델-인-더-루프(model-in-the-loop) 방식의 데이터 엔진을 구축했음.
 - ◆ 1 단계: SAM이 보조하는 수동 라벨링 단계
 - ◆ 2 단계: 일부 자동 예측 + 보정하는 반자동 단계
 - ◆ 3 단계: SAM이 전적으로 마스크를 생성하는 완전 자동 단계
 - 이 과정을 통해 1.1B 고품질 마스크가 생성됐으며, 이는 기존 데이터셋 대비 400배 이상 규모였음
- 제로샷 전이 성능
 - SAM은 학습 데이터에 없는 새로운 데이터 분포에서도 강력한 성능을 보였음.
 - 23개 벤치마크에서 단일 점 프롬프트만으로도 높은 품질의 마스크를 생성했음.
 - 또한, 에지 검출, 객체 제안, 인스턴스 세그멘테이션, 텍스트-마스크 분할 같은 다양한 다운스트림 작업에 제로샷으로 적용 가능했음.
 - 인간 평가에서도 기존 강력한 세그멘테이션 기법들보다 높은 품질 점수를 받았음.

3. 결론

SAM은 세그멘테이션을 위한 최초의 범용 파운데이션 모델을 제시했음. 프롬프트 가능한 구조와 초대형 데이터셋 SA-1B를 통해, 특정 태스크에 맞춰 훈련되지 않아도 새로운 과제에 제로샷으로 적용될 수 있음을 보여줬음. 이는 이후 컴퓨터 비전 연구에서 generalist model의 가능성을 크게 확장시켰으며, 향후 다양한 실세계 응용에서 활용될 수 있는 기반을 마련했음.

Question list

- Q. 논문에서는 fully automatic stage에서 대부분의 마스크를 생성했음.(무려 99.1%)
모델이 생성한 데이터로 모델을 학습시키는 것이 줄 수 있는 잠재적 위험요소가 있지 않을까?
- A. 믿기 힘들게 정상이지만, 성능을 통해 신뢰성 보장해줌.

1. 서론: 생성 모델 패러다임의 전환과 GAN의 등장

기존의 생성 모델(예: RBM, DBM, VAE)은 확률 분포 추정 시 복잡한 추론 과정(MCMC, 근사 추론 등) 때문에 학습이 어렵고 계산량이 많았음. Goodfellow et al.(2014)의 Generative Adversarial Nets은 이러한 한계를 넘어, adversarial training이라는 새로운 프레임워크를 제안했음. GAN은 생성자(Generator, G)와 판별자(Discriminator, D) 두 신경망을 경쟁적으로 학습시켜, 데이터 분포를 모사하는 강력한 생성 모델을 구축했음.

2. GAN의 핵심 기여와 특징

- 핵심 아이디어

■ 두 모델의 게임 구조

- ◆ G: 랜덤 노이즈 $z \sim p_z(z)$ 를 입력받아 데이터를 생성했음.
- ◆ D: 입력 x 가 실제 데이터인지(G가 만든 가짜인지) 판별했음.

■ 학습 목표:

- ◆ D는 진짜/가짜를 정확히 분류하려고 했고,
- ◆ G는 D를 속일 수 있는 샘플을 만들어내려고 했음.

■ 결과적으로, 두 네트워크는 미니맥스 게임(minimax game)을 수행하며, 최적점에서는 G가 진짜 데이터 분포와 동일한 분포를 학습했음

- 모델 구조와 학습

■ 목적함수:

$$\min_G \max_D V(G, D) = E_{x \sim p_{data}} [\log D(x)] + E_{z \sim p_z} [\log(1 - D(G(z)))]$$

■ 학습 절차:

- ◆ D를 여러 스텝(k번) 업데이트한 뒤 → G를 한 번 업데이트했음.
- ◆ 초기 학습에서 G의 gradient 소실 문제(= saturating gradient)를 완화하기 위해, $\log(1 - D(G(z)))$ 대신 $\log(D(G(z)))$ 로 학습하기도 했음.

■ 특징적 장점:

- ◆ 확률밀도 추정이나 마르코프 체인 필요 없음 → 단순한 backpropagation으로 학습 가능했음.
- ◆ 샘플링 시에도 단순 forward pass만 필요했음.

- 이론적 기여

■ 최적의 D는 다음과 같았음:

$$D_G^*(x) = \frac{p_{data}(x)}{p_{data}(x) + p_g(x)}$$

■ 최종적으로 G가 데이터 분포와 동일해질 때 게임은 균형 상태에 도달했으며, 이때 판별자는 모든 입력에 대해 0.5의 확률을 출력했음.

■ 이는 GAN이 데이터 분포 복원을 이론적으로 보장함을 보여줬음

- 실험적 기여

■ 저자들은 MNIST, CIFAR-10, TFD 등 데이터셋에서 GAN을 적용하여, 기존의 생성 모델보다

시각적으로 훨씬 더 사실적인 샘플을 보여줬음.

- 비록 초기 GAN은 불안정한 학습 문제(mode collapse 등)를 가지고 있었으나, 이후 DCGAN, WGAN, StyleGAN 등 다양한 변형 연구의 출발점이 됐음.

3. 결론

GAN은 생성 모델의 새로운 패러다임을 제시했으며, 복잡한 확률 계산 없이도 **고품질 샘플 생성**이 가능함을 보였음. 이는 이미지 합성, 데이터 증강, 예술/디자인, 영상 생성 등 수많은 응용을 가능하게 했고, 이후 딥러닝 생성 모델 분야의 **핵심 토대**가 됐음.

Question list

- Q. 핵심은 distribution을 모방하는 것인데 만약 온 픽셀이 independent하다면 (real-world에 존재하기 어렵지만) 학습이 매우 어려워지는건지?
- A. 성능 보장이 어렵겠지만, 점차 학습할 것