

1. 서론: 확률적 확산모델(Diffusion Model)의 등장

기존의 생성 모델들은 고품질 이미지를 만들 수 있었지만, 학습 과정이 불안정하거나 계산 과정이 복잡하다는 한계를 가지고 있었다. 대표적으로 VAE는 확률 분포를 근사하기 위한 복잡한 추론이 필요했고, GAN은 판별자와 생성자가 경쟁하면서 학습이 자주 불안정해지는 문제가 있었다.

이러한 한계를 극복하기 위해 Ho 등(2020)은 Denoising Diffusion Probabilistic Model, 즉 DDPM이라는 새로운 생성 모델을 제안하였다. 이 모델은 "데이터에 점점 노이즈를 추가했다가, 다시 그 노이즈를 제거하며 원본 이미지를 복원하는 과정"을 학습한다.

즉, 한쪽에서는 깨끗한 이미지에 무작위 노이즈를 반복적으로 섞어가며 완전히 흐릿하게 만드는 과정을 만들고, 다른 한쪽에서는 그 반대 방향으로 점진적으로 노이즈를 제거해 이미지를 되살리는 과정을 학습한다. 이런 구조는 기존의 생성 모델들보다 훨씬 단순하고 안정적이면서도, 매우 사실적인 이미지를 만들 수 있게 해주었다.

DDPM의 핵심 아이디어는 "노이즈 추가와 제거"라는 단순한 절차 안에 있다. 모델은 어떤 데이터가 주어졌을 때 그것을 조금씩 흐리게 만들어 결국 완전히 무작위한 상태로 만들고, 그 반대의 과정을 학습하여 무작위 노이즈에서 다시 이미지를 복원한다. 이렇게 학습된 모델은 판별자 없이도 이미지를 점점 복원해 나갈 수 있으며, 학습 과정이 수학적으로 안정적이다.

2. 핵심 아이디어와 모델 구조

DDPM은 두 가지 주요 과정으로 구성된다. 하나는 정방향 과정이고, 다른 하나는 역방향 과정이다.

정방향 과정에서는 깨끗한 이미지에 아주 미세한 가우시안 노이즈를 한 단계씩 추가한다. 이 과정을 수백 번 반복하면, 원래의 이미지가 점차 희미해지고 결국 완전히 랜덤한 노이즈처럼 된다. 즉, 데이터를 점진적으로 파괴해 나가는 과정이라고 볼 수 있다.

그 다음은 역방향 과정이다. 이 단계에서는 모델이 이러한 노이즈화 과정을 거꾸로 되돌리며 이미지를 복원하는 법을 학습한다. 처음에는 완전히 무작위한 노이즈를 입력받지만, 학습된 모델은 이 노이즈 속에서 점점 의미 있는 형태를 찾아내고, 마지막에는 원래의 이미지와 매우 유사한 결과를 만들어낸다.

기존의 확률적 생성모델들은 복잡한 수식과 근사 방법으로 확률분포를 계산해야 했지만, DDPM은 이러한 과정을 단순화했다. 모델이 직접 "이미지를 예측"하는 대신, 각 단계에서 "이미지 속의 노이즈"를 예측하게 만든 것이다. 학습할 때는 "입력 이미지에 추가된 노이즈를 얼마나 정확히 맞추는가"를 기준으로 모델을 평가한다. 다시 말해, 모델은 실제 이미지를 맞추는 것이 아니라 그 이미지에 섞인 노이즈를 얼마나 정확히 복원할 수 있는지를 배우는 것이다.

이 방식은 매우 단순한 형태의 손실 함수로 훈련할 수 있다. 복잡한 확률 계산 없이, 모델이 예측한 노이즈와 실제 노이즈의 차이를 최소화하도록 학습한다. 이런 구조 덕분에 학습이 매우 안정적이며, GAN처럼 판별자와 생성자가 경쟁할 필요가 없다.

샘플링, 즉 이미지를 생성하는 과정도 간단하다. 처음에는 완전히 무작위한 노이즈를 입력으로 넣고, 학습된 모델을 여러 번 반복 적용한다. 모델은 매번 노이즈의 양을 조금씩 줄여가며 점점 더 선명한

이미지를 만들어낸다. 초반에는 흐릿한 형태만 보이지만, 점점 윤곽이 생기고 마지막 단계에 이르면 고품질의 완성된 이미지가 나온다.

3. 실험 결과

저자들은 DDPM 을 다양한 데이터셋에 적용하여 성능을 비교했다. CIFAR-10 데이터셋에서 DDPM 은 매우 뛰어난 결과를 보였다. Inception Score 가 9.46, FID 점수가 3.17 로, 기존의 대부분의 GAN 기반 모델보다 더 좋은 품질의 이미지를 생성했다. LSUN 데이터셋에서는 ProgressiveGAN 과 비슷한 수준의 샘플 품질을 보였고, CelebA-HQ 데이터셋에서도 매우 자연스러운 얼굴 이미지를 만들어냈다.

이 모델은 한 번의 생성 과정에서 약 1000 단계의 점진적인 노이즈 제거 단계를 거치며, 큰 형태부터 세부적인 질감까지 점차 복원하는 구조를 가지고 있다. 특히 모델 내부에서는 U-Net 구조와 Self-Attention 메커니즘을 사용하여 이미지의 공간적 관계를 잘 보존하면서, 세부적인 질감까지 세밀하게 복원할 수 있었다.

이러한 결과는 “단순한 구조로도 고품질의 이미지를 만들 수 있다”는 것을 보여주었으며, 복잡한 경쟁 구조를 가진 GAN 에 비해 훨씬 안정적으로 학습된다는 장점을 입증했다.

4. 이론적 의미

DDPM 은 단순히 새로운 생성 모델일 뿐 아니라, 여러 기존 기법과 이론적 연관성이 깊다.

첫째, 이 모델은 **Denoising Score Matching** 과 직접적으로 연결된다. 노이즈를 예측하는 과정은 실제로 데이터 분포의 점진적인 “기울기(gradient)”를 추정하는 것과 같기 때문이다. 이 점에서 DDPM 은 Score Matching 기반의 생성 모델과 수학적으로 동일한 구조를 가지고 있다.

둘째, 모델이 이미지를 생성할 때 사용하는 절차는 **Langevin Dynamics**, 즉 확률적 기울기 하강법과 유사하다. 매 단계마다 조금씩 노이즈를 제거하면서, 더 높은 확률의 데이터 분포 쪽으로 점차 이동한다. 따라서 이 모델은 “확률적 최적화 과정”으로도 해석할 수 있다.

셋째, DDPM 은 **Autoregressive 모델**을 일반화한 형태로 볼 수도 있다. 기존의 Autoregressive 모델은 이미지를 한 픽셀씩 순서대로 예측하지만, DDPM 은 픽셀 단위 대신 노이즈 강도 단계를 순서로 삼아 점진적으로 정보를 복원한다. 이런 점에서 DDPM 은 기존의 순차적 생성 과정을 훨씬 유연하게 확장한 모델이라고 할 수 있다.

넷째, 이 모델의 샘플링 과정을 **점진적인 압축과 복원**으로 해석할 수도 있다. 처음에는 큰 구조적 형태를 복원하고, 점점 세부적인 질감이나 색상을 채워 넣는 방식으로 이미지를 만들어내기 때문이다. 즉, DDPM 은 “데이터를 압축했다가 조금씩 복원하는” 과정으로도 이해할 수 있으며, 이는 데이터 압축이나 전송 등의 응용에서도 중요한 시사점을 가진다.

5. 결론

DDPM 은 단순하지만 강력한 아이디어로 생성 모델의 새로운 흐름을 만든 연구이다.

이 모델은 복잡한 판별자 구조 없이도 매우 자연스러운 이미지를 만들어낼 수 있으며, 학습 과정이 수학적으로 안정적이다. GAN 이 만들어낸 경쟁적 구조를 확률적 복원 구조로 대체하면서, “안정성과 품질”이라는 두 가지 목표를 모두 달성했다.

특히 DDPM은 이후 등장한 다양한 확산 기반 모델들의 토대가 되었다. Stable Diffusion, Imagen, DALL·E 3 같은 최신 생성모델들은 모두 DDPM의 아이디어를 기반으로 발전한 모델들이다. DDPM은 “노이즈를 점진적으로 제거하면서 이미지를 생성한다”는 새로운 패러다임을 제시했고, 이는 오늘날 생성 AI의 핵심적인 방향이 되었다.