

Diffusion

해당 연구는 어떤 문제를 해결하기 위함인가

- 고품질 이미지 생성과 안정적 학습을 동시에 달성할 통합적 접근 부재
- diffusion 모델의 실질적 샘플 품질과 설계 지침 부족
- likelihood 평가 가능성과 시각적 품질 사이의 간극 존재

기존 연구들은 어떤 한계점이 있는가

- GAN
 - 훈련 불안정과 mode collapse 문제
→ likelihood 평가 어려움
- Autoregressive, Flow, VAE
 - likelihood는 쉬움
 - But, 품질, 속도, 표현력에서 손해
- Score matching, EBM
 - 샘플링이 느리고 수렴이 까다로움
- 기존 diffusion 연구
 - 파라미터화와 손실 설계에 합의 부족
 - 최고 품질 미달

그걸 이 논문이 어떻게 해결하려 하는가

- 역과정 평균 대신 노이즈 ϵ 예측 파라미터화 도입
- denoising score matching과 Langevin dynamics와의 명시적 연결
- 고정 노이즈 스케줄과 단순 MSE 기반 학습 목적 제안
- 생성 과정을 점진적 손실 압축과 autoregressive 해석으로 설명

어떤 방법론을 제시하는가

- 선형 증가하는 고정 β 스케줄의 forward diffusion 사용

- 시간 임베딩을 받는 U-Net 백본으로 단계별 ϵ 예측
- 파라미터 공유와 중간 해상도 self-attention 적용
- 모든 노이즈 단계에 대해 단순화 목적함수로 학습
- 노이즈 공간 보간과 progressive generation, rate-distortion 분석 제시

해당 방법론이 기존과 다른점, 올바르게 검증되었는가

- μ 예측이 아닌 ϵ 예측, 분산 고정
 - 가중 제거된 단순 손실이 핵심 차별점
- 동일 백본에서 μ 예측 대비 ϵ 예측과 단순 손실 조합이 최고 품질을 보임
- 비조건부 CIFAR-10에서 FID 3.17과 IS 9.46 달성
- 256×256 LSUN에서 ProgressiveGAN에 필적하는 시각적 품질 확인
- likelihood는 일부 모델 대비 낮음
 - But, 과적합 징후는 없고 progressive decoding으로 동작 원리 시각화

결론

- 적절한 파라미터화와 손실 설계로 diffusion은 고품질과 안정 학습을 동시에 달성
- score matching, Langevin, autoregressive, 압축과의 연결로 이론적 기반 강화
- 향후 과제는 더 빠른 샘플링, 더 나은 likelihood, 다양한 조건부와 모달리티 확장