

# [Paper Review] Improving Language Understanding by Generative Pre-Training

25기 분석  
서영우

## 0. Abstract

- 레이블이 없는 방대한 텍스트로 언어모델은 '사전학습'한 후, 특정 작업에 맞게 fine-tuning을 진행하면 성능을 크게 향상시킬 수 있음을 보여줌.


## 1. Introduction

- 대부분 NLP 작업에서 대규모의 레이블된 데이터를 필요하지만, raw data는 그렇지 않으므로 시간과 비용이 많이 듦.
- Transfer Learning을 진행하기 위해 목표가 명확하지 않음(language modeling, machine translation 등)
- 학습되더라도 특정 작업 즉 target에 어떻게 전달하는 것이 가장 효과적인지 기준이 없었기에 작업별로 모델 구조를 기준 없이 변경함.

## 2. Related Works

- 비지도 사전 훈련(Unsupervised pre-training)  
언어 모델링을 통해 신경망을 pre-training하고, 특정 task에 fine-tuning을 진행했으나, 장거리에 위치한 데이터에 영향을 받는 경우가 있음
- 준지도학습(Semi-supervised learning)  
레이블 없는 데이터로 단어 또는 구문 수준 수준의 통계를 계산해서 지도학습의 feature로 사용했으나, 이 이상으로 발전시키기에는 어려움이 존재함

## 3. Method



- 크게 두 가지로 학습을 진행한다
- 1) 비지도 사전 훈련 (Unsupervised Pre-training)
  - 대규모 text corpus를 사용해서 모델의 초기 파라미터 학습
  - 12개 decoder block으로 구성된 **transformer** 구조 사용(RNN 대비 long term dependencies를 효과적으로 처리 가능)
- 2) 지도 미세 조정(Supervised Fine-tuning)
  - 질의응답이나 전제와 가설같은 쌍들을 하나의 연속된 token sequence로 변환해서 입력할 때 작업을 처리할 수 있게 만들.
  - fine-tuning 진행시 language modeling을 목표로 사용

#### 4. Experiments

- BoocksCorpus라는 긴 텍스트가 연속적으로 이루어진 도서 데이터로 사전 훈련 진행
- 12개 decoder block인 transformer, 768차원 state, 12개 attention head
- 12개 작업 중 9개에서 최고 성능 달성
- 특히 언어적 문법성을 판단하는 작업에서 약 30%p 성능 향상을 보임

#### 5. Discussion

- Pre-trained model의 layer를 전이할수록 작업 성능이 향상되는 것으로 보아 레이어가 대상 작업을 해결하는 데 도움을 주고 있음을 시사.
- Fine-tuning이 없어도 pre-trained model 자체가 특정 작업을 어느정도 수행할 수 있음.
  - \*zero-shot 성능이 사전 훈련이 진행됨에 따라 꾸준히 증가하는 것으로 보아 transformer 구조가 lstm보다 transfer learning에 더 우수함을 시사.
- 언어모델의 핵심은 사전 훈련이라는 것을 강조함. 사전 훈련이 되지 않았을 경우 앞선 실험의 결과 대비 15% 가까이 성능이 하락하는 것을 확인함.
- 추후 BERT에서 해결된 것처럼, 양방향으로 문맥을 활용하는 데엔 어려움이 있었음.

\* zero shot : 모델에게 아무런 예시 데이터나 훈련 데이터 없이, 이전에 학습한 일반적인 지식을 바탕으로 새로운 작업이나 과제를 수행하는 방식

#### 6. Conclusion

- 불특정 작업에 한계를 느낀 상황에서 다양한 long text corpus로 pre-training을 진행함으로써, 언어 모델이 한단계 성장하게 되었다.

#### 7. 기존 연구 대비 차별점

- 작업별로 특정 모델 구조를 설계하는 것과 달리 입력 형태를 변환하되 단일 모델 구조를 유지
- 기존에는 lstm을 사용했으나 transformer을 사용하면서 우수함을 선보임 (장거리 의존성 해결)
- 생성형 언어 모델링을 통해 문맥 생성 능력을 기름.

## 8. 핵심 아이디어

- Generative pre-training과 discriminative fine-tuning
- 레이블되지 않은 텍스트 데이터로 트랜스포머 기반 언어 모델을 사전 학습 시키고 레이블된 데이터로 특정 작업에 맞게 모델 전체를 fine-tuning
- 특정 task에 맞게 레이블된 데이터가 꼭 아니어도 효율적으로 모델링 진행했다는 점이 포인트

## 9. 다뤄볼 수 있는 부분 & 의문점

- 영어가 아닌, 특성이 다른 언어에서도 동일하게 적용이 되는지
- BooksCorpus 데이터셋에 대한 편향성이 존재하지 않았는지? 예를 들어 지식 기반 내용의 책이 존재했다면, 특정 작업 처리에 유리한 것이 아니었는지 + 문체에 대한 다양성이 부족해짐
- fine-tuning을 진행할 때 lambda를 0.5로 설정했던데, 해당 데이터셋 한정 최적인지
- very라는 단어를 이해했다! 에 자랑을 하는데, 실제로 모델이 파악하고 이해한 것인지 +zero shot도 동일