

Transformer 이전 모델들

- FNN (Feedforward Neural Network)
 - 독립적인 입력만 학습 가능 → 문맥 반영 불가.
- RNN(Recurrent Neural Network)
 - 시퀀스 데이터를 순차적으로 처리
 - Hidden state를 통해 이전 시점 정보 반영 가능
 - 문제점 : Gradient Vanishing, 장기 의존성 문제
- LSTM(Long Short-Term Memory)
 - Cell state 추가, Forget / Input / Output gate로 정보 흐름 제어.
 - 장기 의존성 문제 개선
 - 단점 : 구조가 복잡하고, 동시에 연산량도 많음.
- GRU(Gated Recurrent Unit)
 - Reset gate + Update gate를 통해 구조 단순화
 - LSTM보다 모델이 훨씬 단순하면서, 성능도 꽤 좋아 효율적.
- Seq2Seq(Encoder-Decoder)
 - Encoder를 통해 context vector를 생성하고, Decoder를 통해 압축을 푸는 형식.
 - Many to Many의 형식이지만, Many to one 을 두개 합친 형식, 즉 context vector에 모든 정보를 압축하기 때문에 Bottleneck 현상이 발생함.

Attention의 등장

- Q(uey), K(ey), V(alue) 구조
 - Query: 현재 처리하는 벡터
 - Key: Query와의 유사도를 측정하는 기준
 - Value: 유사도에 기반해 가중합되는 벡터
- Transformer 구조
 - 입력
 - Token Embedding: 단어를 벡터로 변환
 - Positional Encoding: 순서 정보 보완
 - Encoder
 - Self-Attention: 입력 문장 내 단어 간 관계 학습
 - Scaled Dot-Product Attention: 안정적 학습
 - Multi-Head Attention: 병렬화, 다양한 패턴 학습
 - Decoder
 - Masked Multi-Head Attention: 미래 단어 정보 차단
 - Position-wise Feed-Forward: 비선형 변환
 - Residual Connection + Layer Normalization: 학습 안정화
- Transformer 모델
 - GPT - **Decoder-only**, 다음 단어 '예측'
 - BERT - **Encoder-only**, 'Masked'
 - BART - **Encoder-Decoder**, 앞 둘의 합체