


Diffusion model

<https://lcyking.tistory.com/entry/%EB%85%BC%EB%AC%B8%EB%A6%AC%EB%B7%B0-Denoising-Diffusion-Probabilistic-Models-DDPM>

<https://kyujinpy.tistory.com/95>

Diffusion 이란?

Diffusion은 VAE, GAN과 같은 이미지 생성 모델



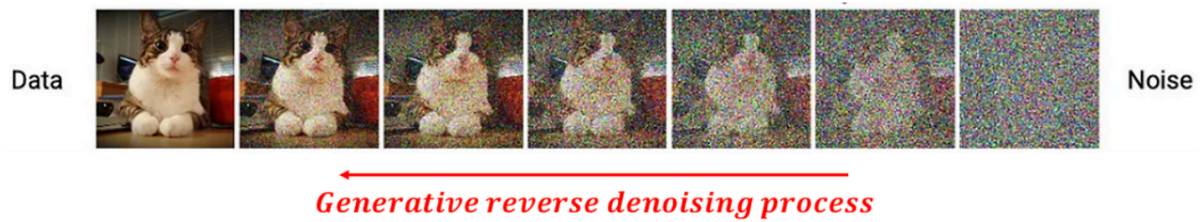
<https://en.wikipedia.org/wiki/Diffusion#/media/File:Diffusion.svg>

원래는 물리, 화학 쪽에서 유래되었으며 직역하면 '**확산**'이라는 뜻이고, 특정한 물질이 조금씩 번지면서 농도가 높은 영역에서 낮은 영역으로 이동하는 것이다.



기존 데이터인 이미지에서 가우시안 노이즈를 점진적으로 가하는 절차를 Diffusion이라고 한다. 이 절차가 점진적으로 진행되면, 가우시안 노이즈가 점차 확산되면서 전체 이미지의 분포는 가우시안 분포와 가까워질 것이다.

아래의 그림을 보면 DDPM은 Diffusion 절차뿐만 아니라 하나의 절차가 더 있다.



위와 같이 노이즈 이미지를 기존 이미지를 복원하는 과정인 **Denoising** 절차가 이 논문의 핵심이다.

이 Denoising 절차에서 기존 생성 모델들의 목적과 같이 **Likelihood**를 최대로 하는 것이다.

이와 같이 DDPM은 **Forward** 과정인 **Diffusion Process**와 **Reverse** 과정인 **Denoising Process** 두 개의 과정으로 분리된다. 일단은 Diffusion은 사전 정의하는 것이고, Denoising은 학습해야 하는 것이다.

Gaussian이란?

우리가 흔히 아는 정규분포.

“어떤 값이 평균 근처에 있을 확률이 가장 높고,
평균에서 멀어질수록 확률이 줄어드는 분포”

가우시안은 계산이 매우 쉽고 닫혀 있는 형태라서 AI, 통계, 확률 모델에서 **표준적인 기본 분포**로 쓰인다.

→ 평균과 분산만 알면, 분포를 완벽히 표현할 수 있음.

조건부 가우시안

조건부라는 말은 “어떤 다른 값이 주어졌을 때”를 뜻함.

x_1, x_2 가 둘 다 가우시안 분포를 따를 때, x_2 가 주어졌을 때 x_1 의 분포

“사람 키는 평균 170cm, 표준편차 5cm로 분포한다.” → 일반적인 가우시안 가정이라고 하면

- 전체 사람의 키 분포: 평균 170cm
- 남자만 본다면: 평균 175cm

→ 성별이 주어졌을 때 키의 분포가 달라진다.

즉, 조건이 주어졌을 때, 가우시안의 평균과 분산이 그 조건에 맞게 달라지는 것을 의미함.


- x_{t-1} : 이전 단계 이미지

- x_t : 지금 단계 이미지 (조금 더 노이즈 추가된 버전)

즉, "이전 이미지가 주어졌을 때, 지금 이미지는 어떻게 나올까?" 라고 모델에게 물어봄.

Markov Chain

Markov Chain이란 **Markov 성질**을 가지는 **이산 확률 과정**을 뜻한다.



여기서 모든 노이즈 이미지는 이전 이미지의 상태에만 의존하여, **Diffusion** 하거나 **Denoising** 합니다. 이 과정이 Markov chain의 수식과 동일하다.

Diffusion Models은 다음 형태의 잠재 변수 모델이다:

$$p_\theta(x_0) = \int p_\theta(x_0 : T) dx_{1:T}$$

여기서 $x_1, \dots, x_T$ 는 데이터 x_0 와 동일한 크기의 잠재 변수이다.

즉, x_0 는 실제 이미지 데이터, x_1, x_T 는 그 데이터의 **노이즈 버전들**이다.

이 전체 확률 $p_\theta(x_{0:T})$ 을 역방향 과정이라고 하며, 이는 학습된 가우시안 전이를 갖는 마르코프 연쇄으로 정의된다.

시작점은 다음과 같다:

$$p(x_T) = N(x_T; 0, I)$$

즉, 맨 처음 상태 x_T 는 순수한 노이즈(평균 0, 분산 1)에서 시작한다.

역확산은 "각 단계마다 가우시안 분포를 따르며, 신경망이 그 분포의 평균·분산을 예측하는" 형태다.

DDPM의 노이즈 추가 과정은 **학습되지 않고 고정된 가우시안 마르코프 체인**으로 정의된다.

이전 이미지(x_{t-1}) 주변에 약간의 노이즈(β_t)만큼 랜덤하게 퍼진 이미지(x_t)를 만드는 **조건부 가우시안 확산 과정**이다.

모델은 "데이터를 가장 잘 재현하는 확률"을 높이는 방향으로 학습된다.

학습 목적 L은 모델의 생성 확률 vs 실제 노이즈화 과정의 차이를 최소화하는 것이다.

노이즈 양(β_t)을 작게 잡으면, **정방향·역방향 모두 가우시안 구조로 단순하고 안정적**이다.

한 번에 "t단계 노이즈화된 이미지"를 바로 샘플링할 수 있어서 학습이 효율적이고 임의의 단계 t의 항만 사용해서 **효율적으로 진행**할 수 있으며, 추가적으로 손실 L을 다음과 같이 **KL Divergence 항들로 재구성**하여 분산을 줄일 수 있다.

→ 데이터를 점점 노이즈로 만들고(q),그걸 거꾸로 복원하는 확률모델(p_θ)을 학습한다.

두 과정이 모두 **가우시안 체인(조건부 정규분포)** 형태라 수식이 단순하고 KL 계산도 닫힌 형태로 가능하다.

Backward process의 경우 VAE와 동일하게 model의 log likelihood를 maximizing하는 것에 초점을 둔다.

일단 VAE와 동일하게 ELBO를 찾고 이를 최대화 하는 방향으로 훈련을 진행한다.

$$\mathbb{E}[-\log p_\theta(\mathbf{x}_0)] \leq \mathbb{E}_q \left[-\log \frac{p_\theta(\mathbf{x}_{0:T})}{q(\mathbf{x}_{1:T}|\mathbf{x}_0)} \right] = \mathbb{E}_q \left[-\log p(\mathbf{x}_T) - \sum_{t \geq 1} \log \frac{p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)}{q(\mathbf{x}_t|\mathbf{x}_{t-1})} \right] =: L \quad (3)$$

Diffusion에서는 equation (3)을 loss function으로 활용하여 훈련을 진행하는데, 이를 효율적으로 바꾸기 위해서 Equation (5)처럼 표현한다.

$$\mathbb{E}_q \left[\underbrace{D_{\text{KL}}(q(\mathbf{x}_T|\mathbf{x}_0) \parallel p(\mathbf{x}_T))}_{L_T} + \sum_{t \geq 1} \underbrace{D_{\text{KL}}(q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) \parallel p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t))}_{L_{t-1}} - \underbrace{\log p_\theta(\mathbf{x}_0|\mathbf{x}_1)}_{L_0} \right] \quad (5)$$

Rewritten ELBO

본 논문에서 forward process의 variance β_t 가 reparameterization으로 학습 가능하다는 사실을 무시하고 대신 **constant로 고정한다**. 따라서, 본 구현에서는 approximate posterior q에 learnable parameters가 없으므로, L_T 는 훈련 중에 constant이며 무시할 수 있다.

ε-예측: 논문에서 제안된 가장 중요한 아이디어 중 하나는 **노이즈 자체(ε)를 예측하도록 학습**시키는 것이다

훈련 방식: 논문에서는 **간단한 손실 함수**를 사용해 효율적인 학습을 도입한다:

$$L_{\text{simple}}(\theta) = \mathbb{E}_{t, x_0, \epsilon} \left[\left\| \epsilon - \epsilon_\theta \left(\sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t \right) \right\|^2 \right]$$

즉, 신경망이 "어떤 노이즈가 섞였는지"를 예측하도록 학습한다.

x_t 는 x_0 에 노이즈가 t단계 섞인 이미지이고, ϵ 은 실제 노이즈이다.

단계	설명
1. 학습 이미지 선택	예: 고양이 사진 하나 선택
2. 노이즈 추가	반복적 랜덤 노이즈 추가해서 $x_0 \rightarrow x_1 \rightarrow \dots \rightarrow x_T$
3. 복원 학습	x_T 에서 x_{T-1} 를 예측 $\rightarrow$ 반복하여 x_0 복원하도록 학습
4. 새로운 샘플 생성	x_T 를 랜덤 노이즈로 설정 한 후, 학습된 복원 과정을 따라 새로운 이미지 생성