

Diffusion model

상위 작업	세션 논문 리뷰
진행 상태	완료
첨부 파일	Diffusion model.pdf

0. Abstract

1. Introduction

1.1 Introduction

1.2 Background

2. Related Work

3. Method (제안 방법론)

3. Diffusion models and denoising autoencoders

3.1 Forward Process and L_T

3.2 Reverse Process and $L_1 : t-1$

4. Experiments (실험 및 결과)

4. Experiments

5. Conclusion

0. Abstract

어떤 문제를 해결하려 했는가?

- 이 논문은 비평형 열역학의 물리학의 확산 개념을 이미지 생성에 적용하여 Diffusion probabilistic model의 새로운 확률 모델을 제시한다.
- 노이즈를 점점 제거하며 이미지를 복원하는 과정을 모델링했는데, 이게 자기회귀적 디코딩을 일반화한 형태이다.
- DPM과 Langevin dynamics를 통한 denoising score matching 사이에 새로운 연결로 weighted variational bound를 설계하였고 이 덕분에 모델이 훨씬 안정적으로 수렴한다.
- 실험 결과, CIFAR-10에서는 FID 3.17, LSUN에서는 ProgressiveGAN과 유사한 품질을 달성하며 당시 최고 수준의 성능을 보여줬다.

1. Introduction

| 연구 동기와 문제점은 무엇인가?

1.1 Introduction





Figure 2: The directed graphical model considered in this work.

- Diffusion
 - Diffusion 모델은 VAE나 GAN과 같은 생성 모델의 한 종류이다.
 - diffusion이라는 용어는 물리학에서 농도가 높은 영역에서 낮은 영역으로 물질이 서서히 이동하는 현상을 의미한다.
 - 이 개념을 이미지 생성에 적용하면 기존 데이터인 이미지에 점진적으로 가우시안 노이즈를 추가하여 완전히 무작위한 상태로 변환하는 과정으로 볼 수 있다.



- 여기서 아래와 같이, Forward Diffusion Process에서는 데이터가 점차 노이즈로 변하고, 반대로 Reverse Denoising Process에서는 노이즈로부터 원본 이미지를 복원한다.



- DDPM은 Forward 과정인 Diffusion과 Reverse 과정인 Denoising의 두 단계로 구성되며, Diffusion은 사전에 정의된 과정이며 Denoising은 학습을 통해 수행된다.

- Markov Chain

$$P[s_{t+1} | s_t] = P[s_{t+1} | s_1, \dots, s_t]$$

- Markov Chain이란 **Markov 성질**을 가지는 **이산 확률 과정**을 의미한다.
 - Markov 성질이란 "특정 상태의 확률(t+1)은 오직 바로 과거(t)의 상태에만 의존한다"는 특성이다.
→ ex) 내일의 날씨(t+1)은 오늘의 날씨(t)만 보고 예측할 수 있다.
 - 이산 확률 과정은 이산적인 시간 속에서 확률적으로 변화하는 현상을 설명한다.

1.2 Background

- 여기서는 2015년에 제안된 확산 확률 모델을 바탕으로, DDPM이 데이터를 노이즈로 변환하고 다시 복원하는 과정을 수식으로 살펴본다.

- Structure

- Diffusion model은 잠재변수 latent variable을 사용하는 생성모델로, 전체 확률 분포는 다음과 같이 정의된다.

$$p_{\theta}(x_0) := \int p_{\theta}(x_{0:T}) dx_{1:T}$$

여기서 $x_1, \dots, x_T$ 는 x_0 와 같은 차원의 잠재변수이며, $p_{\theta}(x_{0:T})$ 는 Reverse Process로 불린다.

- Reverse Process

- 학습된 가우시안 전이를 따르는 Markov chain으로 정의된다.

$$p_{\theta}(x_{0:T}) := p(x_T) \prod_{t=1}^T p_{\theta}(x_{t-1}|x_t), \quad p_{\theta}(x_{t-1}|x_t) := \mathcal{N}(x_{t-1}; \mu_{\theta}(x_t, t), \Sigma_{\theta}(x_t, t))$$

이때 $p(x_T) = \mathcal{N}(x_T; 0, I)$ 로 설정되며, 모델은 노이즈 상태 x_T 로부터 원본 x_0 을 복원하도록 학습된다.

- Forward Process

- Diffusion model이 다른 생성모델과 구분되는 이유는 고정된 Markov chain 형태의 Forward Process 를 사용하기 때문이다.

$$q(x_{1:T}|x_0) := \prod_{t=1}^T q(x_t|x_{t-1}), \quad q(x_t|x_{t-1}) := \mathcal{N}(x_t; \sqrt{1 - \beta_t}x_{t-1}, \beta_t I)$$

여기서 β_t 는 노이즈의 크기를 제어하는 variance schedule로 데이터에 점진적으로 가우시안 노이즈가 추가되는 과정을 의미한다.

- 학습은 변분추론을 기반으로 음의 Log likelihood를 최소화한다.

$$\mathbb{E}[-\log p_\theta(x_0)] \leq \mathbb{E}_q[-\log p_\theta(x_T)] - \sum_t \mathbb{E}_q \left[\log \frac{p_\theta(x_{t-1}|x_t)}{q(x_t|x_{t-1})} \right]$$

- 시점 t의 x_t 는 다음과 같이 계산되며

$$q(x_t|x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I), \quad \bar{\alpha}_t = \prod_{s=1}^t (1 - \beta_s)$$

- 손실함 L은 KL Divergence 형태로 정리된다.

$$L = \mathbb{E}_q \left[D_{KL}(q(x_T|x_0)||p(x_T)) + \sum_{t>1} D_{KL}(q(x_{t-1}|x_t, x_0)||p_\theta(x_{t-1}|x_t)) - \log p_\theta(x_0|x_1) \right]$$

2. Related Work

| 관련 연구 동향은 어떠한가?

- Flow-based Models

- Flow 모델은 **invertible transformation**을 이용해 데이터 분포를 직접 모델링한다.
 - 데이터 x_0 를 잠재 변수 z 로 바꾸는 정방향 함수와, 그 역함수를 통해 샘플을 생성할 수 있는 구조를 가진다.
 - 이때 로그 가능도(log-likelihood)를 명시적으로 계산한다.
 - 하지만 Flow 모델은 모든 변환이 invertible해야 하기 때문에 구조가 복잡하고 제약이 많으며 고해상도 이미지 생성에 불리하다.
- ↔ Diffusion 모델은 비가역적 확산 과정을 거쳐 복원함

- Variational Autoencoders (VAE)

- 잠재 공간 latent space을 학습해 데이터를 인코딩, 디코딩하는 구조의 대표적인 확률적 생성 모델이다.
 - 입력 데이터를 잠재 변수로 압축한 뒤 이를 다시 복원하는 과정에서 전체 데이터 분포를 근사한다.
 - VAE의 강점은 명시적인 확률적 추론 구조와 안정적인 학습이지만, 생성 결과가 흐릿하거나 디테일이 손실되는 문제가 있다.
- Diffusion은 이러한 VAE의 구조를 확장해 점진적인 노이즈 제거로 더 높은 품질의 복원을 달성

- Markov Chain 기반 모델

- 과거에는 확률적 전이 과정을 직접 학습하는 Markov Chain 계열 모델들이 연구되어 왔다. 대표적으로는
 - a. Infusion Training,
 - b. Variational Walkback,
 - c. Generative Stochastic Networks (GSN)
 등이 있다.
- 이들은 각 단계마다 데이터를 점진적으로 수정하며 진짜 데이터 분포에 가까워지도록 학습한다는 점에서 Diffusion 모델의 아이디어와 근본적으로 닮아 있다.
- 다만 기존 방식은 학습이 불안정하거나 샘플 품질이 낮은 경우가 많았다.

3. Method (제안 방법론)

| 연구 접근법과 모델 구조는 어떻게 되는가?

3. Diffusion models and denoising autoencoders

Main Idea

이미지를 생성하는 과정을 노이즈 제거' 문제로 바꿔, 무작위 노이즈에서 노이즈를 점점 없애면서 고품질 이미지를 복원해내자!

3.1 Forward Process and L_T

- Forward Process에서 β_t 는 학습 가능한 파라미터로 설정할 수도 있지만, 논문에서는 단순화를 위해 상수로 고정한다.
- 따라서 이 부분에서는 학습 대상이 없고, L_T (Forward Process의 마지막 항)은 상수 항으로 처리되어 무시할 수 있다.
→ 요약하자면, Forward 과정은 단순히 노이즈를 추가하는 고정 절차로 사용된다.

3.2 Reverse Process and $L_1 : t-1$

0. Distribution

$$p_{\theta}(x_{t-1}|x_t) = \mathcal{N}(x_{t-1}; \mu_{\theta}(x_t, t), \Sigma_{\theta}(x_t, t))$$

- DDPM에서는 Reverse에 $p_{\theta}(x_{t-1}|x_t)$ 를 가우시안 분포로 설정한다.
- 즉, 이전 단계의 이미지를 가우시안 분포로부터 샘플링하는데 이때 평균 μ 와 분산 Σ 는 모델이 학습으로 결정하는 값이다.

1. Variance

- 논문에서는 계산을 단순하게 하기 위해 분산 Σ 는 학습하지 않고 일정한 값(β_t 나 $\tilde{\beta}_t$)으로 고정했다. 이로써 학습의 핵심은 평균 $\mu_{\theta}(x_t, t)$ 을 어떻게 정의하고 예측하느냐에 달려 있다.

- 즉 분산은 고정하고 상수 취급되며, 평균이 학습 대상이 되는 구조이다.

2. Mean Parameterization

$$\mu_{\theta}(x_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_{\theta}(x_t, t) \right)$$

- 평균 $\mu_{\theta}(x_t, t)$ 를 직접 예측하면 계산이 복잡하기 때문에, DDPM은 평균을 **노이즈 예측 모델**로 바꿔서 표현한다.
- 즉, 모델이 "이미지에 섞인 노이즈(ϵ)"를 예측하도록 만들고, 그 예측값을 이용해 평균을 계산한다.
- 모델이 학습하는 건 이미지를 직접 복원하는 게 아니라, **각 단계에서 얼마나 노이즈를 제거해야 하는지(ϵ)를 맞추는 일**이라 할 수 있다.

3. Loss

$$L = \mathbb{E}_{x_0, \epsilon, t} [\|\epsilon - \epsilon_{\theta}(x_t, t)\|^2]$$

- 이렇게 되면 학습 목표는 모델이 예측한 노이즈와 실제 노이즈의 차이를 줄이는 것으로 단순해진다.
- 손실 함수는 위와 같이 MSE 형태로 표현되며, 모델은 주어진 이미지에서 노이즈를 얼마나 정확히 예측하는가를 기준으로 학습된다.

4. L_{simple}

$$L_{simple}(\theta) := \mathbb{E}_{t, x_0, \epsilon} [\|\epsilon - \epsilon_{\theta}(\sqrt{\alpha_t}x_0 + \sqrt{1 - \alpha_t}\epsilon, t)\|^2]$$

- DDPM은 실제 학습 시 이미지 데이터를 $[-1, 1]$ 범위로 스케일링해 처리하며, 마지막 복원 단계에서 이산적 디코더를 사용해 로그 가능도를 계산한다.
- 또한, 계산 효율성과 안정성을 위해 전체 변분 하한식을 단순화한 Simplified Training Objective (L_{simple})을 최종 학습식으로 사용한다.

4. Experiments (실험 및 결과)

4. Experiments

- DDPM은 총 $T=1000$ 단계로 실험을 진행했으며 각 단계마다 노이즈가 점진적으로 추가되고 제거되는 구조를 그대로 사용한다.
- 모델은 U-Net 기반 구조를 채택했고 학습의 안정성을 위해 Group Normalization과 Transformer positional embedding을 적용했다.

• Sample Quality



Figure 3: LSUN Church samples. FID=7.89




Figure 4: LSUN Bedroom samples. FID=4.90

Table 1: CIFAR10 results. NLL measured in bits/dim.

Model	IS	FID	NLL Test (Train)
Conditional			
EBM [11]	8.30	37.9	
JEM [17]	8.76	38.4	
BigGAN [3]	9.22	14.73	
StyleGAN2 + ADA (v1) [29]	10.06	2.67	
Unconditional			
Diffusion (original) [53]			≤ 5.40
Gated PixelCNN [59]			3.03 (2.90)
Sparse Transformer [7]			2.80
PixelIQN [43]	5.29	49.46	
EBM [11]	6.78	38.2	
NCSNv2 [56]		31.75	
NCSN [55]	8.87 ± 0.12	25.32	
SNGAN [39]	8.22 ± 0.05	21.7	
SNGAN-DDLS [4]	9.09 ± 0.10	15.42	
StyleGAN2 + ADA (v1) [29]	9.74 ± 0.05	3.26	
Ours (L , fixed isotropic Σ)	7.67 ± 0.13	13.51	≤ 3.70 (3.69)
Ours (L_{simple})	9.46 ± 0.11	3.17	≤ 3.75 (3.72)

- CIFAR-10 데이터셋을 기준으로, 생성된 이미지의 품질을 FID와 Inception Score로 평가했다.
- 그 결과, DDPM은 FID 3.17을 기록하며 기존 GAN 기반 모델들을 뛰어넘는 고품질 샘플 생성 성능을 보였다.

- 추가적으로 LSUN 데이터셋에서도 Church, Bedroom 등 고해상도 이미지를 생성하여

Diffusion 모델이 비조건적 이미지 생성에도 충분히 일반화됨을 확인했다.

• Reverse Process Parameterization & Training Objective Ablation

Table 2: Unconditional CIFAR10 reverse process parameterization and training objective ablation. Blank entries were unstable to train and generated poor samples with out-of-range scores.

Objective	IS	FID
$\bar{\mu}$ prediction (baseline)		
L , learned diagonal Σ	7.28 ± 0.10	23.69
L , fixed isotropic Σ	8.06 ± 0.09	13.22
$\ \bar{\mu} - \bar{\mu}_\theta\ ^2$	–	–
ϵ prediction (ours)		
L , learned diagonal Σ	–	–
L , fixed isotropic Σ	7.67 ± 0.13	13.51
$\ \bar{\epsilon} - \epsilon_\theta\ ^2 (L_{simple})$	9.46 ± 0.11	3.17

- Reverse 과정의 평균과 노이즈 예측 방식을 달리하며 학습 구조에 따른 품질 차이를 비교했다.
- 실험 결과, 복잡한 ELBO를 사용하는 것보다 단순한 MSE 기반의 L_{simple} 손실함수를 사용했을 때 더 안정적으로 학습되면서 샘플 품질이 향상되는 것으로 나타났다.
- 이를 통해 모델이 이미지를 직접 복원하기보다, 각 시점에서 얼마나 노이즈를 제거해야 하는지를 학습하는 방식이 실제 생성 품질에 더 효과적임을 보였다.

• Progressive Coding




Figure 5: Unconditional CIFAR10 test set rate-distortion vs. time. Distortion is measured in root mean squared error on a $[0, 255]$ scale. See Table 4 for details.



Figure 6: Unconditional CIFAR10 progressive generation ($\hat{x}_0$ over time, from left to right). Extended samples and sample quality metrics over time in the appendix (Figs. 10 and 14).



Figure 7: When conditioned on the same latent, CelebA-HQ 256×256 samples share high-level attributes. Bottom-right quadrants are x_t , and other quadrants are samples from $p_\theta(x_0|x_t)$.

- Diffusion 모델의 생성 과정을 **rate distortion** 관점에서 분석했다.
- DDPM은 lossless에서도 이미지는 높은 품질을 유지했고, 비트율이 낮아질수록 눈에 거의 띄지 않는 세부 정보만 조금씩 사라졌다.
- 또한, 점진적으로 해상도를 복원하는 **Progressive generation** 실험을 했을 때 초반에는 전체 윤곽이 먼저 나타나고 뒤로 갈수록 질감과 디테일이 점점 채워지는 흐름이 보였다.
- DDPM은 단순히 이미지를 만들어내는 모델이라기보다 정보를 효율적으로 압축하고 복원하는 구조로 볼 수 있다.

• Interpolation



Figure 8: Interpolations of CelebA-HQ 256x256 images with 500 timesteps of diffusion.

- 두 개의 이미지를 섞어서 중간 단계를 만들어보는 interpolation 실험을 진행했다.
- Diffusion 모델은 두 이미지 사이를 선형으로 연결했을 때 그 중간 과정이 부드럽고 자연스럽게 이어졌다. 얼굴의 표정, 각도, 조명 같은 세부 변화가 어색하지 않고 하나의 연속된 이미지처럼 흘러가는 것을 확인할 수 있다.

- 이런 패턴을 볼 때 Diffusion 모델은 단순히 이미지를 연결하고 복원하는 것이 아니라 그 사이의 공간적 의미까지 이해하며 학습함을 알 수 있다.

5. Conclusion

| 결론 및 주요 요약은?

- DDPM은 “이미지를 직접 생성한다”는 기존 방식과 달리, 노이즈를 제거하는 과정을 학습함으로써 이미지를 복원하는 새로운 관점을 제시했다.
- 이 단순한 아이디어를 기반으로, 고품질 이미지 생성 성능을 달성했으며 Markov chain, Score Matching, Langevin dynamics 등 다양한 확률적 접근과도 연결된다는 것을 보였다.
- Diffusion은 특히 이미지 도메인에서 강력한 표현력을 가지며 향후 다른 데이터 형태나 생성 모델로 확장될 잠재력을 보여준다.