

Introduction

- 생성 task에 있어서, GAN뿐만 아니라 다른 모델들도 그에 필적하는 수준의 결과를 내기 시작함.
- 그 중, diffusion model은 정의하기 간단하고 학습도 효율적이었지만, 고품질 샘플을 생성할 수 있다는 증거가 없었음.
- 따라서 이 논문에서는 다음과 같은 지점에서 GAN이 가지지 못한 이론적 강점을 제시.
 - lossy compression 관점에서 log-likelihood가 낮더라도 모델이 좋을 수 있음을 보임.
 - progressive decoding을 통해 autoregressive decoding을 일반화.

Diffusion models and denoising autoencoders

- input에 noise를 입히는 **noising**, 노이즈를 제거하며 데이터를 생성하는 **denoising** 과정으로 나뉨.
- 기존 state가 X_{t-1} , 다음 state가 X_t 일 때, $p_\theta(X_{t-1}|X_t)$ 가 $q(X_{t-1}|X_t)$ 를 근사하도록 학습 : $\log p_\theta(x)$ 의 연산이 어렵기 때문.
 - → ELBO (Evidence Lower Bound)로 근사하여 loss를 구함.
- Noising, Denoising 과정은 여러 개의 Markov Chain으로 구성.
 - → Denoising score matching : noise를 제거하는 신경망을 학습시키는 방식.

Forward process

- Linear Scheduling을 통해 gaussian noise의 크기를 변화하며 주입.
- 데이터를 점차 가우시안 분포로 변형시켜 최종적으로 pure noise로 만듦.

Reverse process

- Forward process의 역과정, gaussian noise를 제거해가며 특정한 패턴을 만듦.
- 위에서 말한 신경망이 노이즈를 예측 후, 해당 노이즈를 빼 원래 데이터와 유사해지도록 함.

Data scaling, reverse process decoder

1. scaling : 0~255값을 -1~1 범위로 변형.
2. 픽셀 데이터 : 이산 데이터 -> 를 Gaussian의 적분 구간을 설정해 이산화 처리
3. loseless codelength
 - 데이터에 인위적으로 노이즈를 더하거나 복잡한 수학적 보정을 하지 않아도 최적의 codelength를 학습함.
4. sampling 종료 후 평균값을 픽셀로 출력.

Simplified training objective

- 앞서 정의한 reverse process와 decode을 통해 다음과 같은 목적 함수를 정의할 수 있음.

$$L_{\text{simple}}(\theta) := \mathbb{E}_{t, \mathbf{x}_0, \boldsymbol{\epsilon}} \left[\left\| \boldsymbol{\epsilon} - \boldsymbol{\epsilon}_{\theta}(\sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}, t) \right\|^2 \right]$$