

GAN

↗ 상위 작업	📖 세션 논문 리뷰
↗ 하위 작업	<u>GAN 발제 대본</u>
⚙ 진행 상태	완료
📎 첨부 파일	<u>GAN.pdf</u>

0. Abstract

1. Introduction

1.1 Background

1.2 Introduction

2. Related Work

3. Method (제안 방법론)

3.1 Adversarial Nets

3.2 Theoretical Results

4. Experiments (실험 및 결과)

5. Conclusion

0. Abstract

| 어떤 문제를 해결하려 했는가?

- 본 논문은 생성 모델을 추정하기 위한 새로운 프레임워크로 적대적 신경망(Adversarial Nets)을 제안하였다.
- 생성 모델 G와 판별 모델 D를 동시에 학습하며, G는 데이터 분포를 포착하고 D는 표본이 실제 데이터인지 G가 만든 데이터인지 판별하였다.
- G의 학습 목표는 D가 실수를 하도록 확률을 높이는 것이며, 이는 미니맥스 게임 구조로 설명된다.
- 임의의 함수 공간에서 유일한 해가 존재하며, 이때 G는 실제 데이터 분포를 복원하고 D는 모든 지점에서 1/2 값을 출력하게 된다.
- 제안된 방법은 기존의 생성 모델 학습에서 필요했던 마르코프 체인이나 복잡한 근사 추론 네트워크를 배제할 수 있다는 점에서 단순하고 효율적이다.

1. Introduction

| 연구 동기와 문제점은 무엇인가?

1.1 Background

- Generative VS Discriminative

- 지금까지 딥러닝의 성과는 주로 판별 모델에 집중되었다.
→ 입력 데이터를 특정 클래스에 맞게 분류하는 방식으로 이미지·음성·언어 등 다양한 영역에서 성과를 보였다.
- 생성 모델은 계산 복잡성과 학습의 어려움 때문에 상대적으로 발전이 더뎠다. 확률적 계산이 까다롭고, 기존 방법으로는 효율적으로 학습하기 힘들었기 때문이다.
 1. 우도(likelihood) 계산의 난이도
→ 고차원 데이터의 확률분포 $P(x)$ 를 직접 계산하거나 적분해야 하는데, 이는 수학적으로 폐쇄형 해가 존재하지 않고 계산량이 기하급수적으로 늘어나 매우 어렵다.
 2. 근사 추론 필요
→ 변분추론이나 MCMC 같은 근사 기법으로 이를 해결하려 했지만, 계산 비용이 지나치게 크고 수렴도 느려서 딥러닝 규모의 대규모 모델 학습에는 큰 병목이 된다.
 3. 비선형성 문제
→ 생성 모델은 다층 비선형 변환으로 구성되어 있어 확률 분포를 단순하게 표현할 수 없고, 결국 복잡한 수치적 근사 계산에 의존해야 하는 한계가 있다.
- 따라서 생성 모델 연구에는 이러한 한계를 넘을 수 있는 새로운 접근이 필요했다.

1.2 Introduction

- Adversarial nets

- GAN은 생성 모델(G)과 판별 모델(D)을 서로 경쟁시키는 구조를 제안하였다.
- G는 실제와 구분되지 않는 데이터를 만들려고 하고, D는 그것이 진짜인지 가짜인지 판별하려고 한다.

- 이 경쟁은 양쪽 모델을 동시에 발전시키며, 결국 가짜 데이터가 실제 데이터와 거의 구별되지 않게 된다.
- 중요한 점은, 이 과정이 복잡한 확률 계산이나 근사 추론 없이, 단순히 역전파와 표준 신경망만으로 가능하다는 것이다.
- 따라서 GAN은 기존 생성 모델의 계산적 한계를 극복하는 새로운 학습 패러다임으로서 의미가 있다.

2. Related Work

| 관련 연구 동향은 어떠한가?

- RBM/DBM 계열
 - Restricted Boltzmann Machine(RBM), Deep Boltzmann Machine(DBM) 등은 생성 모델의 초기 시도로 의미가 있었으나, MCMC 기반 샘플링에 의존해야 해 학습이 느리고 비효율적이었다.
 - MCMC(Markov Chain Monte Carlo): 복잡한 확률분포에서 직접 샘플링하기 어려울 때, 확률 상태가 순차적으로 전이되는 마르코프 체인을 이용해 복잡한 분포로부터 샘플을 근사적으로 얻는 방법
- Autoencoder 계열
 - Denoising Autoencoder, Contractive Autoencoder 등이 등장하며 확률분포 근사에 활용되었지만, 여전히 제한적 근사 방법에 머물러 확률 계산의 복잡성을 완전히 해소하지는 못했다.
- VAE (Variational Autoencoder)
 - VAE는 변분추론을 통해 복잡한 확률 계산을 ELBO 최적화 문제로 단순화하였다.
 - 그러나 여전히 우도의 근사 계산에 의존해야 하고, 이로 인해 생성 품질이 제한적이었다.
 - 또, Gaussian 등의 잠재변수 분포를 가정해야 해서 모델링 유연성이 떨어졌다.
- GAN
 - **GAN은 판별자와 생성자의 적대적 게임 구조로 이런 확률 근사 과정을 아예 우회하여 데이터 분포를 학습할 수 있다.**

- 따라서 우도를 계산하거나 근사하지 않아도 단순 역전파만으로 고품질의 샘플 생성이 가능했다.
- 결과적으로 GAN은 VAE가 가진 한계를 극복하면서, 생성 모델 연구에 새로운 패러다임을 제시했다.

3. Method (제안 방법론)

| 연구 접근법과 모델 구조는 어떻게 되는가?

Main Idea

복잡한 확률 계산이나 근사 추론 대신, 생성자와 판별자를 동시에 학습시키는 미니맥스 게임으로 데이터 분포를 추정하자!!

3.1 Adversarial Nets

$$\min_G \max_D V(D, G) = \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_{\mathbf{z}}(\mathbf{z})} [\log(1 - D(G(\mathbf{z})))]$$


- 왼쪽 항 : 실제 데이터 분포에서 샘플링된 $\mathbf{x} \rightarrow D$ 는 이를 진짜(1)로 분류하도록 학습한다.
- 오른쪽 항 : 노이즈 $\mathbf{z}$ 를 통해 생성된 가짜 데이터 $\rightarrow D$ 는 이를 가짜(0)로 분류하도록 학습한다.
- 이때 Generator와 Discriminator의 관점 차이가 발생한다.
 - Discriminator(D) : 전체 수식을 maximize하는 입장이다. (진짜는 1, 가짜는 0)
 - Generator(G) : 오른쪽 항에만 관여하며, D가 가짜를 진짜(1)라고 속이도록 학습한다. 결국 수식을 minimize하는 입장이다.
 - 결과적으로 G와 D는 minimax 게임을 수행한다.

$$\max_G \mathbb{E}_{z \sim p_z(z)} [\log D(G(z))]$$

- 이때 학습 초반 G의 성능이 낮을 때, D는 가짜 데이터를 너무 쉽게 구별해 $D(G(z)) \approx 0$ 이 된다.
- 이 경우 $\log(1 - D(G(z)))$ 항이 saturate되어 gradient가 거의 0이 되면서, G가 배워야 할 신호가 사라진다.

→ **Gradient Vanishing 문제**

- $\log(1 - D(G(z)))$ 대신 $\log D(G(z))$ 를 maximize하도록 바꾸면, 초반에도 gradient가 크게 주어져 안정적인 학습이 가능하다.



GAN이 데이터 분포를 recover하는 과정

a. 초기

- G 분포가 실제와 크게 다르며 D는 쉽게 구별한다.
- 이때 z라는 저차원 latent space에서 uniform/normal 분포로 샘플링이 이루어지고, G는 이를 복잡한 데이터 공간 x로 매핑한다.

b. 학습 중

- D는 실제 분포를 기준으로 구별을 강화한다.
- 파란 점선(D)의 값이 위로 클수록 "진짜일 것이다", 아래로 내려갈수록 "가짜일 것이다"라고 판별하는 과정을 나타낸다.

c. G 분포 수렴 진행

- G가 점차 실제 분포를 따라가면서 D는 점점 구별하기 어려워진다.
- 이 과정은 GAN이 implicit 모델이기 때문에, 노이즈 분포 자체를 직접 정의하기보다는 단순 분포에서 샘플링 후 학습을 통해 복잡한 분포를 근사하는 구조를 보여준다.

d. 수렴

→ $p_g \approx p_{data}$, D의 출력이 1/2로 수렴해 진짜와 가짜 구분이 불가능해진다.

→ 논문에서는 모델 capacity가 충분하다면 GAN이 실제 데이터 분포를 recover할 수 있다고 언급한다.

3.2 Theoretical Results

global optimality of GAN

$$D^*(x) = \frac{P_{data}(x)}{P_{data}(x) + P_g(x)}$$

Proof.

$$\begin{aligned} \min_G \max_D V(D, G) &= \mathbb{E}_{x \sim p_{data}(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))] \\ D^*(x) &= \arg \max_D V(D) = \mathbb{E}_{x \sim p_{data}(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))] \\ E[X] &= \int_{-\infty}^{\infty} x f(x) dx \\ &= \mathbb{E}_{x \sim p_{data}(x)} [\log D(x)] + \mathbb{E}_{x \sim p_g(x)} [\log(1 - D(x))] \\ &= \int_x p_{data}(x) \log D(x) dx + \int_x p_g(x) \log(1 - D(x)) dx \\ &= \int_x [p_{data}(x) \log D(x) + p_g(x) \log(1 - D(x))] dx \\ &= \arg \max_D [p_{data}(x) \log D(x) + p_g(x) \log(1 - D(x))] \end{aligned}$$

Fix G to make it to a function of D

sampling x from p_g instead of sampling z from p_z

global optimality of GAN

$$D^*(x) = \frac{P_{data}(x)}{P_{data}(x) + P_g(x)}$$

$$D^*(x) = \arg \max_D [p_{data}(x) \log D(x) + p_g(x) \log(1 - D(x))]$$


The function inside integral

$$= a \log y + b \log(1 - y)$$

substitute $a = p_{data}(x), b = p_g(x), y = D(x)$

$$\frac{a}{y} + \frac{-b}{1-y} = \frac{a - (a+b)y}{y(1-y)}$$

Differentiate with respect to D(x)



$$\begin{aligned} D^*(x) \text{ 미분} &= a \log y + b \log(1-y) \text{ 미분} = 0 \\ \frac{a}{y} + \frac{-b}{1-y} &\rightarrow \frac{a - ay - yb}{y(1-y)} \rightarrow \frac{a - (a+b)y}{y(1-y)} = 0 \\ &\rightarrow y = \frac{a}{a+b} \end{aligned}$$

Value function을 maximization 할 수 있는 지를 찾기 위해서는 "a log y + b log(1-y)" 함수를 미분했을 때, 0이 나오는 값이 V(D) 함수의 최대값이 됩니다 (V(D) 함수는 concave이기 때문).

a/(a+b)에서 global optimum을 가짐

- 증명의 목표
: Discriminator D 의 최적해 $D^*(x)$ 가 존재함을 보이는 것.
- 흐름
 1. Generator G 를 고정하고, $V(D, G)$ 를 D 에 대해 최적화
 2. 가짜 분포 p_z 를 p_g 로 치환하여, 기대값을 x 공간에서 적분 형태로 표현
→ 이 적분은 x 별로 독립적으로 최적화할 수 있는 구조이므로, 항을 점별(point-wise)로 살펴봄
 3. $a = p_{data}(x), b = p_g(x), y = D(x)$ 로 치환하여 y 에 대해 미분까지 진행하면 $y = a/(a+b)$ 에서 미분값이 0이 되어 극값을 얻음
 4. 이때 이 함수는 $0 < y < 1$ 범위에서 concave하기 때문에, 구한 해가 전역 최댓값이

global optimality of GAN (2)

Global optimum point is $p_g = p_{data}$

Proof.

$$\begin{aligned}
 C(G) &= \max_D V(G, D) = \mathbb{E}_{x \sim p_{data}(x)} [\log D^*(x)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D^*(G(z)))] \\
 &= \mathbb{E}_{x \sim p_{data}(x)} \left[\log \frac{p_{data}(x)}{p_{data}(x) + p_g(x)} \right] + \mathbb{E}_{x \sim p_g(x)} \left[\log \frac{p_g(x)}{p_{data}(x) + p_g(x)} \right] \\
 &= \mathbb{E}_{x \sim p_{data}(x)} \left[\log \frac{2 \cdot p_{data}(x)}{p_{data}(x) + p_g(x)} \right] + \mathbb{E}_{x \sim p_g(x)} \left[\log \frac{2 \cdot p_g(x)}{p_{data}(x) + p_g(x)} \right] - \log 4 \\
 &= KL \left(p_{data} \parallel \frac{p_{data} + p_g}{2} \right) + KL \left(p_g \parallel \frac{p_{data} + p_g}{2} \right) - \log 4 \\
 &= 2 \cdot JSD(p_{data} \parallel p_g) - \log 4
 \end{aligned}$$

$D^*(x) = \frac{p_{data}(x)}{p_{data}(x) + p_g(x)}$
 • $p_g = p_{data}$ 일 때 global minimum을 가짐
 • JSD는 항상 0 이상이며, 두 분포가 같을 때만 0이 됨
 • 그때의 $C^* = -\log 4$
 • 이 조건을 만족할 때 generator가 데이터 생성 과정을 완벽히 복제할 수 있음

Basic properties of log
 $KL(p_{data} \parallel p_g) = \int_{-\infty}^{\infty} p_{data}(x) \log \left(\frac{p_{data}(x)}{p_g(x)} \right) dx$
 $JSD(p \parallel q) = \frac{1}{2} KL \left(p \parallel \frac{p+q}{2} \right) + \frac{1}{2} KL \left(q \parallel \frac{p+q}{2} \right)$

- 증명의 목표
: $D^*(x)$ 를 목적함수에 대입했을 때, $p_g = p_{data}$ 일 때 global optimum이 성립함을 보이는 것.

- 흐름
 1. 앞에서 구한 최적 판별자 $D^*(x)$ 를 목적함수에 다시 대입
 2. 로그 항 정리를 위해 log 안에 2를 곱해주고 log4를 빼는 방식으로 식 변형
 3. 이렇게 정리된 항은 KL divergence 두 개의 합으로 표현됨
 4. 두 KL divergence를 묶으면 Jensen-Shannon Divergence(JSD) 형태로 바뀜

5. JSD는 항상 0 이상이고 두 분포가 동일할 때만 0이 되므로, $p_g = p_{data}$ 일 때 목적 함수 값은 $-\log 4$ 가 되어 global optimum이 성립함

4. Experiments (실험 및 결과)

실험 구성과 결과는?

Model	MNIST	TFD
DBN [3]	138 ± 2	1909 ± 66
Stacked CAE [3]	121 ± 1.6	2110 ± 50
Deep GSN [6]	214 ± 1.1	1890 ± 29
Adversarial nets	225 ± 2	2057 ± 26

Table 1: Parzen window-based log-likelihood estimates. The reported numbers on MNIST are the mean log-likelihood of samples on test set, with the standard error of the mean computed across examples. On TFD, we computed the standard error across folds of the dataset, with a different σ chosen using the validation set of each fold. On TFD, σ was cross validated on each fold and mean log-likelihood on each fold were computed. For MNIST we compare against other models of the real-valued (rather than binary) version of dataset.

- GAN은 MNIST, TFD, CIFAR-10 데이터셋에서 실험을 진행했다. 생성자는 ReLU와 sigmoid 활성화를 사용했고, 판별자는 maxout을 적용했으며 dropout은 판별자에만 적용되었다.
- GAN은 생성 분포를 명시적으로 쓸 수 없기 때문에 직접 likelihood 계산이 불가능하다. 따라서 논문에서는 **Parzen Window 기반 log-likelihood 추정**을 사용하였다. 샘플 주변에 Gaussian 커널을 두어 밀도를 근사하고, 그 위에서 테스트 데이터의 log-likelihood를 평가하는 방식이다.
- 실험 결과, GAN은 MNIST에서 가장 뛰어난 성능을 보였고 TFD에서는 Stacked CAE가 더 높았지만 GAN 역시 경쟁력 있는 결과를 냈다.
→ 이는 초기 GAN의 학습 안정성 한계 때문으로 해석됨




Figure 2: Visualization of samples from the model. Rightmost column shows the nearest training example of the neighboring sample, in order to demonstrate that the model has not memorized the training set. Samples are fair random draws, not cherry-picked. Unlike most other visualizations of deep generative models, these images show actual samples from the model distributions, not conditional means given samples of hidden units. Moreover, these samples are uncorrelated because the sampling process does not depend on Markov chain mixing. a) MNIST b) TFD c) CIFAR-10 (fully connected model) d) CIFAR-10 (convolutional discriminator and “deconvolutional” generator)

a. MNIST

- 새로운 숫자 샘플을 잘 생성했으며 단순 암기는 아니었음을 확인할 수 있다.

b. TFD

- 얼굴 이미지를 자연스럽게 생성했으나 완벽히 선명하진 않았다.

c. CIFAR-10 (Fully connected)

- 자연 이미지와 같은 복잡한 데이터에서는 결과가 흐릿하고 구분이 어려웠다.
- 이는 fully connected 구조가 고해상도·고복잡도 데이터 학습에는 한계가 있음을 보여준다.

d. CIFAR-10 (Conv + Deconv)

- convolutional discriminator와 deconvolutional generator를 적용했을 때 이미지 품질이 개선되었다.
- 배경과 객체 형태가 조금 더 뚜렷해졌으며, CNN 기반 구조의 필요성을 확인할 수 있었다.



Figure 3: Digits obtained by linearly interpolating between coordinates in z space of the full model.

- GAN의 latent space는 Generator의 입력 노이즈 z 가 존재하는 공간으로, 잘 학습되면 z 에서의 작은 변화가 이미지 공간에서도 자연스러운 변화를 만든다.
- Figure 3은 두 점을 z -space에서 선형 보간했을 때 숫자가 매끄럽게 변하는 모습을 보여주며, GAN이 잠재공간을 부드럽게 학습했음을 시각적으로 증명한다.

5. Conclusion

결론 및 주요 요약은?

- GAN은 단순한 생성 모델을 넘어 다양한 확장 가능성을 가진다는 점에서 의의가 크다.
- 조건부 입력을 활용한 conditional GAN, auxiliary network를 통한 추론 보조, semi-supervised 학습, 그리고 학습 효율 개선 등 여러 방향으로 발전할 수 있음을 논문은 제안한다.
- 이러한 가능성들은 GAN이 강력한 adversarial modeling framework로서 미래 연구에 중요한 토대가 될 수 있음을 보여준다.