



GPT-1 : Improving Language Understanding by Generative Pre-Training

■ 생성일	@2025년 9월 10일 오후 5:34
■ 태그	Done

1. Reference

Introduction

BOAZ Session

GPT

transformer framework

Conclusion

Limitations

1. Reference

<https://mountain96.tistory.com/40>

Introduction

- 적은 labeled 텍스트와 많은 unlabeled 텍스트로 인한 어려움을 해결하기 위해 등장
 - **다양한 unlabeled 텍스트로 language model을 generative하게 pretraining**하고, 각 작업에 맞게 fine-tuning 시킨다.
 - 실제로 많은 작업에서 기존 작업에 특화된 모델보다 더 좋은 성능을 보였음
-
- unlabeled text에서 단어 수준의 정보 이상을 이용하는 것이 어려운 2가지 이유?
1. transfer에 유용한 text 표현을 배우는 것에 어떤 형태의 optimization objective(최적화 목적)이 가장 좋은지 불분명하기 때문

2. 이렇게 학습된 표현들을 목표 작업(target task)으로 transfer 시키는 가장 효과적인 방법이 불분명하기 때문

⇒ 이러한 불분명성은 semi-supervised learning을 더 어렵게 만들었음

- 비지도 pre-training과 지도 fine-tuning을 조합한 NLP에 대한 semi-supervised learning을 제시
 - 다양한 작업에 사용될 수 있으면서도 약간의 변화(adaptation)로 transfer할 수 있는 “보편적인 표현”들을 학습하는 것!
 - 즉, 이를 위해서는 대량의 unlabeled text corpus와 목표 작업을 위한 labeled 데이터셋이 필요 ⇒ unlabeled와 labeled data가 꼭 같은 도메인에 속할 필요 x

- 이를 위해 다음 2가지 과정을 만들었음

1. unlabeled data + language modeling objective → 초기 파라미터 학습
2. labeled data + 초기 파라미터들을 주어진 목표 작업에 맞게 조금씩 수정(fine-tune)

- 사용한 모델 구조 → transformer
 - 기계 번역, 문서 생성, 구문 분석에 효과
 - long-term 데이터에 대해서도 기존 RNN이나 LSTM과 같은 모델들보다 훨씬 robust하게 작동
 - transfer 시에는 traversal-style approaches 에서 사용된 task에 특정한 input adaptation을 사용
 - task마다 요구하는 input text가 다양한데, 이를 연속적인 싱글 시퀀스로 변환하여 즉 task에 맞는 fine-tuning을 위해서 pre-trained 모델의 출력을 변형시킨 것이라고 보면 됨
 - ⇒ pre-trained 모델의 출력만 바뀌어도 다양한 작업에 파인튜닝이 가능하다!
- 4 languages understanding tasks — natural language inference, question answering, semantic similarity, text classification
 - 총 12개 작업 중 9개 작업에서 작업에 특화된 기존 모델들보다 높은 성능을 보였음

- unlabeled data에서 학습하는 것은 실용적인 측면과 성능적인 측면에서 모두 중요하다.
 - 그러나 이는 유용한 text 표현을 배우기 위한 최고의 Optimization Objective와 목표 작업으로 transfer시키는 최고의 효과적인 방법이 불분명하기 때문에 어렵다.
 - 본 논문에서는 Unsupervised pre-training과 Supervised fine-tuning을 사용하는데, 이는 unlabeled data로 language model을 만들고, 이를 통해 얻은 결과물을 각 작업에 맞는 labeled data를 사용하여 fine-tuning한다.
 - 모델 구조로는 Transformer를 사용하며, language model 에서 fine-tuning으로 넘어가는 시점에서 language model의 출력을 원하는 작업에 맞는 input으로 변형하여 넘겨준다.
-

BOAZ Session

<before GPT>

1. word2vec

- 단어를 연속적인 저차원 벡터로 표현해 단어 간 의미적, 문법적 관계를 포착할 수 있음을 보여줌 ⇒ 벡터 연산으로 단어 간 관계를 설명할 수 있음
- 단어마다 고정 벡터이기 때문에 문맥에 따른 의미 변화 반영 불가
 - 단어 표현까지만 제공

2. Seq2seq + attention

- seq2seq → 고정 벡터 병목 현상 발생
 - attention → 어느 부분에 주목하면 좋을 지를 계산하여 고정 벡터의 병목을 해소

3. Transformer

- RNN
- ELMo
 - word2vec 같은 정적 임베딩은 문맥에 따른 의미 변화를 담지 못함

- 문맥에 따라 동적으로 변하는 임베딩이 필요!

GPT

- 판별형 & 생성형 concept
- 사후 확률만을 판별하기 때문에 사실상 판별 모델에 더 가깝지만, 이미지나 글을 새롭게 생성할 수 있기 때문에 생성 모델이라고 부를 수 있음
- Pre-trained
- 라벨 데이터의 부족 ⇒ Generative pre-training + discriminative fine-tuning
- unsupervised pre-training
- 1. 임베딩의 발전
 - a. 단어 수준의 임베딩 → 문장 단위 임베딩 ⇒ 더 자연스러운 사전학습과 미세조정 가능
- 2. 기존 연구들의 결과
- 3. 작업 인지 입력 변환
- 4. transformer 사용
- 준지도학습 : 라벨 데이터와 비라벨데이터 둘 다 가지고 학습하는것
 - ex) generative pre-training + discriminative fine-tuning (GPT)
- 준지도학습의 문제 : 1. 학습 목표 설정
 - 후보군 3개 중 GPT는 언어모델링(LM)을 선택함!
- 준지도학습의 문제 : 2. transfer 방식 문제
 - 작업 특화 변경, 복잡한 학습 방식, 보조 학습 목적

transformer framework

- context vector
- positional encoding
- masked multi-head attention

<supervised fine-tuning>

start, delim, extract와 같은 벡터들만 임베딩하면 되기 때문에 다른 모델에 비해서 더 간단하다. ⇒ 언어 모델링을 선택한 이유가 이것이라고 생각

Q. 실제로 GPT를 이용한 실험 결과?

<unsupervised pre-training>

- dataset : bookcorpus ⇒ 책은 길고 연속적인 텍스트이기 때문에 생성 모델이 긴 context를 잘 학습할 수 있도록 함
 - GELU : ReLU와 비슷한데 조금 더 수학적으로 조정된 활성화 함수
- Natural language inference
 - 사용한 모든 dataset에서 SOTA
- Question answering & commonsense reasoning
 - 모델이 긴 맥락을 잘 다룬다.
- Semantic similarity
- classification

Q. Analysis

- pre-training의 layer를 많이 가져올 수록 fine-tuning의 결과도 좋아짐
 - → pre-training model에서 학습된 정보들이 target task를 푸는 데 도움이 된다는 걸 알 수 있음.

<Zero-shot behaviors>

왜 pre-training이 효과적인지 알아보기 위해 가설을 세움

생성 모델이 많은 task를 수행할 수 있는 능력을 자연스럽게 학습함

구조적인 attention memory가 지식 전이에 더욱 효과적fine tuning 없이 모델이 task를 수행 → training할 수록 결과가 좋아짐.

반대로 LSTM은 결과가 튀면서 **transformer 구조가 전이에 더 유리함**을 밝힘.

<ablation studies>

- 데이터가 큰 경우에는 성능이 좋았지만 반대로 데이터셋이 작은 경우에는 오히려 안 좋았음
- LSTM과 비교했을 때 트랜스포머 사용했을 때가 더 좋았다~ ⇒ GPT가 더 좋다
- pre-training의 중요성을 확인할 수 있었음

Conclusion

generative pre-training + discriminative fine-tuning 이 효과적이라는 것을 보임.

특히, *많은 양의 연속적인 텍스트를 학습*하는 것이 세상에 대한 지식과 장기 의존성을 처리하는 데 필요한 능력을 얻게 하고 discriminative task로 그 지식이 잘 transfer 되었을 때, 효과적임을 알 수 있었음.

이러한 큰 성능 향상이 실제로 실현 가능하다는 것을 이 연구를 통해 보였고, 이를 위해서는 transformer와 장기 의존성을 가진 텍스트가 가장 적합함을 보임.

Limitations

- 모델 규모의 한계
- 사전학습을 했음에도 결과적으로는 파인튜닝이 필요하다는 단점 ⇒ 일일이 라벨링하는 supervised 단계가 필요하다는 점이 한계
- **후속 모델: GPT-2**
 - 하나의 task에 대해 집중적으로 supervised learning해서 expert가 된 잘하는 모델들이 많은데, 한계를 갖고 있다!
 - 기존의 도메인이 아닌 다른 분야의 데이터가 들어올 때 결과가 이상
 - 다른 task를 위해서는 구조 변경이나 파인 튜닝이 필요
 - multitask가 가능한 모델의 필요성 강조

- **파라미터나 구조 변경 없이도 zero-shot 환경에서 language model이 잘 수행할 수 있다는 걸 보여주는 것이 이 모델!**

1. 모델 크기 커짐
2. 방대한 규모의 데이터셋 사용
3. Zero-shot 성능 향상, 방대한 규모의 데이터셋 사용 (직접 웹페이지를 크레이핑함), Zero-shot 성능이 향상되어서 별도의 파라미터 변경 없이 구조 변경 없이도 잘함

- **후속 모델 : GPT-3**

1. 모델 크기가 더 커짐
 2. 더 방대한 텍스트 사용 : 570GB 분량의 filtering된 Common Crawl + WebText2, 책 데이터 (Books1, Books2), 위키피디아
 3. in-context learning 성능의 발전
- 파인튜닝이 아니라 프롬프트를 줘서 그걸로 무엇을 해야하는 건지 모델이 이해하도록 하는게 in-context!!
 - 어떤 task를 수행하도록 지시만 주거나(**Zero-shot**), 하나의 예시를 주거나 (**One-shot**), 여러 예시를 주는 방식. (**Few-shot**) 모델에게 어떤 task를 수행하도록 자연어 prompt를 주는 것 만으로, 그 의미를 스스로 이해해서 fine-tuning 이나 구조 변화 없이 작업을 잘 수행.