

SAM

↗ 상위 작업	📖 세션 논문 리뷰
⚙ 진행 상태	완료
📎 첨부 파일	SAM.pdf

[0. Abstract](#)

[1. Introduction](#)

[2. Related Work](#)

[3. Method \(제안 방법론\)](#)

[3.1 Task](#)

[3.2 Model](#)

[3.3 Data](#)

[4. Experiments \(실험 및 결과\)](#)

[5. Conclusion](#)

0. Abstract

| 어떤 문제를 해결하려 했는가?

- 저자들은 Segment Anything(SA) 프로젝트를 소개하며, 새로운 태스크와 모델, 그리고 대규모 데이터셋을 제안했다.
- 효율적인 모델을 활용해 데이터 수집 루프를 만들었고, 11M장의 이미지에 대해 10억 개가 넘는 마스크를 포함한 사상 최대 규모의 segmentation 데이터셋(SA-1B)을 구축했다.
- SAM은 promptable하게 설계되어 포인트나 박스 같은 입력만으로도 다양한 객체를 segmentation할 수 있으며 새로운 분포와 과제에도 zero-shot으로 잘 일반화되었다.
- 다양한 벤치마크 실험에서 SAM은 기존 fully supervised 방법과 경쟁하거나 오히려 뛰어난 성능을 보여주었고, 공개된 모델과 데이터셋은 foundation model 연구를 뒷받침할 자원으로 의미를 가진다.

1. Introduction

| 연구 동기와 문제점은 무엇인가?

- 최근 NLP에서는 web-scale 데이터셋으로 학습된 LLM들이 zero-shot, few-shot 성능을 보여주며 foundation model의 가능성을 입증했다. Vision 분야에서도 CLIP, ALIGN 같은 모델들이 등장했지만, image segmentation을 위한 foundation model은 존재하지 않았다.
- 논문의 목표는 image segmentation을 위한 foundation model을 구축하는 것이다. 이를 위해 세 가지 질문이 중요하다.
 - **Task** – “What task will enable zero-shot generalization?”
 - 저자들은 promptable segmentation task를 정의한다.
 - 다양한 형태의 prompt(점, 박스, 텍스트)에 대응하고 모호할 경우 여러 개의 valid mask를 반환하도록 설계되었다.
 - **Model** – “What is the corresponding model architecture?”
 - 모델은 image encoder + prompt encoder + mask decoder 세 부분으로 구성된다.
 - 이미지 임베딩을 재사용할 수 있고 50ms 이내에 마스크를 생성할 정도로 빠르다. 또한 flexible prompting과 실시간 활용을 지원한다.
 - **Data** – “What data can power this task and model?”
 - 기존에는 segmentation을 위한 web-scale 데이터셋이 부족했기 때문에 새로운 data engine을 구축했다.
 - 수작업 보조(assisted manual) → 반자동(semi automatic) → 완전 자동(fully automatic) 단계를 거쳐 대규모 마스크를 생성했고 최종적으로 SA-1B (11M 이미지, 1B 마스크)를 완성했다.
- 다음의 세 가지 요소가 SAM의 핵심이다.
 - **promptable segmentation task**
 - **flexible하고 ambiguity-aware한 모델 구조**
 - **대규모 데이터를 수집하기 위한 data engine**
- 이를 통해 **zero-shot 일반화**와 다양한 **downstream segmentation task**를 해결할 수 있음을 보여준다.

2. Related Work

| 관련 연구 동향은 어떠한가?

- **FCN (Semantic Segmentation)**

- FCN은 fully connected layer를 fully convolution layer로 대체하여 pixel-level segmentation을 가능하게 만든 최초의 접근이다.
- 그러나 같은 클래스 내에서 객체를 구분할 수 없는 한계가 있었다.

- **Mask R-CNN (Instance Segmentation)**

- Faster R-CNN에 segmentation branch를 추가하여 객체 단위의 마스크를 예측할 수 있었다.
- 하지만 배경과 객체의 경계를 명확하게 구분하기에는 부족했다.

- **Panoptic Segmentation (Holistic Segmentation)**

- “thing vs stuff” 개념을 제안하며 객체와 배경을 통합적으로 다루려 했다.
- 그러나 semantic과 instance를 따로 학습해야 하는 구조로 인해 효율성이 떨어졌다.

- **DETR (Detection Transformer)**

- Transformer를 활용해 object detection을 end-to-end로 단순화한 모델이다.
- 하지만 segmentation으로의 확장에서는 여전히 범용성과 데이터의 한계가 존재했다.

- **SAM (Segment Anything Model)**


- 논문의 SAM은 promptable segmentation이라는 새로운 태스크 정의, 새로운 모델 구조, 그리고 SA-1B라는 초대규모 데이터셋을 기반으로 제시되었다.
- 이를 통해 기존 모델들의 한계를 넘어 **범용성, 효율성, zero-shot 일반화**를 동시에 달성할 수 있었다.

3. Method (제안 방법론)

Main Idea

거대한 데이터셋으로 학습한 모델에 포인트·박스·텍스트 등의 프롬프트를 입력하면, 추가 학습 없이 어떤 이미지에서도 원하는 객체를 분할할 수 있다!

3.1 Task



- Promptable segmentation
 - prompt는 point, box, rough mask, text 등 다양한 형태로 줄 수 있고, 모델은 이를 기반으로 분할 대상을 결정한다.
 - 핵심은 어떤 prompt가 주어져더라도 **valid mask**를 반드시 반환해야 한다는 점이다.
 - prompt가 ambiguous한 경우에도 적어도 하나는 합리적인 mask를 출력하도록 설계되어 있다.
 - 이러한 특성 덕분에 unseen data에도 잘 일반화할 수 있고, 다양한 downstream task로 연결될 수 있다.

3.2 Model




Figure 4: Segment Anything Model (SAM) overview. A heavyweight image encoder outputs an image embedding that can then be efficiently queried by a variety of input prompts to produce object masks at amortized real-time speed. For ambiguous prompts corresponding to more than one object, SAM can output multiple valid masks and associated confidence scores.

• Architecture

- SAM은 Image Encoder와 Prompt Encoder 두 가지 encoder를 사용하여 입력 이미지와 prompt의 특징을 추출하고, 이를 바탕으로 Lightweight Mask Decoder가 최종 mask를 생성하는 구조로 되어 있다.
- Figure 4에서 볼 수 있듯이 세 가지 구성 요소로 이루어져 있으며 Real time performance를 위해 구체적인 tradeoff와 함께 Transformer vision model을 사용한다.
 - Image encoder
 - Flexible prompt encoder
 - Fast mask decoder.

• Image Encoder

- Image Encoder는 ViT-H/16을 backbone으로 하며, MAE로 ImageNet 사전학습을 진행한 모델을 사용한다.
- 입력 이미지는 1024×1024 크기로 처리되며, window attention과 global attention을 거쳐 64×64 크기의 feature map으로 변환된다.
- 이후 1×1 conv와 3×3 conv를 거치면서 채널 수를 맞추고, LayerNorm과 ReLU를 적용하여 256차원 feature embedding으로 정제된다.

• Prompt Encoder


- Prompt Encoder는 사용자가 입력한 다양한 형태의 프롬프트를 임베딩 벡터로 변환한다.
- Point, Box, Text, Mask 프롬프트를 지원하며, 각각 좌표·위치·문장·마스킹 정보를 반영한다.
- Sparse Prompts (희소 프롬프트)

1. Point: 사람이 특정 좌표를 클릭하면 해당 위치와 전경/배경 여부를 임베딩한다.
 2. Box: 사람이 드래그한 박스를 좌표 정보로 변환하여 입력한다.
 3. Text: CLIP의 Text Encoder를 활용해 문장을 임베딩으로 변환한다.
- Dense Prompts (밀집 프롬프트)
 4. Mask: 사용자가 직접 지정한 마스크를 dense embedding으로 변환하고, 이미지 임베딩과 element-wise sum으로 결합해 mask decoder의 입력으로 사용한다.

• Mask Decoder


- Mask Decoder는 두 encoder에서 얻은 embedding을 self-attention과 cross-attention을 통해 결합하고, 최종적으로 mask와 IoU score를 출력한다.
- 이 과정에서 prompt embedding과 image embedding이 상호작용하며, decoder는 이를 반복적으로 업데이트해 mask 품질을 높인다.

• Ambiguity



- 하나의 prompt가 모호할 수 있기 때문에 모델은 단일 결과 대신 3개의 candidate mask를 출력한다.
- 각 mask에는 IoU score가 함께 제공되며, 이 점수를 통해 신뢰도가 가장 높은 mask를 선택할 수 있다.

3.3 Data



(c) **Data**: data engine (top) & dataset (bottom)

• Data Engine (데이터 엔진 설계 및 워크플로우)

- 논문에서는 일반 웹상에 공개된 segmentation mask가 거의 없다는 한계에서 출발한다. 그래서 모델과 데이터 수집을 loop 구조로 공동 진화시키는 data engine을 제안했다.
- 이 엔진은 아래와 같은 세 단계로 구성된다.
 1. 보조 수동 단계 (Assisted manual)
 2. 반자동 단계 (Semi-automatic)
 3. 완전 자동 단계 (Fully automatic)
- 각 단계에서 모델이 개선될수록 annotation 비용은 줄고, 데이터 다양성, 규모는 커지는 방식으로 설계되었다.

• Assisted manual

- 초기에는 annotator가 interactive segmentation 툴을 이용해 point나 foreground/background 클릭으로 마스크를 생성하였다.
- 이 과정에서 모델이 실시간으로 보조하였고, 첫 데이터셋은 약 12만 장의 이미지에서 430만 개 마스크를 생성하였다.
- annotator 1명이 마스크를 만드는 평균 시간이 34초에서 14초까지 단축되었으며, semantic constraint 없이 객체 단위 마스크만을 수집하였다.

• Semi-automatic

- 1단계에서 확보한 마스크로 bounding box detector를 학습시켜 후보 박스를 생성했다.
- SAM에 prompt로 넣어 자동으로 마스크를 생성하였으며 신뢰도가 낮거나 누락된 객체는 annotator가 보완했다.

- 이 과정에서 이미지당 마스크 수가 증가하고 데이터 다양성이 크게 확장되었다.

- **Fully automatic**


- 모델이 충분히 학습되면 정규 격자 포인트를 기반으로 자동으로 마스크를 생성하였다.
- 모호한 경우 여러 후보 마스크를 예측하고, NMS와 stability 기준을 적용해 최종적으로 신뢰도 높은 마스크만 선택하였다.
- 이 과정을 통해 최종 SA-1B 데이터셋이 구축되었다.

- **Dataset : SA-1B**




- SA-1B는 총 1100만 장의 이미지와 11억 개 이상의 마스크로 구성되었다.
- 평균 해상도는 3300×4950 픽셀이며, 공개 버전은 짧은 변 기준 1500픽셀로 리사이즈되었다.
- 개인정보가 포함된 얼굴이나 차량 번호판 등은 블러 처리되었으며, 마스크는 classless 형식으로 저장되었다.


- spatial distribution of object centers




- sample size




- Masks per Image



- Image-relative mask size



- shape complexity



SA-1B Dataset Properties

- RAI Analysis

	# countries	SA-1B		% images		
		#imgs	#masks	SA-1B	COCO	O.I.
Africa	54	300k	28M	2.8%	3.0%	1.7%
Asia & Oceania	70	3.9M	423M	36.2%	11.4%	14.3%
Europe	47	5.4M	540M	49.8%	34.2%	36.2%
Latin America & Carib.	42	380k	36M	3.5%	3.1%	5.0%
North America	4	830k	80M	7.7%	48.3%	42.8%
high income countries	81	5.8M	598M	54.0%	89.1%	87.5%
middle income countries	108	4.9M	499M	45.0%	10.5%	12.0%
low income countries	28	100k	9.4M	0.9%	0.4%	0.5%

	mIoU at			mIoU at	
	1 point	3 points		1 point	3 points
<i>perceived gender presentation</i>			<i>perceived skin tone</i>		
feminine	54.4 ± 1.7	90.4 ± 0.6	1	52.9 ± 2.2	91.0 ± 0.9
masculine	55.7 ± 1.7	90.1 ± 0.6	2	51.5 ± 1.4	91.1 ± 0.5
<i>perceived age group</i>			3	52.2 ± 1.9	91.4 ± 0.7
older	62.9 ± 6.7	92.6 ± 1.3	4	51.5 ± 2.7	91.7 ± 1.0
middle	54.5 ± 1.3	90.2 ± 0.5	5	52.4 ± 4.2	92.5 ± 1.4
young	54.2 ± 2.2	91.2 ± 0.7	6	56.7 ± 6.3	91.2 ± 2.4


- SA-1B와 SAM 사용 과정에서 발생할 수 있는 공정성 문제를 분석하였다.
- 지역 및 소득별 데이터 분포를 살펴본 결과, 저소득 국가 및 특정 지역은 데이터 비중이 현저히 낮았다.

- 사람을 세그멘테이션할 때 성별, 연령, 피부 톤에 따라 성능 편차가 발생하는 것이 확인되었다.
- 이러한 편향을 줄이기 위해 데이터 수집과 라벨링 과정에서 다양성과 대표성을 확보하는 방향이 필요하다고 언급한다.

4. Experiments (실험 및 결과)


실험 구성과 결과는?

• Zero-Shot Single Point Valid Mask Evaluation




(a) SAM vs. RITM [92] on 23 datasets

- 단일 전경점을 프롬프트로 주었을 때의 성능을 평가하였다.




- SAM은 23개 데이터셋 중 대부분에서 기존 방법들보다 높은 mIoU를 기록했고, prompt 수가 달라져도 안정적인 성능을 보였다.



(b) Mask quality ratings by human annotators

- 사람 평가 방식에서도 SAM이 더 정밀하고 깔끔한 마스크를 생성하는 것으로 확인되었다.

• Zero-Shot Edge Detection



method	year	ODS	OIS	AP	R50
HED [108]	2015	.788	.808	.840	.923
EDETR [79]	2022	.840	.858	.896	.930
<i>zero-shot transfer methods:</i>					
Sobel filter	1968	.539	-	-	-
Canny [13]	1986	.600	.640	.580	-
Felz-Hutt [35]	2004	.610	.640	.560	-
SAM	2023	.768	.786	.794	.928

Table 3: Zero-shot transfer to edge detection on BSDS500.

- BSDS500 데이터셋을 이용해 객체 edge 검출 성능을 비교하였다.
- SAM은 추가 학습 없이도 edge detection에서 경쟁력 있는 성능을 보였으며, 기존 전이 학습 기반 방법과 비교해도 높은 ODS, OIS 점수를 달성했다.

• Zero-Shot Object Proposals

method	all	mask AR@1000					
		small	med.	large	freq.	com.	rare
ViTDet-H [62]	63.0	51.7	80.8	87.0	63.1	63.3	58.3
<i>zero-shot transfer methods:</i>							
SAM – single out.	54.9	42.8	76.7	74.4	54.7	59.8	62.0
SAM	59.3	45.5	81.6	86.9	59.1	63.9	65.8


Table 4: Object proposal generation on LVIS v1. SAM is applied zero-shot, *i.e.* it was not trained for object proposal generation nor did it access LVIS images or annotations.

- 이미지 내 객체가 있을 것으로 예상되는 영역을 제안하는 실험을 진행하였다.
- LVIS 데이터셋을 기준으로 평가했을 때, SAM은 다양한 크기의 객체를 고르게 포착했으며 recall 지표에서 기존 방법들과 유사하거나 더 높은 성능을 보여주었다.

• Zero-Shot Instance Segmentation


method	COCO [66]				LVIS v1 [44]			
	AP	AP ^S	AP ^M	AP ^L	AP	AP ^S	AP ^M	AP ^L
ViTDet-H [62]	51.0	32.0	54.3	68.9	46.6	35.0	58.0	66.3
<i>zero-shot transfer methods (segmentation module only):</i>								
SAM	46.5	30.8	51.0	61.7	44.7	32.5	57.6	65.5

Table 5: Instance segmentation results. SAM is prompted with ViTDet boxes to do zero-shot segmentation. The fully-supervised ViTDet outperforms SAM, but the gap shrinks on the higher-quality LVIS masks. Interestingly, SAM outperforms ViTDet according to human ratings (see Fig. 11).




- COCO와 LVIS 데이터셋에서 객체 단위 영역 분할을 수행하였다.
- SAM은 전이 학습 없이도 상당히 합리적인 성능을 달성했으며, 생성된 마스크의 품질에 대해서도 사람이 평가했을 때 높은 점수를 얻었다.

• Zero-Shot Text-to-Mask



- 텍스트를 프롬프트로 주어 객체를 분할하는 실험을 수행하였다.
- CLIP 인코더로 텍스트를 임베딩한 뒤, 이를 SAM에 프롬프트로 제공하면 지정된 텍스트와 대응되는 마스크를 생성할 수 있었다.
- 이는 SAM이 텍스트-비전 멀티모달 입력에도 대응할 수 있음을 보여준다.

• Ablations



- 데이터 엔진 단계별 성능, 데이터셋 크기, 인코더 규모에 따른 학습 성능 변화를 비교하였다.
- 데이터 양이 많을수록 더 큰 모델을 사용할수록 성능이 향상되었으며 자동 생성 데이터만으로도 일정 수준 이상의 성능이 유지됨을 실험적으로 보였다.

5. Conclusion

결론 및 주요 요약은?

- Segment Anything은 프롬프트 기반 태스크, SAM 모델, SA-1B 데이터셋을 통해 이미지 분할을 파운데이션 모델의 시대에 맞게 확장하였다.
- 이러한 접근은 기존 방법과 달리 범용성/확장성/조합성을 동시에 확보하며, 다른 비전 시스템에도 손쉽게 통합될 수 있음을 보여준다.
- 그러나 세밀한 구조 분할, 경계 처리, 다중 포인트 입력, 실시간 적용성에서의 한계는 여전히 존재한다.
- 또한 Text-to-Mask 성능의 제한과 semantic/panoptic segmentation으로의 확장 부족은 향후 해결해야 할 과제로 남아 있다.