



Segment Anything

🕒 생성일	@2025년 10월 1일 오후 11:18
🌟 태그	Done

- [1. Abstract & Introduction](#)
- [2. Related Works](#)
- [3. Methodology](#)
- [4. Experiments & Results](#)
- [5. Discussion](#)
- [6. Conclusion](#)

1. Abstract & Introduction

- “분할을 위한 파운데이션 모델”을 만들기 위해 **새로운 과제(프롬프트 가능한 분할), 모델 (SAM), 데이터셋(SA-1B)** 를 함께 제안
- 모델을 데이터 수집 루프에 넣어 11M 이미지에서 1.1B 마스크를 생성한 초대규모 분할 데이터셋 구축
- SAM은 **프롬프트 가능성(promptability)** 을 통해 제로샷 전이가 가능하며, 여러 과제에서 완전 지도학습 SOTA에 근접/상회하는 성능을 보이며, 모델과 데이터셋을 공개하여 비전 분야의 파운데이션 모델 연구를 촉진하는 것이 목표!
- NLP에서 LLM이 웹 규모 데이터와 프롬프트 기반 제어를 통해 강력한 zero/few-shot 일반화를 보여준 것과 유사한 비전 파운데이션 모델이 필요하다는 문제의식
 - 하지만 segmentation은 텍스트 및 이미지 pair처럼 웹에 풍부히 존재하지 않아 데이터가 부족
 - 따라서 “프롬프트 가능한 분할”이라는 과제를 정의하고, 모델/과제/데이터를 얹힌 상태로 동시 설계하자!

2. Related Works

- 비전-언어 파운데이션 모델:** CLIP, ALIGN은 대규모 웹 텍스트-이미지 쌍으로 학습해 텍스트 프롬프트로 제로샷 일반화를 달성 → 그러나 이는 비전 문제의 일부 범주이며, segmentation 전반에는 데이터가 부족함

- **멀티태스크 분할**: 기존 시스템은 학습/테스트 과제가 동일한 고정 세트였으나, SAM은 프롬프트 조합을 통해 미지의 새로운 하위 과제를 수행하도록 설계 (조합적 시스템 구성)

3. Methodology

- 프롬프트 가능한 분할
 - 입력 이미지와 **프롬프트(점/박스/마스크/텍스트)** 가 주어졌을 때, **"유효한(valid) 마스크"**를 반환하는 것을 목표로 정의
 - 프롬프트가 모호할 경우(예: 셔츠 위 점=사람 vs 셔츠), 가능한 해석 중 하나에 해당하는 합리적 마스크를 내는 것이 과제의 핵심
 - 이 과제를 사전 학습 목적이자 다양한 downstream task를 prompt engineering으로 해결하는 공통 인터페이스로 사용
- **model: SAM(image encoder + prompt encoder + lightweight mask encoder)**
 - **이미지 인코더**: MAE로 사전학습된 ViT-H를 사용하여 고해상도 입력을 처리하고, 이미지 임베딩을 1회만 계산 (프롬프트를 바꿔도 재사용)
 - **프롬프트 인코더**: 점/박스/텍스트(클립 텍스트 인코더)와 마스크를 임베딩으로 변환해 이미지 임베딩과 결합
 - **마스크 디코더**: 수정된 트랜스포머 디코더 블록(프롬프트 self-attn + 교차 어텐션 양방향)과 동적 마스크 헤드로 마스크 확률맵과 예상 IoU(신뢰도)를 생성 & 웹 브라우저 CPU 기준 ~50ms로 실시간 상호작용 대응
 - **모호성 처리**: 단일 프롬프트에 대해 다중 마스크(기본 3개)를 출력하고, min-loss 학습과 IoU 추정 헤드로 랭킹/선택 (whole/part/subpart 3단 중첩 대응)
 - **학습 손실/전략**: focal+dice 손실, 대화형 시뮬레이션(라운드별 랜덤 프롬프트)으로 프롬프트 다양성 학습
- **데이터 엔진 + SA-1B**
 - **3단계 데이터 엔진(보조-수동 → 반자동 → 완전 자동)**: 모델을 루프 안에 넣어 주석을 가속/확장 → 최종적으로 11M 이미지&1.1B 마스크의 SA-1B 구축
 - **완전 자동 단계의 핵심**: 32×32 그리드 점 프롬프트, 다중 마스크 생성(모호성 인지), IoU 예측 기반 신뢰도 선별, 안정성(stability) 기준, NMS 중복 제거, 멀티 크롭/줌인 처리 → 결과적으로 1.1B 고품질 마스크 생성!

- **품질 검증**: 500장(≈50k 마스크) 샘플에서 자동 마스크 vs 전문가 교정 마스크 IoU 90%↑가 94%, 75%↑가 97%로 보고되었고, SA-1B는 자동 생성 마스크만 포함
- **이미지 스펙**: 평균 3300×4950 고해상도(배포본은 최단변 1500), 개인정보 비가시화 처리

4. Experiments & Results

• 핵심 zero-shot 평가 시나리오

- 단일 점 프롬프트로 유효 마스크 생성(가장 모호/어려운 설정)
- 자동 mIoU와 대규모 휴먼 스터디(1~10 점수) 를 병행하여 품질 평가
- 주요 비교 대상은 강력한 인터랙티브 분할기 RITM이며, 평가 23개 데이터셋으로 광범위한 분포(수중·자기중심 etc.)

• 과제 스펙트럼 zero-shot 전이

- (1) 에지 검출 , (2) segment-everything(오브젝트 제안) , (3) 검출 결합 인스턴스 분할 , (4) 텍스트-to-마스크 (개념 증명) 까지 프롬프트 엔지니어링으로 구현함을 시연 ⇒ 다수의 설정에서 완전 지도 방식과 경쟁력 있는 제로샷 성능을 보임!!!

• 23개 데이터셋 목록·프로토콜과 BSDS500 제로샷 에지 검출 지표 (ODS/OIS/AP/R50) 등 세부 구성 공개

• 공정성(Fairness) 분석

- MIAP 등으로 지각된 젠더/연령/피부톤 그룹 간 사람/의류 분할 성능 차이를 분석
→ 대체로 큰 편향은 관찰되지 않음(의류의 경우 부분적 신호)

5. Discussion

• 발견

- 프롬프트 가능 세분화를 통한 태스크 일반화/조합성 ⇒ 분할 모델을 컴포넌트화하여 탐지기·텍스트 인코더 등과 조합해 새로운 태스크를 추론 시점에 실현 가능
- 데이터 엔진 루프로 품질과 규모를 동시에 확보 → 자동 마스크가 전문가 교정치에 매우 근접

• 한계

- 미세 구조 누락
- 작은 분리 component hallucination
- 경계 선명도 열세(줄인 고비용 방법 대비)

- 무거운 인코더 사용 시 전체 파이프라인 실시간 한계
- 텍스트-to-마스크 초기 단계/견고성 부족, 의미/파노픽 분할을 단순 프롬프트로 일반화하는 설계 미정, 특화 도메인 도구가 특정 도메인에선 우수

6. Conclusion

- 프롬프트 가능한 분할 과제·SAM·SA-1B 를 통해 세그멘테이션의 파운데이션 모델화를 시도
- 커뮤니티 활용 여부에 성패가 달렸지만, 1B+ 마스크 공개와 프롬프트 가능한 모델이 이후 연구의 기반이 되길 기대한다!
- Q. 기존 연구 대비 차별점?
 - **과제**: 대상을 고정 집합으로 정한 멀티태스킹이 아니라, 임의 프롬프트로 유효 마스크 생성이라는 일반 인터페이스를 정의 → 새 태스크를 조합하여 추론 시점에 구현 가능!
 - **모델**: 이미지 인코더 비용을 사전 계산/재사용하고, 가벼운 프롬프트 인코더+마스크 디코더로 실시간 상호작용을 보장한다. → 모호성 인지 다중 출력과 IoU 예측 헤드로 결과 선택
 - **데이터**: model-in-the-loop 데이터 엔진으로 11M/1.1B 규모의 고품질 자동 마스크를 만들고, 그 품질을 체계적으로 검증 → segmentation web scale 데이터 부재 문제의 현실적 해법
- 1. 프롬프트 가능한 분할을 통합 인터페이스로 삼아 다양한 다운스트림 분할 태스크를 프롬프트 엔지니어링으로 해결
- 2. SAM 아키텍처: 강력한(사전학습) 이미지 인코더 + 유연한 프롬프트 인코더 + 경량 마스크 디코더로 실시간/조합성/모호성 대응을 동시에 달성
- 3. 데이터 엔진 루프로 규모(1.1B) 와 품질(전문가 교정치 근접) 을 함께 끌어올려, 세그멘테이션용 파운데이션 데이터를 스승로 만들어냄