

TCN

■ 상위 작업	📖 세션 논문 리뷰
■ 진행 상태	완료
■ 첨부 파일	TCN.pdf

[0. Abstract](#)

[1. Introduction](#)

[1.1 Introduction](#)

[1.2 Background](#)

[2. Related Work](#)

[3. Method \(제안 방법론\)](#)

[3. Temporal Convolutional Networks \(TCN\)](#)

[3.1. Sequence Modeling](#)

[3.2. Causal Convolutions](#)

[3.3. Dilated Convolutions](#)

[3.4. Residual Connections](#)

[4. Experiments \(실험 및 결과\)](#)

[5. Conclusion](#)

0. Abstract

| 어떤 문제를 해결하려 했는가?

- 시퀀스 모델링은 전통적으로 RNN(순환신경망)을 의미한다.
- 하지만 최근 연구에서는 합성곱 신경망(CNN)이 오디오 합성, 기계 번역 등의 분야에서 RNN보다 우수한 성능을 보이고 있음을 제시했다.
- 이에 본 논문은 합성곱과 순환 아키텍처를 다양한 표준 작업에서 체계적으로 평가한다.
- 그 결과 단순한 CNN 구조(TCN)가 LSTM 등 RNN보다 뛰어난 성능과 긴 기억력을 제공하는 것을 보였다.
- 따라서 시퀀스 모델링을 무조건 RNN과 연결짓는 일반적 관념은 재고되어야 하며, CNN이 시퀀스 모델링 작업의 기본 출발점이 될 수 있음을 제시한다.

1. Introduction

| 연구 동기와 문제점은 무엇인가?

1.1 Introduction

- 딥러닝 실무에서는 전통적으로 시퀀스 모델링의 기본으로 RNN을 사용해왔다.
- 그러나 최근 연구는 오디오 합성과 기계 번역 등에서 CNN 구조가 RNN을 능가함을 보여주었고, 이는 시퀀스 처리 전반에 대한 재검토 필요성을 제기한다.
- 본 연구는 다양한 시퀀스 작업(음악 생성, 언어 모델링, 합성 테스트 등)에서 RNN과 CNN을 체계적으로 비교하기 위해 간단하면서도 범용적인 TCN을 제안하고, LSTM/GRU와 성능을 대조했다.
- 결과적으로 TCN은 여러 태스크에서 RNN을 압도했으며, 실제로 더 긴 기억력을 보였다.
- 따라서 본 논문은 RNN 중심의 기존 관념을 바꾸고, TCN이 시퀀스 모델링의 새로운 기준점이 될 수 있음을 강조한다..

1.2 Background

- CNN은 원래 이미지 처리에서 출발했지만, 이후 음성 인식/합성, 문장 분류, 기계 번역, 언어 모델링 등 다양한 시퀀스 작업에 적용되어 왔다.
- 특히 causal convolution, dilated convolution, residual connection 같은 기법들은 시퀀스 모델링에서 CNN의 효율을 높였다.
- 반면 RNN, LSTM, GRU는 시퀀스 모델링의 전통적 선택이었지만, 긴 의존성 학습의 어려움과 병렬화 한계 같은 단점이 있다.
- 기존 비교 연구는 데이터·모델·학습 절차가 제각각이어서 공정성이 떨어졌으며, 따라서 동일한 조건에서 CNN과 RNN을 체계적으로 비교할 필요가 제기된다.

2. Related Work

| 관련 연구 동향은 어떠한가?

- 최근 연구에서 CNN(Convolutional Neural Networks, 합성곱 신경망)이 특정 작업에서 RNN보다 우수한 성능을 보일 수 있음이 보고되었다.
- 논문이 나온 시점에서의 대표적인 CNN 기반 순차 모델
 - WaveNet (van den Oord et al., 2016)
→ 오디오 합성에서 RNN보다 뛰어난 성능을 보였다.
 - ByteNet, ConvS25 (Kalchbrenner et al., 2016; Gehring et al., 2017)
→ 기계 번역에서 LSTM보다 우수하였다.
 - Gated CNN (Dauphin et al., 2017)
→ 언어 모델링에서 기존 RNN보다 좋은 성능을 보였다.
- 하지만 CNN이 RNN을 완전히 대체할 수 있는지에 대한 체계적인 비교 연구가 부족한 상황이었다.

3. Method (제안 방법론)

| 연구 접근법과 모델 구조는 어떻게 되는가?

3. Temporal Convolutional Networks (TCN)

Main Idea

시퀀스 모델링에서 꼭 RNN만 쓸 필요는 없다!!!

단순한 합성곱 기반 구조인 TCN은 *causal 1D 합성곱*, *dilated 합성곱*, *residual 블록*을 깊게 쌓아 입력과 같은 길이의 출력을 내며, 더 안정적이고 성능도 우수하다!!

3.1. Sequence Modeling

$$\hat{y}_0, \dots, \hat{y}_T = f(x_0, \dots, x_T)$$

- Sequence Modeling에서는 길이 T 의 입력 시퀀스 $(x_0, \dots, x_t)$ 를 받아 동일한 길이의 출력 시퀀스로 매핑한다.


- 이때 각 시점의 출력은 오직 과거 입력에만 의존해야 하며, 미래 정보는 사용할 수 없다.
- 따라서 모델은 주어진 입력과 실제 출력의 차이를 최소화하는 손실 함수를 통해 학습된다.

3.2. Causal Convolutions

$$\text{TCN} = \text{1D FCN} + \text{causal convolutions.}$$

- TCN은 **인과적 합성곱(causal convolution)**을 기반으로 한다.
 - TCN은 입력과 같은 길이의 출력을 생성하며, 미래의 정보가 과거로 흘러가지 않도록 보장해야 한다.
 - 구현은 1D **fully-convolutional network (FCN)** 구조를 사용하며, **zero padding**을 추가해 출력 길이가 입력과 동일하게 유지된다.
 - 또한 TCN은 **인과적 합성곱(causal convolution)**을 사용하여 특정 시간 t 의 출력이 오직 현재 및 과거 시간의 입력과만 합성곱되도록 제한한다.

3.3. Dilated Convolutions




- RNN은 시간 순서대로 한 단계씩 정보가 전달되기 때문에, 과거 정보를 장기적으로 유지하기 어렵다. LSTM/GRU는 단기 기억 소실 문제가 어느정도 개선되었지만, 긴 시퀀스를 다룰 때는 여전히 한계가 존재한다.

- 본 논문에서는 이 단기 기억 소실 문제를 해결하기 위해 확장 합성곱(Dilated Convolutions)을 제안하였다.


$$F(s) = (\mathbf{x} *_d f)(s) = \sum_{i=0}^{k-1} f(i) \cdot \mathbf{x}_{s-d \cdot i}$$

- Dilated convolution은 필터 적용 시 입력을 일정 간격(dilation factor d)으로 건너뛰며 연결하는 합성곱 방식이다.
 - k 는 필터 크기, d 는 dilation factor이다.
 - dilation을 층마다 1, 2, 4로 증가시키면 receptive field가 지수적으로 커져 아주 긴 과거 정보까지 효율적으로 반영할 수 있는 구조이다.
 - 따라서 TCN은 적은 깊이와 파라미터로도 RNN보다 더 긴 의존성을 처리할 수 있다.

3.4. Residual Connections



(b)



(c)

- TCN이 충분히 깊어지면, 기울기 소실(Vanishing Gradient) 문제가 발생할 수 있다. 즉, 네트워크가 깊어질수록 초기 층이 제대로 학습되지 않는다.
- 본 논문에서는 깊은 신경망에서 발생할 수 있는 기울기 소실 문제를 해결하기 위해 TCN 모델에 Residual Connection을 적용하였다.

$$o = \text{Activation}(\mathbf{x} + \mathcal{F}(\mathbf{x}))$$

- ResNet과 유사한 잔차 연결(Residual Connections)을 추가하여, 기울기 소실 문제를 방지한다.
- 기존 출력값에 입력값을 직접 더하는 구조(Identity Mapping)를 사용하여 안정적인 학습이 가능하다.

4. Experiments (실험 및 결과)

| 실험 구성과 결과는?

- **Synthetic Stress Tests**
 - **Copy Memory Task:** 입력을 일정 시간 유지하다가 그대로 출력해야 하는 테스트
→ 장기 의존성 평가.
 - **Adding Problem:** 긴 시퀀스 중 두 위치의 숫자를 골라 합하는 문제
→ 유효 기억과 장기 정보 활용 능력 평가.
- **Sequential MNIST Variants**
 - **Sequential MNIST:** 픽셀을 한 줄 시퀀스로 순차 입력 → 시퀀스 처리 성능 평가.
 - **Permuted MNIST:** 픽셀 순서를 무작위로 섞어 더 어렵게 만든 버전.
- **Polyphonic Music Modeling**
 - JSB Chorales, Nottingham 등 데이터셋으로 다중 음성 음악 시퀀스 예측.
- **Language Modeling**
 - **Word-level LM:** Penn Treebank, WikiText-103, LAMBADA.
 - **Character-level LM:** Penn Treebank, text8.
 - 전통적인 RNN 벤치마크로, TCN과 LSTM/GRU 비교.

Sequence Modeling Task	Model Size ($\approx$)	Models			
		LSTM	GRU	RNN	TCN
Seq. MNIST (accuracy ^h)	70K	87.2	96.2	21.5	99.0
Permuted MNIST (accuracy)	70K	85.7	87.3	25.3	97.2
Adding problem $T=600$ (loss ^ℓ)	70K	0.164	5.3e-5	0.177	5.8e-5
Copy memory $T=1000$ (loss)	16K	0.0204	0.0197	0.0202	3.5e-5
Music JSB Chorales (loss)	300K	8.45	8.43	8.91	8.10
Music Nottingham (loss)	1M	3.29	3.46	4.05	3.07
Word-level PTB (perplexity ^ℓ)	13M	78.93	92.48	114.50	88.68
Word-level Wiki-103 (perplexity)	-	48.4	-	-	45.19
Word-level LAMBADA (perplexity)	-	4186	-	14725	1279
Char-level PTB (bpc ^ℓ)	3M	1.36	1.37	1.48	1.31
Char-level text8 (bpc)	5M	1.50	1.53	1.69	1.45

- TCN이 모든 실험에서 RNN(LSTM, GRU)보다 더 우수한 성능을 보였다.
- 특히, 기억 유지력이 중요한 실험(Adding Problem, Copy Memory)에서 압도적인 성능차이를 보였다.
- MNIST 실험에서도 TCN이 RNN보다 높은 정확도를 기록하였다.

=> 위 실험을 통해 TCN은 병렬 연산 덕분에 더 빠르게 학습 가능하며, RNN보다 더 긴 의존성을 학습할 수 있음을 입증하였다.




Figure 2. Results on the adding problem for different sequence lengths T . TCNs outperform recurrent architectures.

- Adding Problem
 - 길이가 T 인 시퀀스에서 두 위치의 숫자를 골라 더하는 task
 - TCN은 짧은 길이($T=200$)뿐 아니라 긴 길이($T=600$)에서도 빠르고 안정적으로 loss가 0에 수렴하였다.
 - RNN, LSTM, GRU는 길이가 길어질수록 학습이 불안정하거나 수렴이 느리다.




Figure 3. Results on Sequential MNIST and P-MNIST. TCNs outperform recurrent architectures.

- Sequential MNIST & Permuted MNIST
 - a. Sequential MNIST : 784 픽셀을 순차적으로 입력받아 숫자를 분류하는 task
 - b. P-MNIST : 픽셀 순서를 무작위로 섞은 버전
 - 두 태스크 모두에서 TCN이 LSTM, GRU보다 더 빠르게 accuracy를 끌어올리고 최종 정확도도 높게 나왔다.
 - 순서가 중요한 태스크에서도 TCN이 RNN보다 안정적인 성능을 보인다.




Figure 4. Result on the copy memory task for different sequence lengths T . TCNs outperform recurrent architectures.

- Copy Memory Task
 - 처음에 주어진 입력 시퀀스를 오래 기억했다가 후반부에 그대로 복원하는 task
 - TCN은 긴 길이에서도 빠르게 loss가 0에 수렴하였다.
 - LSTM/GRU는 길이가 길어지면 성능이 급격히 악화되었다. (memory bottleneck)

5. Conclusion

| 결론 및 주요 요약은?

- 본 연구는 TCN과 RNN(LSTM, GRU)을 다양한 시퀀스 과제에서 비교하였다.
- 실험 결과 TCN은 대부분의 과제에서 RNN보다 우수하며, 같은 규모일 때 더 긴 메모리를 유지한다.
- RNN의 '무한 기억'이라는 장점은 실제로는 거의 발휘되지 않았다.
- LSTM은 오랜 최적화를 통해 성숙했으나, TCN은 아직 연구 여지가 많아 발전 가능성이 크다.
- 따라서 RNN 중심의 시대는 저물고 있으며, 단순하면서도 강력한 TCN이 시퀀스 모델링의 새로운 출발점이 될 수 있다.