


ViT

Abstract

Transformer는 NLP에서 대규모 사전학습과 미세 조정을 통해 성과를 내며 표준이 되었지만, 컴퓨터 비전에서는 CNN이 여전히 주류였다. 기존 연구들은 CNN에 self-attention을 결합하거나 합성곱을 대체했지만, 하드웨어 효율성 문제로 대규모 확장에 한계가 있었다. 따라서 이미지를 패치로 나누어 단어처럼 Transformer에 직접 입력하는 단순한 구조의 Vision Transformer를 제안. 중간 규모 데이터셋에서는 CNN보다 다소 낮은 성능을 보였으나 대규모 데이터셋으로 학습했을 때는 ResNet을 넘어서는 정확도를 기록하고, 충분한 데이터와 스케일이 CNN의 귀납적 편향보다 더 중요함을 나타냄.



Method

입력 이미지 전처리

- 이미지를 패치로 분할
- 각 패치를 평탄화 후 선형 변환 → patch embedding 생성
- [CLS] 토큰과 positional embedding 추가

Transformer Encoder 처리

- 입력 시퀀스를 Transformer Encoder에 전달
- Encoder는 Multi-Head Self-Attention (MSA)+ MLP 블록을 쌓은 구조
- 각 블록에는 LayerNorm과 residual connection 적용

Hybrid 구조

- 원본 이미지 패치 대신 CNN feature map을 입력으로 사용 가능
- 경우에 따라 CNN의 특성과 Transformer의 장점을 결합

Fine-tuning

- 대규모 데이터셋에서 사전학습후, 다운스트림 과제에 맞게 분류 헤드를 교체하고 fine tuning 진행
- fine-tuning 시 더 높은 해상도를 사용하면 성능 개선
- 해상도 차이에 따른 위치 임베딩 불일치는 2D interpolation으로 조정

Experiment

ResNet, ViT, Hybrid 모델의 표현 학습 능력을 비교. 데이터셋 크기를 달리해 사전학습을 진행하고, 다양한 벤치마크 과제에서 성능을 평가. 사전학습 비용 대비 성능을 비교했을 때, ViT는 낮은 비용으로도 SOTA를 달성하였다. 추가적으로 자기지도 학습 실험을 소규모로 진행하여 ViT의 확장 가능성을 확인하였다. 사전학습은 ImageNet-1k, ImageNet-21k, JFT-300M 등 다양한 규모의 데이터셋에서 수행되었으며, 전이 평가는 ImageNet, CIFAR-10/100, Oxford-IIIT Pets, Oxford Flowers-102, VTAB 등에서 진행되었다. 모델은 ViT(Base, Large, Huge), 개선된 ResNet(BiT), Hybrid 구조를 사용하였다. 학습은 Adam 옵티마이저와 대규모 batch로 사전학습 후, SGD 기반 Fine-tuning으로 최적화되었으며, Fine-tuning accuracy와 Few-shot accuracy로 성능을 검증하였다. 비교 결과, ViT-L/16과 ViT-H/14는 기존 SOTA 모델(BiT, Noisy Student)을 능가했으며, 특히 JFT-300M 기반 학습 시 높은 효율성과 일반화 능력을 보였다. ViT-H/14는 ImageNet, CIFAR-100, VTAB 같은 난도 높은 과제에서 우수한 성과를 기록했고, ImageNet-21k 학습 모델도 적은 연산 자원으로 경쟁력 있는 성능을 달성하였다. Vision Transformer가 CNN을 대체할 수 있는 강력한 대안임을 알수있다.

YOLO는 객체 탐지의 여러 단계를 분리하지 않고, 이를 단일 신경망으로 통합하였다. 이 네트워크는 이미지 전체에서 추출된 특징을 활용하여 각 바운딩 박스를 예측하며, 동시에 모든 클래스에 대한 탐지를 수행한다. 시스템은 입력 이미지를 격자로 나눈다. 객체의 중심이 속한 격자 셀이 그 객체를 탐지할 책임을 가진다. 각 격자 셀은 B개의 바운딩 박스와 confidence score를 예측한다. Confidence는 해당 박스가 실제 객체를 포함할 확률과 예측된 위치 정확도를 반영하고 객체가 없으면 confidence는 0이 되고, 객체가 있을 경우 IoU와 일치하는 값을 가지도록 학습된다. 각 바운딩 박스는 5개의 요소(x, y, w, h, confidence)로 구성된다. (x, y)는 격자 셀 내 중심 좌표, w와 h는 전체 이미지 대비 상대적 너비와 높이, confidence는 예측 박스와 실제 박스 간 IoU를 의미한다. 또한 각 격자 셀은 객체가 존재한다고 가정할 때의 C개의 클래스 조건부 확률을 출력한다.

Network Design

CNN 기반 아키텍처로 구현되었으며, PASCAL VOC 데이터셋에서 평가되었다. 초기 합성곱 계층들은 이미지 특징을 추출하고, 이후 완전 연결 계층이 클래스 확률과 좌표를 예측한다. 네트워크는 24개의 합성곱 계층과 2개의 완전 연결 계층으로 구성된다. 1×1 축소 계층 + 3×3 합성곱을 활용하는 단순한 구조를 채택했다. 또한 더 빠른 탐지를 위해 Fast YOLO버전을 설계하였다. 합성곱 계층 수를 줄여(24 $\rightarrow$ 9), 각 계층의 필터 수도 감소시킨 경량화 네트워크로, YOLO와 동일한 학습-테스트 파라미터를 사용하면서 속도를 극대화.

Experiment

YOLO는 PASCAL VOC 2007과 2012 데이터셋을 중심으로 다양한 객체 탐지 기법과 성능을 비교하였다. 먼저, 기존의 R-CNN 계열과 DPM과 달리 YOLO는 전체 이미지를 한 번만 보고 바로 바운딩 박스와 클래스 확률을 예측하는 방식이므로, 추론 속도 면에서 압도적인 이점을 가진다. 실제로 기본 YOLO 모델은 Titan X GPU에서 45fps의 실시간 성능을 달성했으며, 경량화된 Fast YOLO는 150fps 이상을 기록하였다. 스트리밍 영상 처리나 실시간 응용에 적합한 수준으로, 기존 실시간 탐지기보다 두 배 이상 높은 mAP를 보였다. 또한 YOLO는 이미지 전체를 고려하여 예측하기 때문에 전역적 문맥을 활용할 수 있으며, 그 결과 R-CNN이 흔히 범하는 배경 오염을 절반 이하로 줄였다. 이러한 특성 덕분에 자연 이미지로 학습한 후에도 예술 작품과 같은 새로운 도메인으로 잘 일반화하여, DPM이나 R-CNN보다 높은 성능을 기록하였다. 다만, YOLO는 그리드 단위로 객체를 예측하는 구조적 제약으로 인해 가까이 있는 다수의 객체를 동시에 탐지하기 어렵고, 작은 객체의 위치를 정밀하게 잡는 데 한계가 있었다. 특히 localization 오류가 주요 성능 저하 요인으로 나타났다. 그럼에도 불구하고, YOLO는 단일 CNN 기반의 통합적이고 단순한 구조로 높은 효율성과 실시간 성능을 보여주며, 기존 탐지 시스템을 대체할 대안임을 실험을 통해 알 수 있었다.