

VIT

■ 상위 작업	📖 세션 논문 리뷰
■ 진행 상태	완료
■ 첨부 파일	VIT.pdf

[0. Abstract](#)

[1. Introduction](#)

[2. Related Work](#)

[3. Method \(제안 방법론\)](#)

[3. Vision Transformer\(ViT\)](#)

[3.1 Input Embedding](#)

[3.2. Transformer Encoder](#)

[Hybrid Architecture](#)

[4. Experiments \(실험 및 결과\)](#)

[Datasets](#)

[5. Conclusion](#)

0. Abstract

| 어떤 문제를 해결하려 했는가?

- 트랜스포머는 NLP에서 사실상 표준이 되었지만, 비전 분야에서는 활용이 제한적이었다.
- 기존에는 CNN 구조에 어텐션을 덧붙이거나 일부만 대체하는 식으로 쓰였다.
- 하지만 ViT는 이미지를 패치 단위로 나누어 순수 트랜스포머만으로도 분류 성능을 낼 수 있음을 보였다.
- 특히 대규모 데이터로 사전 학습 후 다양한 벤치마크에 전이하면, 최신 CNN과 견줄 만한 성능을 내면서도 학습 자원은 더 적게 필요하다.

1. Introduction

| 연구 동기와 문제점은 무엇인가?

- Transformer와 NLP
 - NLP task에서 Transformer가 큰 성공을 거두었다.
 - 연산 효율성과 확장성이 뛰어나 데이터와 모델 크기가 커져도 성능이 계속 개선되었다.
- Computer Vision에서의 상황
 - 하지만 Computer Vision에서는 여전히 CNN 기반 구조가 주류를 차지하고 있었다.
 - self-attention을 CNN에 추가하거나 convolution을 대체하려는 시도가 있었지만, 실제 하드웨어 환경에서는 확장성이 떨어졌다.
- Vision Transformer
 - 본 연구에서는 이미지를 직접 Transformer에 적용하는 단순한 접근 방식을 제안하였다.
 - 이미지를 패치 단위로 분할해 토큰처럼 처리하고, linear embedding을 거쳐 Transformer 입력으로 사용했다.
- Inductive bias
 - 모델이 학습할 때 데이터만으로는 충분히 알 수 없는 부분을, 모델 구조나 설계에 미리 심어둔 가정이나 제약이다.
 - CNN은 translation equivariance(평행 이동 불변성), locality(지역성) 같은 귀납적 편향을 구조적으로 가지고 있어 작은 데이터셋에서도 잘 일반화된다.
 - Transformer는 이런 bias가 부족하기 때문에 중간 규모 데이터셋에서는 ResNet보다 성능이 떨어졌다.
 - 하지만 대규모 데이터셋(14M~300M)에서 학습하여 이러한 한계를 극복하고 높은 성능을 달성해냈다.
- 실험 결과
 - ImageNet: 88.55%
 - ImageNet-Real: 90.72%
 - CIFAR-100: 94.55%
 - VTAB(19 tasks): 77.63%

2. Related Work

| 관련 연구 동향은 어떠한가?

- **NLP 분야**

- Vaswani et al. (2017): Transformer 구조를 기계 번역 모델로 처음 제안하였다
→ 이후 NLP에서 표준 구조로 자리잡게 되었다
- Devlin et al. (2019): BERT를 제안하고, 노이즈 제거(Self-supervised) 방식의 사전학습을 수행하였다
- GPT 계열 (2018~2020): 언어 모델을 사전학습 + 태스크별 파인튜닝 방식으로 발전시켰다

- **Computer Vision 분야**

- 개선 시도
 - self-attention을 모든 픽셀 쌍에 적용하면 계산 비용이 $O(n^2)$ 으로 매우 커졌다
 - Parmar et al. (2018): local neighborhood에만 self-attention을 적용하였다
 - Sparse Transformers (2019): attention 범위를 scaling하여 효율화를 시도하였다

→ 하지만 여전히 특수한 설계가 필요했고, 하드웨어 가속기에서 효율적으로 처리하기 어려웠다
- ViT와 유사한 연구:
 - Cordonnier et al. (2020): 이미지를 2×2 패치로 분할한 뒤 self-attention을 적용하였다
 - ViT와 유사했지만 작은 패치 단위로만 적용할 수 있었다
 - ViT는 단순 Vanilla Transformer 구조만으로도 SOTA CNN보다 우수한 성능을 증명하였다
- 생성 모델 적용:
 - Chen et al. (2020): 이미지 해상도와 color space를 줄인 뒤, Transformer를 픽셀 단위 생성 모델로 적용하였다 (Image GPT)

3. Method (제안 방법론)


| 연구 접근법과 모델 구조는 어떻게 되는가?

3. Vision Transformer(ViT)

Main Idea

이미지를 패치 단위로 나누어 토큰처럼 선형·위치 임베딩 후 Transformer Encoder에 넣고 [CLS] 토큰으로 분류한다!

3.1 Input Embedding



- NLP에서 사용되는 일반적인 Transformer와 ViT의 가장 큰 차이점은 ViT는 입력 이미지를 patch 단위로 쪼개 입력 임베딩으로 사용한다는 점이다.
- Patch 단위로 쪼갠 image들을 Linear Projection을 통해 Flatten Patches로 만든다.
- 이렇게 만든 patch embedding에 patch가 이미지의 어느 위치에 있던 것인지 그 위치 정보를 표현하는 Position Embedding을 더해 최종 Input Embedding으로 사용한다.
- 이때 가장 앞에 있는 *는 추가적인 learnable [class] token이다. 이는 classification을 위해 추가된 학습가능한 token이다.

⇒ NLP domain의 Transformer는 input을 token 단위로 나눠 token embedding을 사용하고, CV domain의 Transformer는 input을 patch 단위로 나눠 patch embedding


을 사용한다는 점이 가장 큰 차이점이다.

$$\begin{aligned}
 \mathbf{z}_0 &= [\mathbf{x}_{\text{class}}; \mathbf{x}_p^1 \mathbf{E}; \mathbf{x}_p^2 \mathbf{E}; \dots; \mathbf{x}_p^N \mathbf{E}] + \mathbf{E}_{pos}, & \mathbf{E} &\in \mathbb{R}^{(P^2 \cdot C) \times D}, \mathbf{E}_{pos} \in \mathbb{R}^{(N+1) \times D} \\
 \mathbf{z}'_\ell &= \text{MSA}(\text{LN}(\mathbf{z}_{\ell-1})) + \mathbf{z}_{\ell-1}, & \ell &= 1 \dots L \\
 \mathbf{z}_\ell &= \text{MLP}(\text{LN}(\mathbf{z}'_\ell)) + \mathbf{z}'_\ell, & \ell &= 1 \dots L \\
 \mathbf{y} &= \text{LN}(\mathbf{z}_L^0)
 \end{aligned}$$

- 이 과정을 수식으로 정리하면 다음과 같다.
- 여기서 $\mathbf{z}_0$ 는 입력 패치와 [class] 토큰, 위치 임베딩을 합친 초기 임베딩이고, $\mathbf{z}'_\ell, \mathbf{z}_\ell$ 은 각 레이어에서 attention과 MLP 연산을 거친 후의 중간 표현을 의미한다. 최종적으로 $\mathbf{y}$ 는 Transformer Encoder의 출력이 된다.

3.2. Transformer Encoder

Transformer Encoder



(좌) ViT (우) Transformer

- ViT의 입력은 최종적으로 만들어진 Input Embedding 시퀀스이다.
- 이 입력은 다수의 Transformer Encoder 블록을 거치게 된다.
- 각 블록은 Multi-Head Self-Attention(MSA) 과 MLP(Feed Forward Network) 로 구성되며, 각 층마다 Layer Normalization과 Residual Connection이 적용된다.
- MLP는 두 개의 fully connected layer와 GELU 활성화 함수를 포함한다.
- 이러한 블록을 LLL번 반복하여 깊은 표현 학습을 수행한다.
- Transformer Encoder의 출력 중 [class] 토큰이 최종적인 이미지 표현으로 사용된다.

Hybrid Architecture

- ViT는 원시 이미지 패치 대신 **CNN feature map**을 입력으로 사용할 수도 있다.
- 이 경우 CNN이 제공하는 inductive bias(예: 지역성, 엣지 검출)를 유지하면서 Transformer의 전역 학습 능력을 결합할 수 있다.
- Patch embedding은 CNN feature map에서 추출한 출력을 선형 변환하여 얻는다.
- CNN과 Transformer의 장점을 결합하여 성능을 향상시킬 수 있는 대안 구조이다.

4. Experiments (실험 및 결과)

| 실험 구성과 결과는?

Datasets

- ILSVRC-2012 ImageNet Dataset with 1k classes and 1.3M images
- superset ImageNet-21k with 21k classes and 14M images
- JFT with 18k classes and 303M high-resolution images
- downstream tasks
 - ImageNet (validation sets)
 - ImageNet with cleaned-up Real Labels
 - CIFAR-10/100
 - Oxford-IIIT Pets
 - Oxford Flowers-102
- VTAB Datasets for 19 tasks
 - 19개의 downstream tasks
 - Natural, Specialized (의료, 위성 사진 등), Structured (localization 같은 이미지 내 기하에 대한 이해 바탕의 task로 구성)의 3개 그룹으로 분류하는 것

Model	Layers	Hidden size D	MLP size	Heads	Params
ViT-Base	12	768	3072	12	86M
ViT-Large	24	1024	4096	16	307M
ViT-Huge	32	1280	5120	16	632M

Table 1: Details of Vision Transformer model variants.

Model Variants

- Baseline은 ResNet을 Group Normalization과 Standardized Convolutions(BiT)로 구성하였다.
- Hybrids는 ViT에 ResNet의 stage 4 feature map을 입력으로 넣고 patch size를 1로 설정하였다.

Training Details

Models	Dataset	Epochs	Base LR	LR decay	Weight decay	Dropout
ViT-B/{16,32}	JFT-300M	7	$8 \cdot 10^{-4}$	linear	0.1	0.0
ViT-L/32	JFT-300M	7	$6 \cdot 10^{-4}$	linear	0.1	0.0
ViT-L/16	JFT-300M	7/14	$4 \cdot 10^{-4}$	linear	0.1	0.0
ViT-H/14	JFT-300M	14	$3 \cdot 10^{-4}$	linear	0.1	0.0
R50x{1,2}	JFT-300M	7	10^{-3}	linear	0.1	0.0
R101x1	JFT-300M	7	$8 \cdot 10^{-4}$	linear	0.1	0.0
R152x{1,2}	JFT-300M	7	$6 \cdot 10^{-4}$	linear	0.1	0.0
R50+ViT-B/{16,32}	JFT-300M	7	$8 \cdot 10^{-4}$	linear	0.1	0.0
R50+ViT-L/32	JFT-300M	7	$2 \cdot 10^{-4}$	linear	0.1	0.0
R50+ViT-L/16	JFT-300M	7/14	$4 \cdot 10^{-4}$	linear	0.1	0.0
ViT-B/{16,32}	ImageNet-21k	90	10^{-3}	linear	0.03	0.1
ViT-L/{16,32}	ImageNet-21k	30/90	10^{-3}	linear	0.03	0.1
ViT-*	ImageNet	300	$3 \cdot 10^{-3}$	cosine	0.3	0.1

Table 3: Hyperparameters for training. All models are trained with a batch size of 4096 and learning rate warmup of 10k steps. For ImageNet we found it beneficial to additionally apply gradient clipping at global norm 1. Training resolution is 224.

- Optimizer는 사전학습에는 Adam을, 파인튜닝에는 SGD를 사용하였다.
 - Batch size는 4096으로 설정하였다.
 - 학습률은 Linear Warmup을 적용한 뒤 Cosine 또는 Linear Decay를 사용하였다.
- Fine-tuning Results

	Ours-JFT (ViT-H/14)	Ours-JFT (ViT-L/16)	Ours-I21k (ViT-L/16)	BiT-L (ResNet152x4)	Noisy Student (EfficientNet-L2)
ImageNet	88.55 ± 0.04	87.76 ± 0.03	85.30 ± 0.02	87.54 ± 0.02	88.4/88.5*
ImageNet Real	90.72 ± 0.05	90.54 ± 0.03	88.62 ± 0.05	90.54	90.55
CIFAR-10	99.50 ± 0.06	99.42 ± 0.03	99.15 ± 0.03	99.37 ± 0.06	—
CIFAR-100	94.55 ± 0.04	93.90 ± 0.05	93.25 ± 0.05	93.51 ± 0.08	—
Oxford-IIIT Pets	97.56 ± 0.03	97.32 ± 0.11	94.67 ± 0.15	96.62 ± 0.23	—
Oxford Flowers-102	99.68 ± 0.02	99.74 ± 0.00	99.61 ± 0.02	99.63 ± 0.03	—
VTAB (19 tasks)	77.63 ± 0.23	76.28 ± 0.46	72.72 ± 0.21	76.29 ± 1.70	—
TPUv3-core-days	2.5k	0.68k	0.23k	9.9k	12.3k



• 평가 방식

- ViT 모델과 기존 전이학습 SOTA CNN 모델(BiT-L, NoisyStudent)을 비교하였다.
- Fine-tuning을 각 데이터셋마다 3번 진행한 후, 정확도의 평균과 표준편차를 계산하여 성능을 평가하였다.
- 효율성은 TPUv3-core-days = 사용된 코어 수 × 소요 일수로 측정하였다.


• 결과

- 중간 규모 데이터셋에서는 Baseline(CNN)이 ViT보다 성능이 높았다. (ViT<Baseline)
- 대규모 데이터셋에서는 ViT가 Baseline을 능가하였다. (ViT>Baseline)
- ViT는 모델 파라미터와 데이터셋 크기가 커질수록 성능이 지속적으로 증가하며, 성능 포화(saturation)가 나타나지 않았다.


• Pre-training Data Requirements



- **왼쪽:** Pre-training 데이터셋 크기(ImageNet, ImageNet-21k, JFT-300M)에 따른 ViT와 ResNet 성능 비교
- **오른쪽:** Pre-training 샘플 수(10M ~ 300M)에 따른 few-shot 성능 비교
- 작은 데이터셋(ImageNet)에서는 BiT-ResNet이 ViT보다 성능이 높고, 큰 ViT 모델일 수록 더 불리하다.
- ImageNet-21k에서는 ViT-Base와 ViT-Large의 성능 차이가 줄어든다.
- JFT-300M처럼 초대형 데이터셋에서는 ViT-Large가 ViT-Base를 앞서며, 데이터셋이 커질수록 ViT 성능이 계속 향상된다.
- Scaling Study



- **왼쪽:** 여러 벤치마크(average-5)에서 성능과 연산량(exaFLOPs) 관계
- **오른쪽:** ImageNet에서 성능과 연산량 관계
- 적은 데이터(10M, 30M)에서는 ResNet이 ViT보다 우수하다.
- 데이터가 커질수록 ResNet 성능은 점차 포화되는 반면, ViT는 꾸준히 성능이 향상된다.
- ViT는 대규모 데이터셋에서 ResNet을 능가하며, few-shot 학습 상황에서도 높은 일반화 성능을 보인다.



- RGB 임베딩 필터를 보면 CNN의 초기 합성곱 필터처럼 색상, 엣지, 패턴을 포착하는 양상이 나타난다. → 따라서 ViT도 입력 단계에서 CNN과 유사하게 저수준 시각적 특징을 학습하고 있음을 알 수 있다.
- 위치 임베딩 유사도를 보면 인접한 패치일수록 높은 값을 가지며, 거리가 멀어질수록 유사도가 낮아진다. → 따라서 ViT가 패치 간 상대적 위치 정보를 효과적으로 인코딩하고 있음을 알 수 있다.
- Attention 거리 분석을 보면 층이 깊어질수록 self-attention의 평균 범위가 넓어진다. → 따라서 ViT는 얇은 층에서 지역적 관계를, 깊은 층에서 전역적 관계를 학습한다는 것을 알 수 있다.

5. Conclusion

결론 및 주요 요약은?

- ViT는 image recognition 분야에 Transformer를 직접 적용한 최초의 사례이다.
- 단순하면서도 높은 확장성을 가진 Transformer 구조를 성공적으로 적용하였다.
- 이미지 특화 inductive bias를 거의 사용하지 않고(패치 분할 제외), 이미지를 NLP와 유사하게 패치 시퀀스로 처리하였다.
- inductive bias가 약하기 때문에 general-purpose architecture로서 활용 가능성이 크다.
- 대규모 데이터셋에서 사전학습 후 CNN 기반 baseline을 능가하는 성능을 보였으며, 사전학습 과정 또한 상대적으로 단순하다.