

Week2 - RNN, seq2seq

25기 분석 김지수

1. LSTM 기반 seq2seq 모델에서 디코딩할 때 사용하는 Beam Search 동작 방식에 대해서 설명하시오.

- Beam Search는 LSTM 기반 Seq2Seq 모델에서 output sequence를 생성하는 과정인 decoding 시 더 나은 문자 생성 결과를 얻기 위해 사용하는 탐색 기법이다.
- 기본적인 seq2seq 모델에서의 디코딩 과정은 보통 greedy decoding 방식을 따르는데, 이는 단순히 해당 시점에서 가장 확률이 높은 후보를 선택하는 방법이므로 시간 복잡도 면에서는 훌륭하나 최종 정확도 관점에서는 좋지 못한 방법이다.
 - 즉 이러한 greedy적 예측에서 한 번이라도 틀린 예측이 나오게 된다면, 이전 예측이 중요한 디코딩 방식에서는 치명적인 문제가 될 수 있다.
 - Beam search가 바로 이 greedy decoding의 단점을 어느 정도 극복하기 위해 나온 방법이다. (해당 시점에서 유망한 beam의 개수(K)만큼 골라서 진행하는 방식)

Beam search는 여러 후보 sequence를 동시에 고려하며 확률이 높은 경로를 탐색한다.

동작 방식 : beam width B를 지정하면 매 디코딩 시점마다 가장 확률이 높은 상위 B개의 후보 문장을 유지하게 되고, 각 후보는 다음 단어를 예측하여 확장하면서 이들 중 가장 높은 누적 확률을 가진 상위 B개가 다시 선택되는 흐름이다. 최종적으로는 가장 높은 확률을 가진 전체 시퀀스를 선택하거나, 특정 종료 토큰(EOS)이 등장한 시점에서 종료할 수 있게 된다.

ex) beam width=3이면 매 시점에서 상위 3개의 가능한 경로를 유지하면서 decoding을 진행

이렇게 다양한 후보를 고려하며 더 자연스러운 문장을 생성할 가능성이 높아지는 한편, 계산 비용이 증가하여 beam width 크기에 따라 성능이 달라질 수 있다는 단점이 있다.

참고 자료 :

<https://blog.naver.com/sooftware/221809101199>

<https://littlefoxdiary.tistory.com/4>

2. Seq2Seq with LSTM 모델은 Attention이 없던 시절 제안된 구조이다. 기존 seq2seq 모델의 한계와 이후 attention 메커니즘이 이 한계를 어떻게 보완했는지 설명하시오.

- 기존의 seq2seq w/ LSTM은 다음과 같은 encoder-decoder 구조를 가졌다.
 - encoder : 입력 시퀀스를 고정된 길이의 context vector로 압축
 - decoder : 이 고정된 벡터를 기반으로 출력 시퀀스를 생성
- 한계
 1. 고정된 context vector로 인한 정보의 손실
 - 입력 시퀀스의 길이가 길면 길어질수록 모든 정보를 단 하나의 벡터에 압축해서 담는 것이 어렵고 성능 또한 급격히 떨어진다는 단점이 존재했다.
 2. 입력의 모든 단어가 동등하게 처리되는 문제
 - decoder가 어느 단어에 주목해야 할지 알 수 없어서 문맥 정보가 희석되는 단점도 존재했다.
 - 이를 해결하기 위해 attention 메커니즘이 등장했다.

Attention mechanism은 decoder가 출력 생성 시 입력 시퀀스의 각 단어를 가중합하여 동적으로 참조할 수 있게 해주는 메커니즘이다. 동작 방식을 간단하게 설명하면 다음과 같다.

1. decoding 시 decoder가 encoder의 각 hidden state에 대해 attention score를 계산
2. 이 유사도는 보통 dot product, additive, 또는 scaled dot-product 방식으로 계산되며 마지막에 softmax를 거쳐서 attention weight로 변환된다.
3. 마지막으로 decoder는 이 weight를 기반으로 입력 시퀀스 전체에 대한 가중합(context vector)을 생성하고 이를 이용해 출력 단어를 예측한다.

⇒ 이렇듯 attention을 통해 긴 문장에서도 이제 중요한 단어에 더 집중이 가능하고, 문맥에 따라 동적으로 정보 선택도 가능해지도록 한계점을 보완하였다.