

GPT-1

Abstract

- NLP
 - 텍스트 추론, 질의응답, 의미 유사도 평가, 문서 분류
- 방대한 양의 라벨 없는 텍스트 말뭉치(unlabeled corpus)는 풍부하지만, 특정 task를 학습시키기 위한 라벨된 데이터는 부족
 - 판별적으로 학습된 모델이 충분히 성능을 내기 힘들
- 다양한 말뭉치에 대해 언어 모델을 생성적으로 사전학습한 뒤
 - 각 task에 대해 판별적 미세조정(discriminative fine-tuning)을 수행함으로써 task에서 큰 향상을 달성할 수 있음을 보임
- 이전 접근과 달리, 미세조정 단계에서 **task-aware input transformations**(과업 인지 입력 변환)을 활용
 - 모델 아키텍처의 최소 변경만으로도 효과적인 전이 달성

1. Introduction

- raw text로부터 효과적으로 학습하는 능력은 자연어 처리에서 지도학습에 대한 의존을 완화하는 데 핵심적
 - 대부분의 딥러닝 방법은 상당한 양의 수작업 라벨 데이터 필요
 - 주석 자원이 부족한 많은 도메인에서 적용 가능성을 제한
 - 라벨 없는 데이터로부터 언어 정보를 활용할 수 있는 모델은 더 많은 주석 데이터를 수집하는 데 드는 시간과 비용에 대한 가치 있는 대안이 됨
- 충분한 감독이 존재하는 경우에도 비지도 방식으로 좋은 표현을 학습하는 것은 성능 향상에 의미 있는 도움
 - 다양한 NLP 과업에서 성능을 개선하기 위해 지금까지 가장 설득력 있는 증거
 - 사전학습된 워드 임베딩
- 단어 수준 이상의 정보를 라벨 없는 텍스트에서 활용하는 일은 두 가지 이유로 도전적
 1. 전이에 유용한 텍스트 표현을 학습하는 데 어떤 최적화 목적이 가장 효과적인지 불분명

2. 학습된 표현을 목표 task에 전이하는 가장 효과적인 방법에 대해 합의가 없음

- 기존 기법들은 과업 특화 아키텍처 변경, 복잡한 학습 스킴, 보조 학습 목적 추가를 결합하는 경향

→ 이러한 불확실성은 언어 처리를 위한 효과적인 준지도 학습 접근을 개발하는 것을 어렵게 만들

- 본 논문에서는 비지도 사전학습 + 지도 미세조정을 결합한 준지도 접근을 탐구
 - 최소한의 적응으로 광범위한 과업에 전이되는 범용 표현을 학습하는 것이 목표
- 방대한 라벨 없는 텍스트 말뭉치와 수잡업 라벨이 달린 여러 목표 과업 데이터셋에 접근할 수 있다고 가정
 - 라벨 없는 말뭉치와 목표 task의 도메인이 동일할 필요는 없음
 - 학습 절차 두 단계
 1. 라벨 없는 데이터에서 language modeling objective를 사용해 신경망의 초기 파라미터 학습
 2. 해당 파라미터를 각 목표 과업의 지도 목적에 맞춰 적응시킴
- 모델 아키텍처로 Transformer 사용
 - 다양한 task에서 강력함이 입증됨
 - 순환망 같은 대안보다 텍스트의 장기 의존성을 다루기 위한 보다 구조화된 메모리를 제공하여 다양한 과업에서 견고한 전이 성능을 보임
- 전이 시에는 traversal-style-approaches에서 유도한 과업 특화 입력 적응(task-specific input adaptations)을 활용하여 구조화된 텍스트 입력을 단일 연속 토큰 시퀀스로 처리
 - 실험을 통해 입력 변환이 사전학습된 모델 아키텍처의 변경을 최소화하면서 효과적인 미세조정을 가능하게 함을 보임

2. Related Work

- NLP를 위한 준지도 학습
 - 초기 접근: 라벨 없는 데이터로부터 단어/구 통계를 계산 → 지도 모델의 feature로 사용
 - 최근: unlabeled corpus로 학습된 word embeddings 사용 → 다양한 task 성능 개선

- 한계: 주로 **단어 수준 정보** 전이에 집중
- 목표: 더 높은 수준의 semantics 포착
- **비지도 사전학습**
 - 목표: 지도 objective를 바꾸는 대신 좋은 초기화 지점을 찾는 것
 - 이미지 분류, 음성 인식, 기계 번역 등 다양한 분야에서 효과 입증
 - 언어 모델링 objective로 pre-train → target task에 fine-tuning
 - LSTM 기반 연구: 짧은 범위 예측에 제한
 - Transformer 기반: 긴 범위 언어 구조 포착 가능, 다양한 task에 효과
- **보조 학습 목적**
 - auxiliary unsupervised objective 추가도 준지도 학습의 한 형태
 - Collobert & Weston: POS, 청킹, NER, LM 등 보조 task → SRL 개선
 - 최근 연구: target objective에 auxiliary LM objective 추가 → 성능 향상
 - 본 연구: auxiliary objective도 사용하지만, pre-training만으로도 이미 많은 언어적 측면 학습

3. Framework

- 학습 절차 2단계
 1. **Unsupervised pre-training**
 - 언어 모델링 objective
 - Transformer decoder 기반 LM 사용
 - multi-head self-attention + position-wise FFN
 2. **Supervised fine-tuning**
 - labeled dataset으로 적응
 - 마지막 layer activation → linear layer W_y → softmax로 라벨 예측
 - auxiliary LM objective 추가 시: 일반화 향상 + 수렴 가속
- 추가 파라미터:
 - W_y , delimiter 토큰 임베딩
- **Task-specific input transformations**

- structured input을 token sequence로 변환
- Textual entailment: premise + delimiter + hypothesis
- Similarity: 두 문장 순서를 모두 포함, 독립 처리 후 element-wise sum
- QA/Commonsense reasoning: [document; question; delimiter; answer]
각각 독립 처리, softmax로 후보 정규화

4. Experiments

• Setup

- Dataset: BooksCorpus (7천 권, 긴 연속 텍스트)
- Model: 12-layer decoder-only Transformer
 - hidden size 768, 12 heads, FFN dim 3072
 - Adam($2.5e-4$), warmup 2000 step, cosine decay
 - Epoch 100, batch 64, sequence length 512
 - Dropout 0.1, GELU, BPE vocab 40k
- Fine-tuning: $lr=6.25e-5$, batch=32, epoch=3

• Results

- **Natural Language Inference**
 - SNLI, MNLI, QNLI, SciTail, RTE 평가
 - 5개 중 4개에서 SOTA 달성
 - RTE는 데이터가 작아 성능 낮음
- **Question Answering & Commonsense Reasoning**
 - RACE, Story Cloze
 - Story Cloze: +8.9%, RACE: +5.7% 향상
- **Semantic Similarity**
 - MRPC, QQP, STS-B
 - STS-B: +1 point, QQP: +4.2% 향상
- **Classification**
 - CoLA: 45.4 , SST-2: 91.3%

- GLUE overall: 72.8

→ 총 12개 task 중 9개에서 새로운 SOTA

5. Analysis

- 전이된 층 수
 - 더 많은 층을 전이할수록 성능 향상
 - MultiNLI: full transfer 시 +9%
- Zero-shot behaviors
 - 생성 모델 자체가 여러 task를 암묵적으로 학습
 - Transformer의 구조화된 메모리 → LSTM보다 안정적
 - 휴리스틱 실험: CoLA, SST-2, RACE, Winograd schema에서 점진적 성능 향상 확인
- Ablation study
 - auxiliary LM 제거: 큰 dataset에서는 이점, 작은 dataset은 영향 적음
 - Transformer vs LSTM: LSTM은 평균 점수 5.6 낮음, MRPC에서만 우위
 - Pre-training 제거: 전반적 성능 -14.8%

6. Conclusion

- 생성적 사전학습 + 판별적 미세조정 프레임워크 제안
- 다양한 긴 텍스트 말뭉치에서 사전학습 → 세계 지식 + 장기 의존성 처리 능력 획득
- 이를 QA, semantic similarity, entailment, classification에 전이 → 12개 중 9개 task에서 SOTA
- 비지도 (사전)학습이 판별적 과업 성능 향상에 효과적임을 실증
- Transformer + long-range text가 가장 적합한 조합임을 제시
- 향후 비지도 학습 연구의 발전에 기여할 수 있기를 기대