

[Paper Review] Denoising Diffusion Probabilistic Models

25기 분석

서영우

1. Introduction & Diffusion Model?

기존 생성 모델은 GAN, VAE 등이 주를 이뤘는데, 과거 확산 모델들은 학습이 간단하고 효율적임에도 고품질 샘플 생성에는 한계가 있다고 판단.

VAE와 같이 log likelihood 측면에서는 경쟁력이 떨어질지 몰라도 손실 압축과 autoregressive decoding 형태로 일반화했다는 점이 흥미로운 점.

손실 압축(lossy compression)?

사람의 눈이 색상의 변화보다 밝기의 변화에 더 민감하고, 돌고래처럼 특정 주파수 대역의 소리를 듣지 못하는 등 인지적 한계를 이용해 불인지 노이즈를 제거. 책의 내용을 요약정리 비유 가능.

vs 무손실 압축(데이터 완벽 보존)

Autoregressive Decoding?

이름 그대로 첫 번째 조각부터 시작해서 마지막 조각까지 순서대로, 하나씩 만들어나가는 원리.

이전 생성에 영향을 받으므로, Markov Chain의 내용을 담고 있음.

후에 언급 예정이지만, 일반적인 autoregressive는 방향이 정해져있는, 고정된 순서를 따르는 반면 diffusion 모델은 순수 노이즈에서 이미지 전체의 디테일을 점진적으로 구체화

2. Mechanisms

1) Forward Process

$$q(x_t|x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I)$$

원본 이미지 x_0 에 T 단계에 걸쳐 점진적으로 가우시안 노이즈를 추가하는 Fixed Markov Chain 과정. 각 t 단계에서 추가되는 노이즈의 양 β_t 은 미리 정해진 스케줄에 따라 결정.

특정 시점 t 의 노이즈가 낀 이미지 x_t 를 원본 이미지 x_0 와 노이즈 ϵ 만으로 한번에 계산할 수 있다는 게 큰 특징.

2) Reverse Process (Forward Process의 역과정)

$$p_\theta(x_{t-1}|x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t))$$

순수 노이즈 x_T 에서 점진적으로 노이즈를 제거해서 원본 이미지 x_0 생성. 신경망 모델

p_θ 이 각 단계에서 이전 단계의 이미지 분포를 예측하도록 학습.

모델에 평균 μ_θ 를 직접 예측하는 대신 x_t 를 만드는 데 사용된 노이즈 ϵ 을 예측하도록 모델 재구성

Denoising Score Matching?

(1) Score = Gradient

데이터가 더 밀집된 방향을 나타내는 벡터. 고양이 사진 데이터가 많이 모여있는 경우, 강아지 사진을 고양이처럼 만들기 위해 어떤 방향으로 픽셀을 수정해야하는지 알려주는 값

(2) Denoising

원본 이미지에 일부러 흐릿한 이미지를 주어서, 역으로 흐릿한 이미지에서 원본 이미지를 만드는 데 어떤 노이즈가 필요한지 예측을 하면 자가적으로 Score을 학습하게 됨.

(3) = (1) + (2)

노이즈가 낀 이미지 x_t 에서 x_{t-1} 의 이미지를 예측하는데, x_t 대신 ϵ 을 예측하도록 모델 설계. 고품질 이미지를 생성하는 데 효과적.

3) Simplified Training Objective

실제로 추가된 노이즈 ϵ 과 신경망이 예측한 노이즈 ϵ_θ 사이의 평균 제곱 오차 최소화

$$L_{simple}(\theta) := \mathbb{E}_{t, x_0, \epsilon} [\|\epsilon - \epsilon_\theta(\sqrt{\alpha_t}x_0 + \sqrt{1 - \alpha_t}\epsilon, t)\|^2]$$

가중치 조절을 통해 품질 향상 유도.

3. DDPM's Architectures

1) 시간 임베딩(Time Embedding)

각 노이즈 제거 단계(t) 정보를 모델에 전달하기 위해 트랜스포머에서 사용되는 sinusoidal position embedding을 각 잔차 블록에 주입

2) 어텐션 메커니즘(Attention Mechanism)

이미지의 전역적인 특징을 포착하기 위해 16×16 해상도의 feature map에 self-attention 블록을 적용

3) 정규화(Normalization)

weight normalization 대신 group normalization를 사용하여 구현을 단순화

4. 장단점

장점

(1) GAN에 필적하는 고품질 이미지 생성

(2) 간단한 MSE 손실함수로 안정적인 학습 가능

(3) 이미지 보간이 자연스러움(sampling 과정)

단점

(1) 고품질을 제공하는 만큼, 속도가 느림 (1000번 넘게 하는 경우도, 최대 단점?)

(2) Negative Log-Likelihood(이하 NLL) 은 생성 모델이 실제 데이터의 분포를 얼마나 잘 학습했는지를 평가하는 지표인데, 실제 데이터를 잘 예측하면 놀라움이 적어(당연히 잘만들어야지 라는 마인드) NLL 값이 낮아짐(압축 효율이 좋을때도 낮다고 판단). 그런데 그정도로 낮지 않다?