



You Only Look Once: Unified, Real-Time Object Detection

■ 생성일	@2025년 9월 24일 오후 9:10
■ 태그	In progress

- 1) Abstract
 - 2) Introduction
 - 3) Related Works
 - 4) 연구 접근법과 모델 구조 (Method)
 - 5) 실험 구성과 결과 (Experiments)
 - 6) 무엇을 발견했고 한계점은? (Discussion)
 - 7) 결론 및 주요 요약 (Conclusion)
- 주요 수식

1) Abstract

- 객체 탐지를 “분류기 재활용 + 파이프라인 조합” 문제로 보지 않고, 하나의 회귀 (regression) 문제로 재정의
- 입력 이미지 한 번만 보고(You Only Look Once) 바운딩 박스와 클래스 확률을 단일 신경망이 한 번에 예측하는 통합(End-to-End) 구조를 제안. 실시간(45 FPS) 동작을 목표로 함

2) Introduction

- 기존 DPM/슬라이딩 윈도우, R-CNN 계열은 느리고 단계별로 분리된 복잡한 파이프라인이라 전체 최적화가 어려움
 - 그러나 YOLO는 한 번의 네트워크 추론 + NMS만으로 끝나는 간결한 흐름을 제시
- YOLO의 장점
 - 매우 빠르고 전역 문맥을 활용(배경 오검출 감소), 도메인 일반화(예술작품 등) 우수
 - 단, 정밀한 위치(localization)에 약함(특히 소형 객체)

3) Related Works

- **DPM(Deformable Part Model)**

1. sliding window: 이미지 픽셀마다 bounding box(window)를 그림
2. block wise operation: 하나의 이미지를 block 단위로 분리
3. HOG block wise orientation histogram: 각 bounding box 영역마다 HOG feature에 대한 histogram 추출
4. 위 과정에서 추출한 특징을 바탕으로 어떤 객체에 대한, 예를 들어 사람에 대한 팔, 다리, 가슴이 검출된다면 해당 객체를 사람으로 분류

- **R-CNN**

- 설정한 region을 CNN의 feature(input)로 활용하여 Object detection을 수행하는 신경망 모델
 - 1. Region proposal: input image에 대해서 selective search 알고리즘을 적용해 물체가 존재할 가능성이 있는 box 2000개를 추출 → Localization task에 해당
 - 2. 2000개의 ROI를 동일한 크기로 wrapping
 - 3. 이 이미지를 CNN의 입력으로 사용
 - 4. CNN에서 나온 feature들에 대해 binary SVM에 넣어 class 분류 → Classification task에 해당
- 기존의 HOG+SVM 기반 방법보다 훨씬 강력한 표현력 확보
 - Object Detection 성능을 크게 끌어올려 딥러닝 Detection 시대의 문을 열었음
 - 매우 느린 속도
 - End-to-end 학습이 불가능
 - 실시간/고성능 탐지기 비교: Fast/ Faster R-CNN 등은 정확하지만 실시간은 어려움. YOLO/ Fast YOLO는 실시간 영역에서 최고 속도/경쟁력!!

4) 연구 접근법과 모델 구조 (Method)

1. **통합 탐지 파이프라인**

- 이미지를 $S \times S$ 그리드로 분할하고 객체 중심이 속한 셀이 그 객체를 담당

- 각 셀은 B개 박스(x,y,w,h, confidence)와 C개 클래스 조건부 확률을 예측
- 테스트 시 $\text{Pr}(\text{Class}|\text{Object}) \times \text{Pr}(\text{Object}) \times \text{IoU}$ 로 클래스별 confidence를 산출
- PASCAL VOC 설정: S=7, B=2, C=20 → 7×7×30 텐서 출력
- 한 번의 네트워크 실행 → NMS만으로 최종 검출

2. 네트워크 아키텍처

- 분류용 GoogLeNet에서 영감: 24 Convolution + 2 FC, 1×1 축소 뒤 3×3 Conv 반복
- 사전학습(분류, 224) 후 탐지에 맞게 층 추가 및 입력 448로 증대
- Fast YOLO는 얇고 가벼운 변형(9 conv)

3. 학습 목표(loss) 설계의 핵심

- 좌표 손실 가중치↑($\lambda_{\text{coord}}=5$), 배경 박스 confidence 손실 가중치↓($\lambda_{\text{noobj}}=0.5$)로 학습 안정화
- w,h는 제곱근으로 예측하여 큰 박스와 작은 박스 오차의 균형 개선
- 다중 박스 중 IoU가 가장 큰 예측자만 그 객체에 "responsible"로 할당(전문화 유도)
- 전체 손실은 좌표 + 크기(제곱근) + 객체 confidence + 비객체 confidence + 분류의 합

5) 실험 구성과 결과 (Experiments)

- **데이터/학습**: VOC 2007/2012 train/val 조합으로 약 135 epoch 학습, 모멘텀 0.9, weight decay 5e-4, 배치 64
- LR warm-up 후 단계적 감소, dropout 0.5, 강한 데이터 증강(스케일/평행이동/노출·채도)
- **속도/정확도(VOC07)**:
 - Fast YOLO: mAP 52.7, 155 FPS
 - YOLO: mAP 63.4, 45 FPS
 - Faster R-CNN(VGG-16): mAP 73.2, 7 FPS
 → 실시간 영역에선 YOLO가 압도적 속도와 양호한 정확도

- 오류 분석: YOLO는 localization error 비중↑, 반면 Fast R-CNN은 배경 오검출↑
- 두 모델 결합 시 mAP 상승

6) 무엇을 발견했고 한계점은? (Discussion)

- 단일 통합 모델만으로도 실시간 + 경쟁력 있는 mAP 달성, 전역 문맥 활용 덕에 배경 오검출이 크게 감소, 도메인 일반화가 좋음
- 한계점
 - 정밀 위치(localization) 취약, 소형 객체에서 성능 저하
 - 그리드 셀은 객체 중심 1개만 담당하므로 한 셀에 여러 객체가 몰리면 놓치기 쉬움

7) 결론 및 주요 요약 (Conclusion)

- 분류기 재활용/제안영역 기반의 복잡한 파이프라인 없이, End-to-End 회귀로 탐지 전체를 통합해 학습·추론 단순화와 실시간성을 동시에 제공
- 단, 정확도 최고치는 당시 Region-based 방법이 앞섰고, 정밀 위치/소형 객체는 과제로 남음
- 기존 연구 대비 차별점
 - 단일 네트워크·단일 추론으로 탐지를 수행("통합")
 - 전역 문맥을 항상 활용 → 배경 오검출 대폭 감소
 - 실시간(45~155 FPS) 달성
- **'회귀'로 탐지하는 아이디어**: 이미지 → (그리드 기반) 다중 박스 + 클래스 확률을 한 번에 예측
- **학습 안정화 전략**: $\lambda_{coord}=5$, $\lambda_{noobj}=0.5$, w,h 제곱근 예측, responsible box 지정

주요 수식

- 클래스별 confidence

$$score = P(Class_i | Object) \times P(Object) \times IoU_{pred, gt} \\ score = P(Class_i | Object) \times P(Object) \times IoU_{pred, gt}$$

→ 박스가 해당 클래스일 확률 × 박스 품질을 함께 반영

- 손실 함수(요지)

- 좌표: $(x - \hat{x})^2 + (y - \hat{y})^2$
- 크기: $(\sqrt{w} - \sqrt{\hat{w}})^2 + (\sqrt{h} - \sqrt{\hat{h}})^2$
- 객체 신뢰도(Obj)/비객체 신뢰도(No-obj) 항
- 분류 오차(객체가 있을 때만)
- 가중치: $\lambda_{coord}=5, \lambda_{noobj}=0.5$

- 책임 할당(responsible predictor)

- 한 셀의 B개 박스 중 **IoU가 최대인 박스만** 그 객체를 담당 → **전문화로 recall↑**

- 추론(의사 코드)

1. 이미지 448로 리사이즈 → 1회 CNN 추론
2. 셀별 B박스과 C클래스 확률 획득
3. 클래스별 confidence 계산
4. 임계값 필터 + NMS 출력

⇒ (논문 Figure 1/2 흐름과 동일)